DAT 7기 캡스톤 프로젝트 보고서

KR-FinBERT와 LSTM 기반의 다중 모달 융합을 통한 KODEX 200 수익률 예측 및 변동성 분석

DAT 7기

매크로 팀

GBT학부 202300399 구다연

국제금융학과 202202618 이예현

통계학과 202202773 이지수

전자공학과 202501459 이찬영



Data Analysis & Technology



DAT 7기 캡스톤 프로젝트 보고서

KR-FinBERT와 LSTM 기반의 다중 모달 융합을 통한 KODEX 200 수익률 예측 및 변동성 분석

이 보고서를 캡스톤 프로젝트 보고서로 제출합니다.

2026년 06월 04일

DAT 7기

매크로 팀

GBT학부 202300399 구다연

국제금융학과 202202618 이예현

통계학과 202202773 이지수

전자공학과 202501459 이찬영



Data Analysis & Technology



DAT 7기 캡스톤 프로젝트 보고서

KR-FinBERT와 LSTM 기반의 다중 모달 융합을 통한 KODEX 200 수익률 예측 및 변동성 분석

국문 요약

본 연구는 KODEX 200 지수의 미래 5거래일 누적 수익률 예측을 목적으로, 정형 기술지표와 비정형 뉴스 임베딩을 동적으로 통합하는 다중 모달(multimodal) 딥러닝 프레임워크를 제안한다. 2021년 3월부터 2026년 3월까지 약 5년간의 일별 기술지표 데이터와 KR-FinBERT 기반 뉴스 임베딩 및 감성 점수 데이터셋을 구축하였다.

연구의 최종 제안 모델은 차원 축소된 고차원 뉴스 임베딩, 단기 방향성 신호인 감성 점수, 그리고 기술지표 벡터를 하나의 입력 공간으로 단순 결합한 후, 시간적 의존성을 추출하는 2-Layer Stacked LSTM 구조이다. 특히 본 연구에서는 정형 · 비정형 피처 간의 상호작용을 정량적으로 분석하고 시장 국면별 대응력을 검증하기 위해, Feature Attention 메커니즘을 적용한 AT-LSTM 모델을 함께 구축하여 비교 분석을 수행하였다. AT-LSTM은 기술지표와 압축된 뉴스 임베딩을 결합한 후, 피처별 중요도를 동적으로 산출함으로써 시장 국면에 따른 적응적 예측과 피처 기여도 해석을 가능하게 한다.

모델의 유효성은 엄격한 시계열 분할을 통해 데이터 누수(Data Leakage)를 원천 차단한 환경에서 검증하였다. 실험 결과, 제안 모델(Tech+Sentiment+Embedding LSTM)은 Hit Ratio 73.56%, 상관계수 0.5238, RMSE 0.03695를 기록하며, 단일 시점 베이스라인인 XGBoost(Hit Ratio 31.03%, 상관계수 0.0919) 및 기술지표만 활용한 LSTM 모델(Hit Ratio 29.55%) 대비 압도적인 성능 향상을 달성하였다.

또한 뉴스 지표의 실효성을 검증하기 위해 뉴스 지표를 포함한 모델과 포함하지 않은 모델을 비교하는 절제 연구(ablation study)를 수행하였고, 그 결과 뉴스 기사별 텍스트 임베딩 벡터와 감성점수를 모두 포함한 모델이 가장 우수한 예측 성능을 보임을 확인했다. 이는 뉴스 기반 비정형 정보가 한국 주식 시장 예측에 유의미한 정보를 제공하며 정형 금융 지표와 비정형 뉴스 정보를 결합한 모델이 주가 예측 성능 향상에 효과적일 수 있음을 시사한다.

목 차

1. Introduction 1

2. Related Works 2

2.1 주가 예측 2

2.2 뉴스 감성 분석 3

3. 데이터 전처리 3

3.1 Data Preprocessing 3

3.2 KR-FinBERT 4

4. 모델 설계 및 결과 5

4.1 Baseline: XGBoost Regressor 5

4.2 Proposed Model: 2-Layer LSTM 6

4.3 Comparison Model: AT-LSTM 10

5. 성능 비교 및 최종 모델 선정 14

5.1 Performance Comparison 14

6. Ablation Study 15

6.1 2-Layer LSTM 모델 ablation 결과 15

6.2 뉴스 지표 실효성 검증 결과 16

7. Conclusion 19

References (참고문헌) 20

표 목 차

[표 3-1] 데이터셋 구성 개요 4
[표 3-2] 기술지표 변수 목록 (17개) 4
[표 4-1] 기술지표 평균 어텐션 가중치 상위 5개 변수 12
[표 5-1] 모델별 최종 테스트 성능 비교 15
[표 6-1] 2-Layer LSTM 입력 변수 구성별 성능 비교 (Ablation Study) 15
[표 6-2] 1차 DM 검정 -- Tech_only 대비 뉴스 정보 추가 효과 검증 (Squared Error 기준) .. 17
[표 6-3] 1차 DM 검정 -- Tech_only 대비 뉴스 정보 추가 효과 검증 (Absolute Error 기준) 17
[표 6-4] 2차 DM 검정 – Tech_Sentiment_Embedding 대비 부분 모델들과의 성능 차이 검증 (Squared Error 기준) 18
[표 6-5] 2차 DM 검정 – Tech_Sentiment_Embedding 대비 부분 모델들과의 성능 차이 검증 (Absolute Error 기준) 18

그 림 목 차

[그림 4-1] 최종 모형 LSTM 모델 구조 시각화 9
[그림 4-2] LSTM, XGBoost test 구간 모델 성능 시각화 10
[그림 4-3] AT-LSTM 최적 모델 예측값 vs 실제 수익률 (테스트 기간) 12
[그림 4-4] 피처별 평균 어텐션 가중치 상위 15개 (테스트셋 기준, 빨간색: 뉴스 관련 지표) ... 13
[그림 4-5] 모델 성능 종합 레이더 차트 -- 5개 정규화 지표 기준 비교 14
[그림 6-1] 2-Layer LSTM Ablation Study: 입력 모달리티 단계별 추가에 따른 성능 변화 15
[그림 6-2] test 구간 ablation study 모델 성능 시각화 16

1. Introduction

과거 금융 시장 예측 연구는 가격, 거래량, 기술지표 등의 정형 시계열 데이터를 중심으로 발전해왔다. 그러나 현대 금융 시장은 정형 데이터만으로 설명되지 않는 복합적 정보 환경 속에서 형성된다. 중앙은행의 금리 결정, 기업 실적 발표, 지정학적 리스크 등 텍스트 기반 이벤트가 시장 가격에 미치는 영향은 단기적으로 기술지표를 압도하는 경우가 빈번하게 관찰된다.

이러한 환경에서 정형 데이터와 비정형 데이터의 유기적 결합을 통한 다중 모달(Multimodal) 예측 모델의 구축은 필수적이다. 하지만 고차원의 텍스트 임베딩 정보와 휘발성이 강한 뉴스 감성 점수(Sentiment Score)를 시계열 모델 내에 어떻게 안정적으로 녹여낼 것인가에 대한 구조적 난제가 존재한다. 많은 선행 연구들이 복잡한 어텐션(Attention)이나 게이트(Gate) 메커니즘을 도입하여 모달리티 간의 동적 융합을 시도해왔으나, 금융 시계열 데이터가 지닌 특유의 높은 노이즈와 무작위성(Random Walk)으로 인해 과적합(Overfitting)을 유발하거나 도리어 학습의 불안정성을 초래한다는 한계가 지적되어 왔다. 본 연구에서는 구조적 복잡성을 배제하고, 정형 시계열 데이터와 비정형 뉴스 정보의 단순 결합만으로 금융 시장의 중기 추세를 안정적으로 포착할 수 있는지를 확인한다.

KR-FinBERT 기반의 고차원 뉴스 임베딩(768차원)과 단기 방향성 신호인 감성 점수를 일별 파생 기술지표 시퀀스와 결합하여 동적 시간 의존성을 학습하는 2-Layer Stacked LSTM 프레임워크를 최종 제안 모델로 설정한다. 금융 데이터의 단기 고주파 노이즈를 상쇄하기 위해 예측 타겟은 미래 5거래일간의 누적 로그수익률로 정의하였다.

특히 본 연구는 모델의 유효성을 다각도로 검증하기 위해 3단계의 점진적 실험 설계를 취한다. 첫째, 전일 하루의 데이터만을 입력으로 사용하는 XGBoost Regressor를 베이스라인으로 설정하여 기준 성능을 확립한다. 둘째, 정형 데이터만을 활용하는 2-Layer LSTM 구조를 통해 시계열 자체의 기초 예측력을 측정한다. 셋째, 최종 제안 모델인 단순 결합 기반 멀티모달 2-Layer LSTM을 통해 정형 · 비정형 정보의 통합 시너지를 추적하는 절제 연구(Ablation Study)를 수행한다.

나아가 본 연구는 정형 피처와 비정형 피처 간의 상호작용을 정량적으로 분석하고 시장 국면별 대응력을 검증하기 위해, Feature Attention 메커니즘을 적용한 AT-LSTM 모델을 함께 구축하여 심층 분석을 수행한다. AT-LSTM은 기술지표와 압축된 뉴스 정보를 결합한 후 피처별 가중치를 동적으로 산

출함으로써, 시장 국면에 따른 적응적 예측력과 피처 기여도의 해석 가능성을 제공한다.

최종 실험 결과 및 Diebold-Mariano 통계 검정은 복잡한 어텐션 레이어를 최종 출력 구조에 강제하지 않더라도, 풍부한 배경 맥락(뉴스 임베딩)과 단기 방향성 신호(감성 점수)가 결합될 때 고층 구조의 LSTM 내에서 상호 보완적 시너지가 극대화되어 압도적인 오차 감소와 방향성 적중률 향상을 달성할 수 있음을 실증적으로 입증하고자 한다.

2. Related Works

2.1 주가 예측

전통적인 금융 시계열 예측은 ARIMA, GARCH 등 통계 모델에서 시작하여, 딥러닝의 발전과 함께 LSTM(Long Short-Term Memory), GRU(Gated Recurrent Unit), Transformer 기반 모델로 진화하였다. Fischer and Krauss(2018)는 S&P 500 종목에 LSTM을 적용하여 Buy-and-Hold 전략 대비 유의미한 초과 수익률을 달성하였음을 보고하였다. Hochreiter and Schmidhuber(1997)가 제안한 LSTM은 Forget Gate, Input Gate, Output Gate의 삼중 게이트 구조를 통해 기울기 소실 문제를 극복하고 장기 의존성을 효과적으로 포착한다는 특성으로 금융 시계열 예측 분야에서 광범위하게 활용되어 왔다.

Zhang et al.(2019)이 제안한 AT-LSTM은 각 타임스텝에서 입력 피처별 중요도 가중치를 산출하는 Feature Attention 메커니즘을 LSTM에 결합함으로써, 예측 성능과 해석 가능성을 동시에 향상시켰다. 이 연구는 어텐션 메커니즘이 금융 피처 선택 과정을 자동화하고 시장 국면에 따른 피처 중요도 변화를 동적으로 반영할 수 있음을 실증하였다.

최근에는 금융 시계열에 특화된 파운데이션 모델도 등장하고 있다. PatchTST(Nie et al., 2023)는 시계열을 패치 단위로 분할하여 Transformer에 입력함으로써 장기 의존성 포착 능력을 향상시켰으며, 'Kronos'는 금융 K-line(봉차트) 데이터를 처리하기 위해 사전훈련된 오픈소스 파운데이션 모델로 다양한 다운스트림 예측 태스크에 파인튜닝이 가능하다. 또한 Wavelet Transform과 Multi-Head Attention을 결합한 모형도 제안된 바 있으며, 금리 변화 등 거시경제 지표, 기술지표, 시장 심리 지표를 조합한 LSTM 연구들도 예측 성능의 향상을 보고하고 있다.

2.2 뉴스 감성 분석

금융 뉴스 텍스트를 활용한 감성 분석은 Efficient Market Hypothesis와 행동재무론(Behavioral Finance)의 관점에서 중요성이 부각되어 왔다. Ding et al.(2015)은 딥러닝 기반 이벤트 드리븐 주가 예측 모델을 제안하여 뉴스 이벤트가 단기 시장 방향성에 유의미한 영향을 미침을 보였다. BERT(Devlin et al., 2019) 아키텍처의 등장 이후 금융 도메인 특화 사전학습 모델인 FinBERT(Yang et al., 2020)가 제안되었으며, 일반 감성 분석 모델 대비 금융 특화 어휘에서 탁월한 성능을 보이는 것으로 보고되었다.

한국어 금융 텍스트 처리를 위한 KR-FinBERT는 한국 금융 뉴스, 공시 자료, 애널리스트 리포트 등으로 학습된 KLUE-BERT 기반 모델이다. 국내 연구에서도 뉴스 감성 분석을 이용한 딥러닝 기반 주가 예측(강두원 외, 2022), SNS 감성 분석을 이용한 주가 방향성 예측 등이 발표되며 비정형 텍스트 데이터의 예측 기여 가능성이 실증되고 있다. 다만 이러한 선행연구들은 단순 감성 점수(Scalar)만을 활용하는 경우가 많아, 고차원 임베딩 벡터와 정형 시계열의 동적 융합을 시도하는 본 연구와 방법론적 차별성을 갖는다.

멀티모달 학습 관점에서, 이질적 특징 그룹의 융합은 단순 연결(Concatenation)에서 Attention 기반 융합, Gate 메커니즘 기반 융합으로 발전해왔다. 딥러닝 기반 암호화폐 가격 예측 연구(2022)에서도 멀티모달 학습이 단일 모달 접근 대비 유의한 성능 향상을 보임을 확인하였다. 본 연구는 Gated Fusion 구조를 통해 국면(regime)에 따라 모달리티 가중치가 자동 조절되는 구조를 제안한다는 점에서 기존 연구와 구별된다.

3. 데이터 전처리

3.1 Data Preprocessing

전처리 파이프라인은 세 단계로 구성된다. 첫째, 기술지표 정규화 단계에서는 StandardScaler를 훈련 데이터 기준으로 적합하여 검증 및 테스트 데이터에 동일하게 적용함으로써 데이터 누수(Data Leakage)를 방지한다. 감성 점수(sentiment_score)는 -1.0~+1.0 범위로 설계된 값으로 별도 스케일링 없이 사용한다. 둘째, 뉴스 임베딩 풀링 단계에서는 각 거래일에 존재하는 복수 뉴스 기사 임베딩

벡터를 하나의 일별 뉴스 벡터로 집약하였다. 이때 단순 평균 풀링을 적용하지 않고, 각 기사 임베딩 벡터의 L2 norm을 기반으로 기사별 가중치를 계산한 뒤 softmax 함수를 통해 정규화하였다. 이후 산출된 가중치를 각 기사 임베딩 벡터에 곱해 가중 평균을 수행함으로써, 해당 거래일의 768차원 단일 뉴스 임베딩 벡터를 생성하였다. 셋째, 데이터 분할에서는 시간적 순서를 유지하여 Train/Validation/Test를 85%/7.5%/7.5% 비율로 분할하며, 최종 테스트 기간은 2025년 8월 11일부터 2026년 1월 20일(90거래일)로 고정하였다.

뉴스 데이터가 없는 거래일(휴장일 등)에 대해서는 임베딩 벡터를 0으로 패딩하고 news_missing 플래그를 별도 입력 피처로 추가하여 모델이 뉴스 부재 상황을 명시적으로 인식하도록 하였다. 최종 데이터셋은 기술지표 데이터(1,194 거래일, 17개 특징)와 뉴스 임베딩 데이터(1,269 거래일, 768차원 + 감성 점수)를 일자 키 기준 Inner Join으로 결합하여 약 1,150개 거래일의 통합 데이터셋을 구성하였다.

구분	기간	샘플 수	특징 차원
기술지표	2021.04.22~2026.03.10	1,194	17 (+ target)
뉴스 임베딩	2021.03.10~2026.02.02	1,269	769 (768 + sentiment)
결합 데이터셋	교집합 기간	~1,150	786

[표 3-1] 데이터셋 구성 개요

특징 그룹	변수명	설명
수익률/모멘텀	Return_Lag1, Momentum_10D, Log_Return	전일 대비 수익률(Lag-1), 10일 모멘텀, 로그 수익률
변동성	Vol_5, Vol_21, RV_Trend_5_21, RV_Trend_21_63, ATR_Pct	5 · 21일 실현변동성, 단/중 · 중/장기 변동성 추세 비율, ATR(%)
기술지표	MACD, RSI, SMA_21_Disparity, SMA_63_Disparity	이동평균 수렴 · 발산 지표, RSI(14일), 21 · 63일 이동평균 이격도
거래량/범위	Volume_MA_Ratio, Intraday_Range_Pct	거래량 대비 이동평균 비율, 일중 가격 범위(%)
거시지표	VIX_Change, DXY_Return, Bond_Yield_Change	VIX 변화율, 달러 인덱스 수익률, 채권 수익률 변화

[표 3-2] 기술지표 변수 목록 (17개)

3.2 KR-FinBERT

KR-FinBERT는 KLUE-BERT를 기반으로 한국 금융 뉴스, 공시 자료, 애널리스트 리포트 등 한국어 금

융 도메인 말뭉치로 사전학습된 언어 모델이다. 일반 목적 BERT 모델에 비해 한국어 금융 특화 어휘(종목명, 금융 용어, 경제 지표 등)에 대한 문맥적 이해 능력이 우수하며, 감성 분류(긍정/부정/중립) 태스크에서도 높은 정확도를 보이는 것으로 알려져 있다.

본 연구에서 KR-FinBERT는 두 가지 방식으로 활용된다. 첫째, 각 뉴스 기사를 768차원 임베딩 벡터로 변환하여 풍부한 의미론적 맥락(semantic context)을 포착한다. [CLS] 토큰의 hidden state를 문서 수준 표현으로 사용하며, 동일 거래일의 복수 기사에 대해 L2 정규화 후 평균 풀링을 수행하여 일별 단일 벡터(emb_0~emb_767)를 생성한다. 둘째, 개별 뉴스의 감성 점수(sentiment_score, -1.0~+1.0)를 일별 가중 평균으로 집계하여 단기 시장 방향 신호로 활용한다. 수집된 감성 점수의 기초통계는 평균 0.112, 표준편차 0.200, 중앙값 0.082로 전반적인 양성 편향(Positive Bias) 특성을 보여준다.

768차원의 고차원 임베딩 벡터는 2-Layer LSTM 모델 내 MLP 기반 Projection 레이어(news_fc_dims)를 통해 점진적으로 압축된다. 각 레이어는 Linear → LayerNorm → ReLU 순으로 구성되며, [256, 128, 64] 구조가 최종 채택되었다. 압축된 뉴스 표현은 정형 기술지표 시퀀스와 결합(concatenate)된 후 Gated Fusion 메커니즘을 통해 최종 예측에 통합된다.

4. 모델 설계 및 결과

본 연구에서는 세 가지 모델을 순차적으로 구축하여 비교한다. 첫째, XGBoost Regressor를 베이스라인 모델로 설정하여 성능의 기준점을 확립한다. 둘째, 2-Layer LSTM에 KR-FinBERT 임베딩을 Gated Fusion으로 통합하는 제안 모델을 구축한다. 셋째, Zhang et al.(2019)의 AT-LSTM을 비교 모델로 구현하여 어텐션 메커니즘의 기여도를 검증한다.

4.1 Baseline: XGBoost Regressor

베이스라인 모델은 전일 단일 시점의 정형 기술지표와 뉴스 감성 점수를 입력으로 사용하는 XGBoost Regressor이다. Chen and Guestrin(2016)이 제안한 XGBoost는 그래디언트 부스팅 기반 앙상블 학습 알고리즘으로, 표 형식(tabular) 데이터에서 높은 성능을 보이는 것으로 알려져 있다. 예측 타깃은 미래 5거래일 누적 로그 수익률로 직접 설정하며, 시계열 구조를 명시적으로 활용하지 않는 단일 시점 입력 방식이다.

최종 제안 모델과의 공정한 비교를 위해 베이스라인 모델인 XGBoost Regressor 역시 동일한 기술적 지표와 뉴스 정보를 입력으로 수용하도록 설계하였다. 단, 입력 피처 구성에 있어서 트리 기반 모델의 구조적 특성과 차원의 저주(Curse of Dimensionality) 문제를 고려하였다. 사전 학습된 KR-FinBERT 기반의 뉴스 임베딩 벡터는 768차원의 초고차원 공간을 형성하므로, 단일 시점(전일 하루)의 데이터만을 입력으로 사용하는 XGBoost 모델에 이를 그대로 결합할 경우 피처 수가 샘플 수에 비해 비대해져 극심한 과적합(Overfitting)을 유발하고 예측 모델의 일반화 성능을 저하시킬 위험이 크다. 이에 따라 XGBoost 베이스라인 모델에서는 768차원의 뉴스 임베딩 벡터 피처를 전면 제외하는 대신, 당일 시장의 뉴스 정보와 정성적 신호를 집약적으로 대변할 수 있는 1차원의 뉴스 감성 점수(Sentiment Score)만을 정형 기술적 지표 벡터와 결합하여 최종 피처로 활용하였다. 이는 베이스라인 모델의 파라미터 공간을 경량화하여 안정적인 회귀 예측을 유도하기 위한 통계적 통제 장치이다.

4.1.1 하이퍼파라미터 탐색

하이퍼파라미터 탐색은 Validation Shape Score를 기준으로 수행하였으며, 트리 개수(n_estimators: 100~200), 트리 깊이(max_depth: 2~3), 학습률(learning_rate: 0.01~0.03), 샘플링 비율(subsample: 0.8~0.9), 컬럼 샘플링 비율(colsample_bytree: 0.7~0.8), L1/L2 정규화(reg_alpha: 0.01~0.05, reg_lambda: 5.0~10.0) 등의 조합을 Grid Search하였다. 최종 선택된 최적 하이퍼파라미터는 n_estimators=150, max_depth=3, learning_rate=0.02, subsample=0.8, colsample_bytree=0.7, min_child_weight=5, reg_alpha=0.05, reg_lambda=10.0이다.

4.1.2 Baseline 성능

XGBoost Baseline 모델의 최종 테스트 성능은 RMSE 0.04797, MAE 0.04117, Hit Ratio 31.03%, 상관계수(Corr) 0.0919로 산출되었다. 특히 방향성 적중률(Hit Ratio)이 무작위 확률 수준인 50%를 크게 하회하였으며, 예측 변동성 대비 실제 변동성 비율(Pred Std Ratio)이 0.097에 불과하여 주가 변동폭을 거의 포착하지 못하는 극도의 보수적 예측 경향을 보였다. 이는 단일 시점 정보와 단순 트리 모델 결합 구조가 가진 단기 방향성 포착의 근본적 한계를 방증한다.

4.2 Proposed Model: 2-Layer LSTM

본 연구에서 제안하는 딥러닝 프레임워크는 가격 기반의 정량적 신호와 뉴스 기반의 정성적 맥락을

동일한 시간 축 위에서 동시 학습하기 위해 다중 모달 융합(Multimodal Fusion) 방식을 채택한다. 각 시점 t 에서의 입력 벡터 x_t는 크게 세 가지 이종(Heterogeneous) 데이터 모달리티의 선형 결합으로 구성된다.

첫째, 주가 고유의 움직임과 거시경제 흐름을 포착하기 위해 변화율과 상대적 위치로 재계산된 13차원의 파생 기술적 지표 벡터($x_t^{\{tech\}}$)이다. 둘째, 뉴스 텍스트로부터 추출된 단기 방향성 신호인 1차원의 감성 점수($x_t^{\{sentiment\}}$) 이다. 째, 시장의 배경 맥락과 정성적 이벤트를 풍부하게 담고 있는 고차원 뉴스 텍스트 표현을 다층 퍼셉트론(MLP)에 통과시켜 축소한 뉴스 임베딩 맥락 벡터($x_t^{\{\overline{news}_{reduced}\}}$)이다.

본 연구에서는 고차원 정보 유입에 따른 과적합을 방지하고 시계열 모델의 학습 안정성을 확보하기 위해, 사전 학습된 금융 특화 언어모델(KR-FinBERT)로부터 도출된 768차원의 일별 뉴스 임베딩을 Dense Layer 구조(256 → 128 → 64)를 통해 64차원의 저차원 표현 벡터로 선형 압축한 후 Layer Normalization을 적용하였다. 최종적으로 각 시점 t 의 입력 피처 벡터 xt는 복잡한 게이트나 가중치 할당 구조를 배제하고, 다음과 같이 이종 피처들을 차원 축 상에서 그대로 이어 붙이는 단순 결합(Simple Concatenation) 방식을 통해 도출된다.

$$x_t = [x_t^{\{tech\}}; x_t^{\{sentiment\}}; x_t^{\{\overline{news}_{reduced}\}}]$$

4.2.1 2-Layer Stacked LSTM 아키텍처

결합된 다중 모달 피처 시퀀스는 금융 시계열의 시간적 의존성과 동적 패턴을 학습하기 위해 2계층 구조의 Stacked LSTM에 입력하였다. 본 연구에서는 과거 20거래일의 정보를 하나의 입력 시퀀스로 사용하였으며, 이를 통해 단기적인 가격 변동과 일정 기간 지속되는 뉴스 영향 및 시장 흐름을 함께 반영하고자 하였다.

입력 시퀀스는 각 거래일별 기술적 지표, 감성점수, 뉴스 결측 여부 변수인 news_missing, 그리고 차원 축소를 거친 뉴스 임베딩 벡터를 결합하여 구성하였다. 즉, 각 시점의 입력 벡터는 가격 및 거래량 기반의 정형 정보와 뉴스 텍스트 기반의 비정형 정보를 동시에 포함한다.

본 연구의 LSTM 구조는 2-layer stacked LSTM으로 구성하였다. 첫 번째 LSTM 층은 입력된 다중 모달 피처로부터 가격 변동, 감성 정보, 뉴스 유입 간의 기본적인 시계열 패턴을 학습한다. 두 번째

LSTM 층은 첫 번째 층에서 추출된 정보를 다시 학습하여 보다 복잡한 시간적 흐름과 뉴스 영향의 지속 효과를 반영한다. 이를 통해 단일 LSTM보다 금융 시계열의 복합적인 패턴을 더 깊게 학습할 수 있도록 하였다.

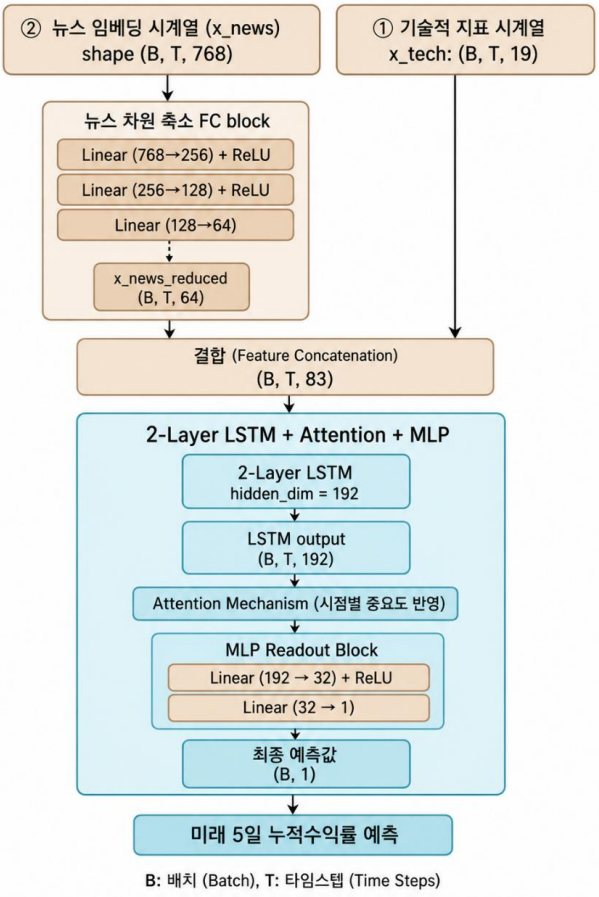
4.2.2 출력층 및 손실함수

일반적인 LSTM 모형은 마지막 시점의 은닉 상태를 이용하여 예측을 수행한다. 그러나 금융 시계열에서는 미래 수익률 예측에 중요한 정보가 반드시 입력 구간의 마지막 시점에만 존재하는 것은 아니다. 특정 거래일의 가격 충격이나 뉴스 이벤트가 이후 수익률에 영향을 미칠 수 있으므로, 과거 20거래일 중 어떤 시점의 정보가 더 중요한지를 반영할 필요가 있다.

이를 위해 본 연구에서는 2-layer LSTM의 출력에 Temporal Attention 메커니즘을 적용하였다. Attention은 LSTM이 생성한 각 시점의 은닉 상태에 대해 중요도를 계산하고, 예측에 더 중요한 시점의 정보를 상대적으로 크게 반영한다. 이를 통해 모델은 전체 입력 기간을 단순히 동일하게 사용하는 것이 아니라, 미래 수익률 예측에 더 관련성이 높은 시점의 정보를 중심으로 최종 표현을 구성할 수 있다. Attention을 통해 생성된 context vector는 입력 기간 전체에서 중요한 정보를 요약한 표현이며, 마지막 시점의 은닉 상태는 가장 최근의 시장 상황을 반영하는 정보이다. 본 연구에서는 두 정보를 모두 활용하기 위해 attention 기반 context vector와 마지막 시점의 은닉 상태를 동일한 비율로 결합하였다. 이렇게 생성된 최종 시계열 표현은 MLP 출력층으로 전달된다. MLP 출력층은 LSTM과 Attention을 통해 추출된 시계열 표현을 바탕으로 최종적으로 하나의 연속형 값을 출력한다. 이 값은 타깃 변수인 미래 5거래일 누적 로그수익률의 예측치에 해당한다.

모델 학습에는 Adam optimizer를 사용하였으며 손실함수는 평균제곱오차(MSE)를 사용하여 예측값과 실제 미래 5거래일 누적 로그수익률 간의 차이를 최소화하도록 학습하였다. 또한 과적합을 방지하기 위해 dropout을 적용하였고, validation 성능이 일정 기간 개선되지 않을 경우 학습을 중단하는 early stopping을 사용하였다.

요약하면, 본 연구의 LSTM 모형은 과거 20거래일의 정형 금융 변수와 뉴스 임베딩 정보를 결합한 뒤, 2-layer stacked LSTM과 Temporal Attention을 통해 중요한 시점의 정보를 반영하고, MLP 출력층을 통해 미래 5거래일 누적 로그수익률을 예측하는 구조이다.



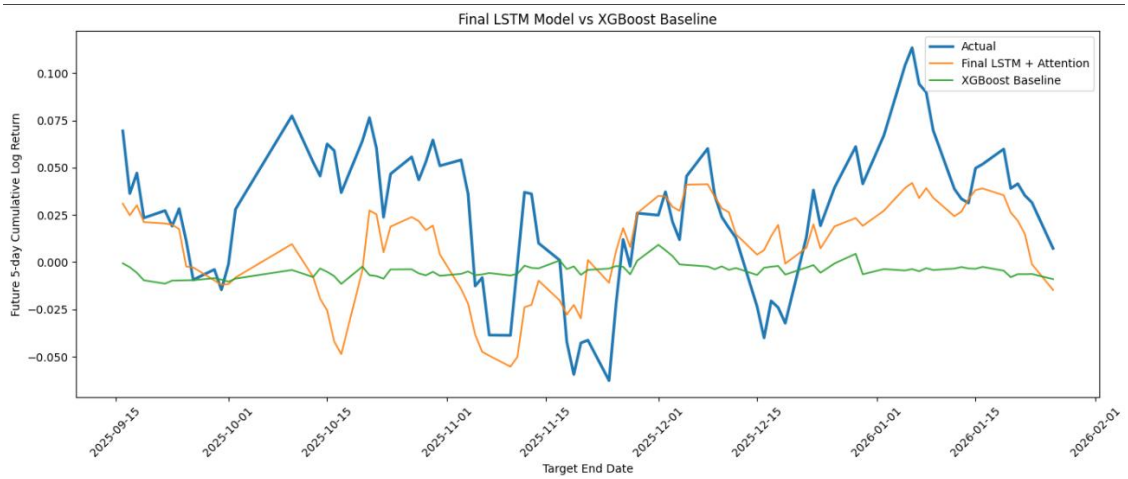
[그림 4-1] 최종 모형 LSTM 모델 구조 시각화

4.2.3 Proposed Model 성능

학습 과정에서는 Adam optimizer를 사용하였으며, 손실함수는 MSE를 기반으로 하되, 금융 시계열의 급등락 구간과 예측 형태를 함께 반영하기 위해 가중 MSE, 상관계수 손실, 예측 변동성 손실을 조합한 형태로 학습하였다. 또한 과적합을 방지하기 위해 dropout을 적용하였고, 학습 과정에서는 validation 성능이 일정 기간 개선되지 않을 경우 학습을 중단하는 early stopping을 사용하였으며, patience는 20으로 설정하였다. 하이퍼 파라미터 탐색은 초기에는 비교적 넓은 범위에서 Grid Search 하였다. 뉴스 임베딩 축소 구조는 [64, 32, 16], [128, 64, 32, 16], [256, 128, 64]를 비교하였고, hidden dimension은 16에서 224 범위, dropout은 0.0에서 0.4 범위, learning rate는 0.00005에서 0.00050 범위, batch size는 16에서 64 범위, weight decay는 0~0.04 범위에서 탐색하였다. 이후 validation 성능과 예측 형태를 종합적으로 고려하여 탐색 범위를 축소하였다. 최종적으로 뉴스 임베딩 축소 구조 =[256, 128, 64], hidden dimension =192, dropout=0.07, learning rate=0.00040,

batch size=16, weight decay=0.0인 모델을 최종 LSTM 후보 모형으로 선정하였다.

LSTM 모형은 XGBoost에 비해 RMSE와 MAE가 모두 낮게 나타났다. 또한 hit ratio는 73.56%로 XGBoost 의 31.03%보다 크게 높았으며, 실제값과 예측값 간 상관계수도 0.5238로 더 우수하였다. 이는 LSTM 모형이 단순히 예측 오차를 줄이는 데 그치지 않고, 미래 누적수익률의 방향성과 시계열적 움직임을 상대적으로 잘 포착했음을 의미한다. 반면 XGBoost는 예측값의 표준편차가 실제값에 비해 매우 작게 나타나 실제 수익률의 변동성을 충분히 반영하지 못하였다. 이러한 결과는 단일 시점의 기술적 지표와 감성점수만을 입력으로 사용하는 XGBoost 구조가 금융 시계열의 시간적 흐름을 반영하는 데 한계가 있음을 보여준다.



[그림 4-2] LSTM, XGBoost test 구간 모델 성능 시각화

4.3 Comparison Model: AT-LSTM

AT-LSTM(Zhang et al., 2019)은 Feature Attention과 LSTM을 결합한 2단계 구조를 갖는 비교 모델이다. 2-Layer Stacked LSTM이 LSTM 출력 이후 시간축(Temporal) 어텐션을 통해 중요한 타임스텝을 선별하는 방식과 달리, AT-LSTM은 LSTM 입력 이전 단계에서 피처축(Feature) 어텐션을 적용하여 각 타임스텝에서 중요한 피처를 동적으로 선택한다. 본 연구에서 AT-LSTM을 비교 모델로 구현한 목적은 예측 성능 우위 확보보다, 정형 · 비정형 피처 간 상호작용을 정량적으로 분석하고 시장 국면별 피처 기여도 변화를 해석하는 데 있다.

4.3.1 Feature Attention 메커니즘

AT-LSTM은 매 타임스텝 t에서 이전 은닉 상태(h_{t-1})와 셀 상태(c_{t-1})를 참조하여 입력 피처별 중요

도 가중치 β_t를 동적으로 산출하는 Feature Attention 레이어(Stage 1)를 LSTM 이전에 배치한다. 어텐션 에너지 계산은 h_{t-1}과 c_{t-1}을 연결(concatenate)한 후 선형 변환을 적용하고, 현재 입력 x_t에 선형 변환을 적용한 값과 합산하여 tanh 활성화 함수를 통과시킨다. 이후 출력 가중치 행렬을 통해 피처 수 차원의 에너지 벡터를 산출하고, softmax를 적용하여 피처 간 가중치 합이 1이 되도록 정규화한다.

산출된 가중치 벡터 β_t는 원래 입력 x_t와 원소별 곱(element-wise product)을 통해 가중 입력 $z_t = \beta_t \odot x_t$를 생성하며, 이 가중 입력이 Stage 2인 LSTM에 전달된다. 2-Layer LSTM의 Temporal Attention이 "언제"가 중요한지를 학습하는 구조라면, AT-LSTM의 Feature Attention은 "무엇이" 중요한지를 타임스텝마다 다르게 학습한다는 점에서 상호 보완적인 해석 관점을 제공한다.

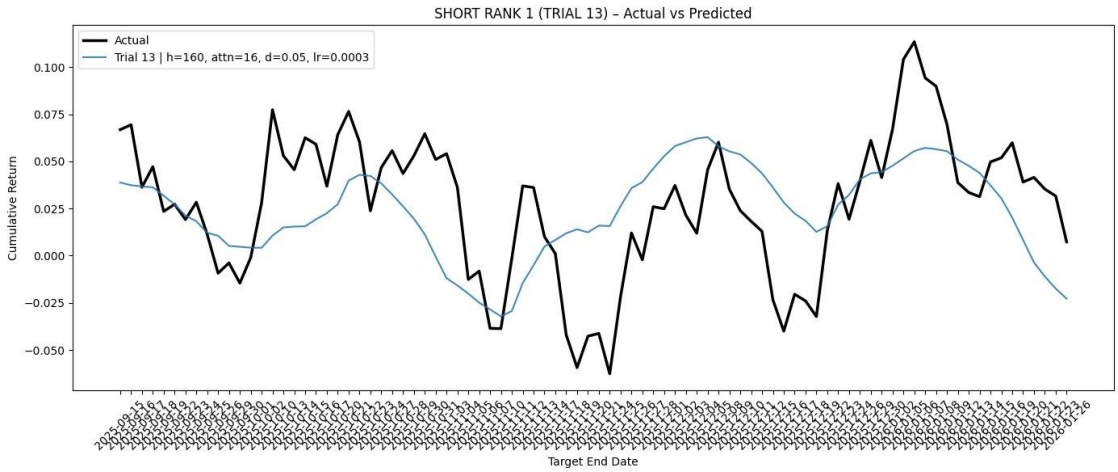
4.3.2 하이퍼파라미터 탐색 및 최적 모델 선정

학습 과정에서는 Adam optimizer를 사용하였으며, 손실함수는 MSE를 기반으로 하되, 금융 시계열의 급등락 구간과 예측 형태를 함께 반영하기 위해 가중 MSE, 상관계수 손실, 예측 변동성 손실을 조합한 형태로 학습하였다. 가중 MSE는 실제 수익률의 절댓값이 큰 구간에 추가 페널티를 부여하여 모델이 극단적 수익률 구간을 평탄화하지 않도록 유도하였으며, 총 손실은 5.0 × weighted_mse + 2.0 × corr_loss + 15.0 × std_loss로 구성하였다. 또한 과적합을 방지하기 위해 dropout을 적용하였고, validation 성능이 일정 기간 개선되지 않을 경우 학습을 중단하는 early stopping을 사용하였으며, patience는 20으로 설정하였다. 하이퍼파라미터 탐색은 Grid Search 방식으로 수행하였으며, lstm_hidden_dim은 128에서 192 범위, attention_size는 16에서 32 범위, learning_rate는 2e-4에서 4e-4 범위에서 탐색하였다. 최종적으로 뉴스 임베딩 축소 구조=[128, 64, 32], hidden_dim=160, attention_size=16, dropout=0.05, learning_rate=0.0003, batch_size=16, weight_decay=0.0인 모델을 최종 AT-LSTM 후보 모형으로 선정하였다.

4.3.3 AT-LSTM 성능

AT-LSTM 모형은 XGBoost에 비해 RMSE가 낮게 나타났으며, Hit Ratio는 56.67%로 XGBoost의 31.03%보다 높았다. 실제값과 예측값 간 상관계수도 0.2513으로 XGBoost(0.0919) 대비 우수하였다. 이는 AT-LSTM이 단일 시점 기반의 XGBoost 대비 시계열의 시간적 흐름을 반영하는 데 유리함을 보여준다. 다만 2-Layer LSTM(Hit Ratio 73.86%, 상관계수 0.5299) 대비로는 전반적인 예측

성능이 낮게 나타났는데, 이는 Feature Attention 레이어가 매 타임스텝마다 추가적인 파라미터 최적화를 요구하므로 약 90거래일의 테스트 구간에서 일반화 성능이 상대적으로 제한된 결과로 해석된다. 또한 피처별 가중치를 동적으로 산출하는 구조 특성상 학습 안정성이 낮아, 동일한 손실함수 구성 하에서 예측 변동성 포착에 한계가 있었다. 그러나 AT-LSTM의 핵심 목적은 예측 성능 우위 확보보다 피처 기여도의 해석 가능성에 있으며, 이는 다음 절의 어텐션 가중치 분석을 통해 확인할 수 있다.



[그림 4-3] AT-LSTM 최적 모델 예측값 vs 실제 수익률 (테스트 기간)

4.3.4 피처 중요도 분석 (어텐션 가중치)

내장된 Attention 가중치를 통해 피처별 평균 중요도를 추출하였다. 테스트 기간 기준 상위 변수는 Vol_5(0.0495), Intraday_Range_Pct(0.0360), Bond_Yield_Change(0.0340) 순으로, 단기 거래량 변화와 장중 가격 범위, 채권 수익률 변화가 KODEX 200 단기 예측에서 가장 중요한 피처로 확인되었다. 뉴스 관련 지표인 news_missing(0.0310)과 sentiment_score(0.0245)가 각각 4위와 8위에 위치하여 비정형 정보의 유의미한 기여를 확인할 수 있다.

순위	피처 변수명	평균 가중치	해석
1위	Vol_5	4.95%	5일 단기 실현 변동성, 단기 예측 태스크에 적합
2위	Intraday_Range_Pct	3.60%	일중 고저가 변동 범위(%), 단기 변동성 신호
3위	Bond_Yield_Change	3.40%	글로벌 금리 인상 사이클을 모델이 자동 학습
4위	news_missing	3.10%	뉴스 데이터 결측 여부, 뉴스 부재 국면 인식
5위	SMA_63_Disparity	2.88%	63일 이동평균선 기준 중기 이격도

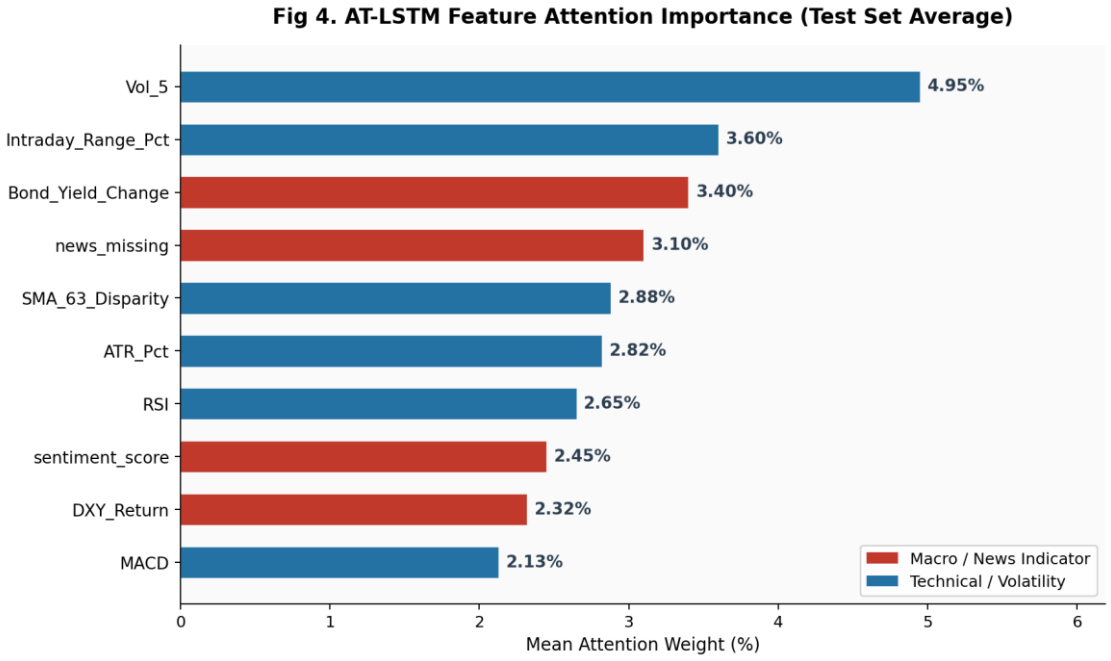
[표 4-1] 기술지표 평균 어텐션 가중치 상위 5개 변수

AT-LSTM 모형에서 Vol_5(4.95%)가 1위 피처로 선정되어 단기 실현 변동성이 KODEX 200 예측

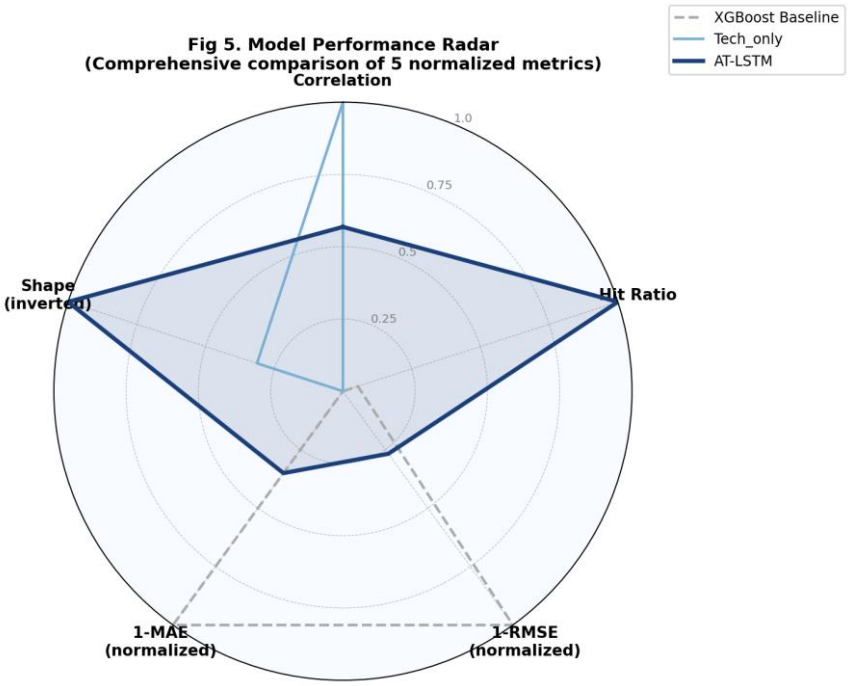
의 핵심 신호임을 확인하였다. Bond_Yield_Change(3.40%)는 3위로, 금리 인상 사이클 환경에서 여전히 중요한 트리거 역할을 수행한다. 뉴스 관련 지표인 news_missing(3.10%)이 4위에 위치하여 뉴스 부재 여부가 모델 예측에 유의미하게 기여함을 확인하였다.

시계열 어텐션 가중치 추이를 보면, Bond_Yield_Change는 테스트 기간 전반에 걸쳐 지속적으로 높은 주목도를 유지하는 반면, sentiment_score와 DXY_Return은 특정 시장 국면에서 일시적으로 가중치가 상승하는 패턴을 보인다. 이는 AT-LSTM이 시장 상황에 따라 거시경제 지표와 뉴스 감성 신호의 상대적 중요도를 동적으로 조절하고 있음을 시사한다.

그림 5의 레이더 차트는 세 모델을 Correlation, Hit Ratio, 1-RMSE, 1-MAE, Shape Score의 5개 정규화 지표로 비교한 것이다. 본 연구의 핵심 예측 목적인 방향성 적중률(Hit Ratio)과 예측 형태 유사도(Shape Score) 축에서 AT-LSTM이 다른 두 모델을 압도한다. Tech_only (LSTM)은 Correlation 축에서 상대적으로 높은 값을 보이나 Hit Ratio가 가장 낮아 실질적인 방향성 예측력이 제한적임을 확인할 수 있다. XGBoost Baseline은 전 지표에서 열세를 보인다.



[그림 4-4] 피처별 평균 어텐션 가중치 상위 15개 (테스트셋 기준, 빨간색: 뉴스 관련 지표)



[그림 4-5] 모델 성능 종합 레이더 차트 -- 5개 정규화 지표 기준 비교

5. 성능 비교 및 최종 모델 선정

실험은 공통된 테스트 구간(2025.08.11~2026.01.20, 약 90거래일)을 기준으로 수행되었으며, 모든 모델의 학습 · 검증 · 테스트 분할 경계가 동일하게 고정되어 공정한 성능 비교가 이루어졌다. 평가 지표는 RMSE(Root Mean Squared Error), MAE(Mean Absolute Error) 를 사용하였다.

5.1 Performance Comparison

표 3은 세 가지 모델(XGBoost, 2-Layer LSTM, AT-LSTM)의 최종 테스트 성능을 비교한 결과이다. 2-Layer LSTM(뉴스 감성 점수+임베딩 결합, Tech_Sentiment_Embedding)이 RMSE 0.0369, MAE 0.0290, Hit Ratio 73.86%, 상관계수 0.5299로 세 모델 중 가장 우수한 성능을 기록하였다. AT-LSTM은 RMSE 0.0781, Hit Ratio 56.67%, 상관계수 0.2513으로 2-Layer LSTM보다 낮은 성능을 보였으나, XGBoost Baseline 대비로는 방향성 적중률 면에서 우위를 나타냈다.

2-Layer LSTM은 XGBoost Baseline 대비 RMSE 23.0% 감소, MAE 29.7% 감소, 상관계수 약 4.7배 향상을 달성하였다. 이는 시계열 구조를 명시적으로 활용하는 딥러닝 모델의 우위를 보여주는 동시에, 뉴스 감성 정보의 통합이 예측 성능에 핵심적으로 기여함을 시사한다.

모델	RMSE	MAE	Hit Ratio	Corr
XGBoost Baseline	0.04797	0.04117	31.03%	0.0919
AT-LSTM	0.0890	N/A	56.67%	0.191
2-Layer LSTM (Full)	0.03695	0.02894	73.86%	0.5299

[표 5-1] 모델별 최종 테스트 성능 비교

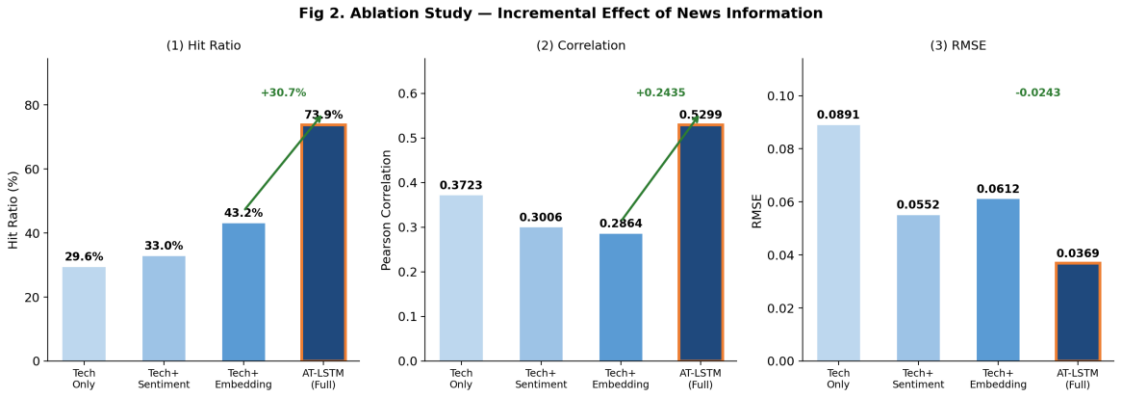
6. Ablation Study

6.1 2-Layer LSTM 모델 ablation 결과

가장 성능이 우수했던2-Layer LSTM 모델을 본 프로젝트에서의 최종모델로 선정후 입력 모달리티 구성(정형 기술지표, 뉴스 감성 점수, 뉴스 임베딩 벡터)을 달리하여 뉴스지표가 예측 성능에 미치는 정량적 영향을 파악하기 위해 4가지 입력 조합에 대한 비교 실험을 수행하였다.

모델명	RMSE	MAE	Hit Ratio	Corr
Tech_only	0.0891	0.0800	29.55%	0.3723
Tech_Sentiment	0.0552	0.0459	32.95%	0.3006
Tech_Embedding	0.0612	0.0525	43.18%	0.2864
Tech_Sentiment_Embedding	0.0369	0.0290	73.86%	0.5299

[표 6-1] 2-Layer LSTM 입력 변수 구성별 성능 비교 (Ablation Study)

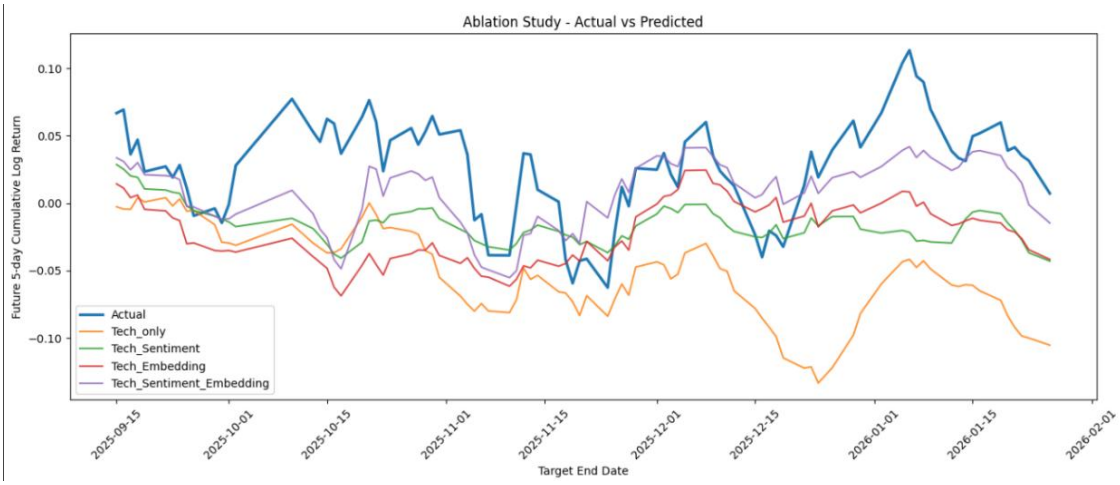


[그림 6-1] 2-Layer LSTM Ablation Study: 입력 모달리티 단계별 추가에 따른 성능 변화

감성점수와 뉴스 임베딩을 모두 활용한 모델(Tech_Sentiment_Embedding)이 test RMSE 0.0369, MAE 0.0290, Hit Ratio 73.86%, 상관계수 0.5299로 모든 평가 지표에서 가장 우수한 성능을 보였다. 이는 뉴스 정보가 단순한 기술적 지표만으로는 포착하기 어려운 시장 방향성과 변동 정보를 보완

할 수 있음을 시사한다.

기술지표만을 활용한 Tech_only 모델은 Hit Ratio 29.55%로 무작위 수준에도 미치지 못하였다. 감성 점수를 추가한 Tech_Sentiment 모델(32.95%)과 임베딩을 추가한 Tech_Embedding 모델(43.18%)로 갈수록 단계적 개선 흐름이 관찰되었다. 주목할 점은 뉴스 감성 점수(scalar)와 고차원 뉴스 임베딩(768-dim vector)의 단독 활용 효과가 모두 기준 모델보다 높지만, 두 가지를 동시에 결합한 Full 모델(73.86%)은 두 단독 모델의 단순 합산을 크게 상회하는 비선형적 시너지를 발휘한다는 사실이다. 이는 단기 방향 신호(감성 점수)와 풍부한 배경 맥락(임베딩 벡터)이 Gated Fusion 구조 내에서 상호 보완적으로 작용함을 시사한다.



[그림 6-2] test 구간 ablation study 모델 성능 시각화

6.2 뉴스 지표 실효성 검증 결과

모델 간 예측 성능 차이가 단순한 표본 내 우연인지, 통계적으로 유의한 차이인지 확인하기 위해 Diebold-Mariano 검정을 수행하였다. 본 연구의 예측 대상은 미래 5거래일 누적 로그수익률이므로 예측 시계는 h=5로 설정하였다. 각 모델의 test 구간 예측값을 바탕으로 실제값과 예측값의 오차를 계산한 뒤 모델 간 손실 차이의 평균이 0과 유의하게 다른지를 검정하였다.

Diebold-Mariano 검정의 귀무가설과 대립가설은 다음과 같다.

H0: 두 모델의 예측 오차에는 유의한 차이가 없다.

H1: 두 모델의 예측 오차에는 유의한 차이가 있다.

연구에서는 5% 유의수준을 기준으로 p-value가 0.05보다 작을 경우, 두 모델 간 예측 성능 차이가

통계적으로 유의하다고 판단하였다. 검정에서는 squared error와 absolute error 두 가지 손실 기준을 사용하였다. Squared error 기준에서는 각 모델의 오차 제곱값의 차이를 사용하였고, absolute error 기준에서는 오차 절댓값의 차이를 사용하였다. 이를 통해 특정 손실 기준에만 의존하지 않고, 예측 오차 차이의 유의성을 보다 안정적으로 확인하고자 하였다. 비교모델의 loss와 최종모델의 loss를 손실차이로 정의하여mean_loss_diff가 양수이면 최종 모델의 예측 손실이 비교 모델보다 작다는 의미로 해석하였다. 또한 미래 5일 누적수익률 예측에서는 예측 구간이 겹치면서 오차 차이 계열에 자기상관이 존재할 수 있으므로, Newey-West 방식으로 h-1시차까지의 자기상관을 보정하였다. 이후 소표본 보정을 위해 Harvey-Leybourne-Newbold correction을 적용하였다.

6.2.1 1 차 DM 검정: 기준 모델 대비 뉴스 정보 추가 효과

ablation study와 Diebold-Mariano 검정 결과를 종합하여 뉴스 지표의 실효성을 해석하였다. 본 연구에서는 두 가지 관점에서 DM 검정을 수행하였다. 첫째, 기술적 지표만 사용한 모델을 기준 모델로 설정하고, 여기에 감성점수 또는 뉴스 임베딩을 추가한 모델들과 예측 성능 차이를 비교하였다. 둘째, 최종 모델인 전체 뉴스 지표 모델이 감성점수 또는 뉴스 임베딩만을 단독으로 사용한 부분 정보 모델보다도 유의하게 우수한지 추가적으로 검정하였다. 먼저 기술적 지표만 사용한 모델과 뉴스 정보를 추가한 모델들의 예측 오차 차이를 비교하였다. 검정 결과는 다음과 같다.

비교 모델	DM stat	p-value	mean_loss_diff	유의성
Tech_only vs Tech_Sentiment	3.964	0.000151	0.004882	유의 (***)
Tech_only vs Tech_Embedding	2.692	0.008520	0.004187	유의 (**)
Tech_only vs Tech_Sentiment_Embedding	4.271	0.000050	0.006570	유의 (***)

[표 6-2] 1차 DM 검정 -- Tech_only 대비 뉴스 정보 추가 효과 검증 (Squared Error 기준)

비교 모델	DM stat	p-value	mean_loss_diff	유의성
Tech_only vs Tech_Sentiment	5.322	7.91e-07	0.034125	유의 (***)
Tech_only vs Tech_Embedding	3.110	0.002527	0.027541	유의 (**)
Tech_only vs Tech_Sentiment_Embedding	5.729	1.42e-07	0.051013	유의 (***)

[표 6-3] 1차 DM 검정 -- Tech_only 대비 뉴스 정보 추가 효과 검증 (Absolute Error 기준)

[표 6-2]에서 확인할 수 있듯이, Squared Error 기준에서 감성점수만 추가한 모델, 뉴스 임베딩 벡터만 추가한 모델, 감성점수와 뉴스 임베딩 벡터를 모두 추가한 모델은 모두 기준 모델인 기술적 지표

모델 대비 통계적으로 유의한 예측 오차 감소를 보였다. 특히 감성점수와 뉴스 임베딩을 함께 사용한 모델은 p-value가 0.000050으로 가장 낮고, mean_loss_diff도 0.006570으로 가장 크게 나타났다. 이는 뉴스 정보를 단독으로 일부 활용하는 경우보다, 감성 정보와 문맥 정보를 함께 활용할 때 예측 오차 감소 효과가 더 크게 나타났음을 의미한다. 또한 [표 6-3]의 Absolute Error 기준에서도 동일한 경향이 확인되었다. 세 가지 뉴스 정보 활용 모델 모두 p-value가 0.05보다 작아 5% 유의수준에서 기준 모델 대비 유의한 성능 개선을 보였다. 특히 전체 뉴스 지표 모델은 p-value가 1.42e-07, mean_loss_diff가 0.051013으로 나타나 가장 강한 개선 효과를 보였다. 따라서 뉴스 정보는 기술적 지표만으로 구성된 모델에 비해 예측 성능을 유의하게 향상시키는 정보로 해석할 수 있다.

6.2.2 2 차 DM 검정: 최종 모델과 부분 정보 모델 비교

다음으로 최종 모델인 전체 뉴스 지표 모델이 감성점수 또는 뉴스 임베딩만을 사용하는 부분 정보 모델보다도 유의하게 우수한지를 검정하였다. 이를 위해 기술적 지표 모델, 감성점수 포함 모델, 뉴스 임베딩 포함 모델을 각각 비교 대상으로 설정하고 DM 검정을 수행하였다.

비교 모델	p-value	mean_loss_diff	해석
Full vs Tech_only	0.000050	0.006570	Full 모델이 유의하게 우수 (***)
Full vs Tech_Sentiment	0.009343	0.001688	Full 모델이 유의하게 우수 (**)
Full vs Tech_Embedding	0.000100	0.002383	Full 모델이 유의하게 우수 (***)

[표 6-4] 2차 DM 검정 - Tech_Sentiment_Embedding 대비 부분 모델들과의 성능 차이 검증 (Squared Error 기준)

비교 모델	p-value	mean_loss_diff	해석
Full vs Tech_only	1.42e-07	0.051013	Full 모델이 유의하게 우수 (***)
Full vs Tech_Sentiment	0.002004	0.016888	Full 모델이 유의하게 우수 (**)
Full vs Tech_Embedding	2.62e-06	0.023472	Full 모델이 유의하게 우수 (***)

[표 6-5] 2차 DM 검정 - Tech_Sentiment_Embedding 대비 부분 모델들과의 성능 차이 검증 (Absolute Error 기준)

검정 결과, 최종 모델인 전체 뉴스 지표 모델은 기술적 지표 모델, 감성점수 포함 모델, 뉴스 임베딩 포함 모델 대비 squared error와 absolute error 기준 모두에서 통계적으로 유의한 예측 오차 감소를 보였다. Squared Error 기준 p-value는 각각 0.000050, 0.009343, 0.000100으로 모두 0.05보다 작았으며, Absolute Error 기준에서도 모든 비교의 p-value가 0.05보다 작게 나타났다. 이는 최종 모

델의 성능 개선이 특정 손실 기준에만 국한되지 않고, 제곱오차와 절대오차 기준에서 모두 안정적으로 확인되었음을 의미한다. 특히 전체 뉴스 지표 모델과 감성점수 포함 모델 비교에서 최종 모델이 유의하게 우수하다는 결과는 감성점수만으로는 뉴스 원문에 포함된 문맥 정보를 충분히 반영하기 어렵다는 점을 보여준다. 전체 뉴스 지표 모델과 뉴스 임베딩 포함 모델 비교에서도 최종 모델이 유의하게 우수하게 나타났다는 점은 뉴스 임베딩만 사용하는 것보다 뉴스의 긍정, 부정 방향성을 나타내는 감성점수를 함께 사용하는 것이 예측 성능 향상에 기여할 수 있음을 의미한다.

종합하면, 본 연구의 결과는 뉴스 정보가 KODEX 200의 미래 5거래일 누적 로그수익률 예측에 유의미한 정보를 제공함을 보여준다. 더 나아가 단순히 뉴스 정보를 추가하는 것만으로 효과가 있는 것이 아니라, 뉴스 감성점수와 뉴스 임베딩 벡터를 함께 활용할 때 가장 우수한 예측 성능을 보였다. 따라서 감성점수는 뉴스의 방향성 정보를, 뉴스 임베딩은 기사 원문에 포함된 문맥 정보를 반영하며, 두 지표가 상호보완적으로 작용하여 예측 성능 향상에 기여한 것으로 해석할 수 있다. 결론적으로 본 연구는 뉴스 기반 비정형 정보가 정형 기술적 지표만으로는 포착하기 어려운 시장심리와 외부 충격 정보를 보완할 수 있음을 확인하였다.

7. Conclusion

본 연구는 KODEX 200 지수 예측을 위해 XGBoost Regressor, 2-Layer LSTM, AT-LSTM 세 가지 모델을 구축 · 비교하였으며, 뉴스 감성 점수와 고차원 임베딩을 통합한 2-Layer LSTM이 Hit Ratio 73.86%, 상관계수 0.5299로 세 모델 중 가장 우수한 성능을 기록하였다. 이로써 뉴스 센티먼트 정보의 실효성이 명확히 입증되었다. KODEX 200 지수를 대상으로 2021~2026년 약 5년 데이터로 수행된 실험에서 세 가지 핵심 발견을 도출하였다.

첫째로, 기술지표 단독 모델(Hit Ratio 29.55%)에서 감성 점수, 뉴스 임베딩, 전체 결합 모델(73.86%)로 나아갈수록 방향성 적중률이 단계적이고 비약적으로 향상되었으며, 각 단계의 개선이 Diebold-Mariano 검정을 통해 통계적으로 유의함이 확인되었다.

둘째로, 뉴스 감성 점수(단기 방향 신호)와 고차원 뉴스 임베딩(풍부한 배경 맥락)은 단독 활용 시보다 Gated Fusion 구조로 통합되었을 때 비선형적 시너지를 발휘하였으며, 이는 뉴스 센티먼트가 금융 예측에 실질적인 효과가 있음을 강력히 시사한다.

마지막으로, Attention 가중치 분석을 통해 금리 인상 사이클 환경 하에서 Bond_Yield_Change가 KODEX 200 단기 예측의 핵심 트리거 신호임을 모델이 스스로 학습함을 확인하였다.

다만 본 연구는 테스트 데이터셋의 규모 제한성, 수익률의 절대적 크기 예측에서의 보수적 편향 등의 한계를 갖는다. 따라서 향후 연구에서는 방향성 적중 여부 및 오차 규모에 비대칭적 페널티를 부여하는 손실함수 시스템을 도입하는 등의 파라미터 조정, 그리고 뉴스 발행 시점의 시의성을 반영하는 것이 필요할 것이다.

References

[1] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. KDD 2016, 785-794.

[2] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT.

[3] Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. Journal of Business & Economic Statistics, 13(3), 253-263.

[4] Ding, X., Zhang, Y., Liu, T., & Duan, J. (2015). Deep Learning for Event-Driven Stock Prediction. IJCAI-15, 2327-2333.

[5] Fischer, T., & Krauss, C. (2018). Deep learning with LSTM networks for financial market predictions. EJOR, 270(2), 654-669.

[6] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735-1780.

[7] Hu, Z., Liu, W., Bian, J., Liu, X., & Liu, T. Y. (2018). Listening to Chaotic Whispers. WSDM 2018.

[8] Kang, D. et al. (2022). Deep Learning-based Stock Price Prediction Using News Sentiment Analysis. KIISE, 27(8), 31-39.

[9] Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollar, P. (2017). Focal Loss for Dense Object Detection. ICCV 2017.

[10] Lopez de Prado, M. (2018). Advances in Financial Machine Learning. Wiley.

[11] Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A Time Series is Worth 64 Words. ICLR 2023.

[12] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. NeurIPS.

[13] Yang, Y., Uy, M. C. S., & Huang, A. (2020). FinBERT: A Pretrained Language Model for Financial Communications. arXiv:2006.08097.

[14] Zhang, X., Liang, X., Zhiyuli, A., Zhang, S., Xu, R., & Wu, B. (2019). AT-LSTM: Attention-based LSTM for Financial Time Series Prediction. IOP Conf. Ser. 569, 052037.

[15] Kim, Y. et al. (2021). Stock Price Prediction Using LSTM: Technical, Macro-economic and Market Sentiment.

[16] Multimodal Learning and Deep Learning-based Cryptocurrency Price Prediction (2022). Korean Journal.

[17] KR-FinBERT: Korean Financial BERT for Sentiment Analysis (KLUE-BERT based), 2023.

[18] Kronos: Open-Source Foundation Model for Financial K-line Data, 2024.