매크로팀 중간 발표

멀티모달 데이터를 활용한 KODEX 200
수익률 예측

매크로팀
이찬영 · 구다연 · 이예현 · 이지수

HUFS DAT 7th

연구 배경

비선형 변동성 설명 한계

가격 데이터만으로는 시장의 비선형적 변동성과 예측 불가능성을 설명하는 데 명확한 한계 존재.
단순한 가격 시계열 분석으로는 시장의 복잡한 패턴을 포착하기 어렵다.

한국 시장의 대외 의존도와 뉴스 민감도

한국 시장은 대외 의존도가 높아 거시경제 지표뿐만 아니라 뉴스에 내재된 투자 심리와 외부 충격에 매우 민감하게 반응한다. (특히 미국 금리, 환율 변동, 지정학적 리스크 등에 취약)

멀티모달 접근의 필요성

비정형 데이터(뉴스)와 정형 데이터(거시경제 지표)의 융합이 시장 예측력을 유의미하게 향상시킨다는 선행연구를 바탕으로, 한국 시장에 특화된 뉴스 임베딩과 시계열 모델을 결합한 예측 분석이 필요하다.

연구 목적 정의

1. 뉴스 데이터의 추가적 유효성 검증

기술적 지표만을 학습한 Baseline 모델과 뉴스 임베딩을 추가한 Proposed 모델의 성과와 SHAP분석을 통한 변수중요도 해석

2. 모델 아키텍처별 시계열 예측 성능 비교

순환 신경망 기반의 LSTM과 transformer 구조인 PatchTST 모델 간 예측 성능 차이를 Diebold-Mariano 검정 통해 통계적 유의성을 확보하며 검증

3. 실전 투자 성과 및 안정성 평가

백테스팅을 통해 누적 수익률, 리스크 대비 수익률을 나타내는 Sharpe Ratio, MDD 등의 지표를 산출함으로써 통계적 · 경제적 유의성을 동시에 확보한 최적의 모델을 판별

데이터셋 구성 : 2021.03.10. ~ 2026.03.10. (5개년)

예측 환경 설정

Target
KODEX 200 의 누적 로그수익률

Inputs
일별 기술적 지표 + 금융 뉴스 텍스트 데이터 결합

look-back window
단기 모델: 입력 값 20일 → 예측 값 5일
장기 모델: 입력 값 120일 → 예측 값 20일

Preprocessing
날짜 기준 데이터 정렬, 결측치 보간, Standard 스케일링을 통한 표준화 수행

데이터 소스

금융 뉴스 (Unstructured)

~18,520 Articles

빅카인즈를 활용하여 'kodex' 키워드로 추출한 국내 주요 4 개 방송사(MBC, SBS, KBS, YTN)의 뉴스만을 선별하여 수집

기술적 지표 (Structured)

~14 Indicators

FRED api를 이용해 수집한 거시경제 지표와 타겟종목의 가격데이터로 구성

피쳐 엔지니어링 : 단순히 수치를 넣는 대신 변화율이나 상대적 위치를 계산하여 피쳐 계산

분류	지표명	산출 방식 및 설명
수익률 및 변동성	Log_Return	종가의 로그 수익률
	Return_Lag1	1일 전의 수익률
	Vol_5, Vol_21	5일(1주) 및 21일(1개월) 간 수익률 표준편차
	RV_Trend_5_21	단기 변동성(Vol_5)/장기 변동성 (Vol_21)
추세 및 모멘텀	SMA_21/63_Disparity	현재가와 이동평균선(21일, 63일) 간 이격도
	MACD	단기 및 장기 지수이동평균(EMA)의 차이
	Momentum_10D	10일 전 가격 대비 현재가의 변화율
	RSI	일정 기간의 상승폭과 하락폭 비율 (0~100)
리스크 및 외부 충격	ATR_Pct	평균실제범위(ATR) / 당일 종가
	VIX_Change	공포지수(VIX)의 전일 대비 변화율
	DXY_Return	달러인덱스(DXY)의 전일 대비 변화율
	Bond_Yield_Change	국채 금리의 전일 대비 변화량(Diff)

뉴스 임베딩

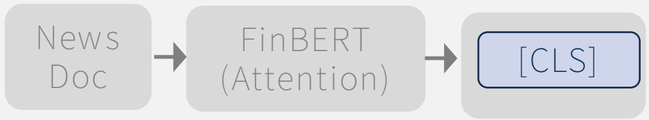
금융 뉴스 처리

A. 뉴스 데이터의 시계열 정합성 및 보정

한국 거래소의 장 마감 시간인 15:30 이후에 발생한 뉴스는 익일 영업일의 데이터로 할당하여 데이터 누수를 방지

금요일 15:30 이후부터 월요일 09:00 이전까지 발생한 모든 뉴스 데이터는 월요일 데이터로 통합하여 처리

기술적 지표 처리



B. KR-FinBERT 임베딩

뉴스 제목과 본문을 결합하여 문맥 정보를 보존한 각 기사를 사전 학습된 FinBERT에서 문장 전체의 문맥 정보를 768 차원의 고차원 벡터로 응축

L2 norm 기반 가중 pooling

D. 일별 단위의 뉴스 정보를 표현

각 뉴스 임베딩의 L2 norm을 기반으로 각 기사의 세기를 계산한 뒤, softmax를 통해 가중치를 부여하여 가중 평균을 수행함으로써, 시장에 더 큰 영향을 미치는 뉴스에 집중하도록 설계

단순 평균은 중요한 뉴스의 영향력을 희석시키고, 최대값 방식은 노이즈에 민감하다는 한계가 있기 때문에, 본 연구에서는 뉴스 임베딩의 크기를 기반으로 중요도를 반영하는 L2 norm-based weighting 방법을 사용

베이스라인 - XGBoost

모델 선정 이유:

비선형성과 변수 간 상호작용을 효과적으로 포착하여 기술적 지표와 거시경제 변수로 구성된 tabular 형태의 금융 데이터에서 안정적인 baseline 모델

	MAE	Sign accuracy	최적 하이퍼파라미터
단기모델	0.0389	48.30%	depth: 5, lr: 0.05 n: 50
장기모델	0.0866	75.00%	depth: 3, lr: 0.05 n: 50

1. 뉴스지표의 필요성

단기 예측 성능이 낮은 것은 기술적 지표만으로는 단기 시장 변동을 설명하기 어렵다는 점을 시사하며 뉴스와 같은 외생 변수의 도입이 필요함을 보여준다.

2. 시계열 모델 필요성

현재 모델은 시계열 구조를 직접 반영하지 못하기 때문에, LSTM과 같은 순차 모델을 통해 시간적 의존성을 학습할 필요가 있다.

LSTM 모델 프레임 워크

뉴스 벡터 차원 축소

뉴스 임베딩은 fully connected layer를 통해 차원 축소 및 특징 추출을 수행

시계열 패턴 학습

기술적 지표와 결합되어 2-stacked LSTM의 입력으로 사용

출력층

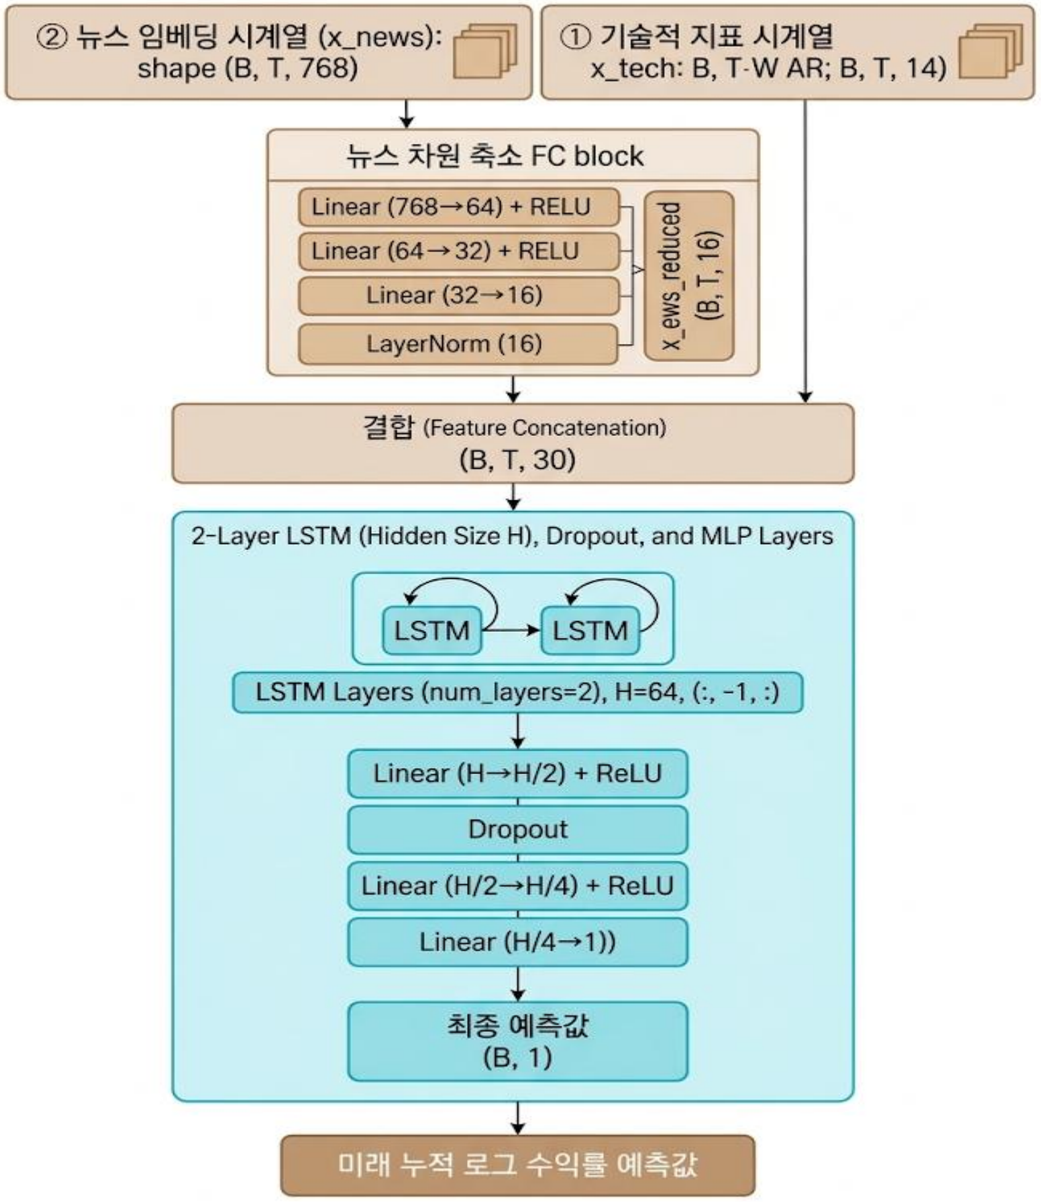
LSTM에서 생성된 최종 hidden state는 MLP에 입력되어 최종 예측값을 생성

학습 대상 파라미터

FC layer, LSTM, MLP 는 backpropagation을 거치며 학습되지만

768차원으로 임베딩된 뉴스임베딩 자체는 freeze

→ 개별 모델의 편향을 줄이고 안정성과 일반화 성능을 향상시키기 위해 서로 다른 하이퍼파라미터 설정을 가진 복수의 LSTM 모델을 결합하는 앙상블 구조로의 확장가능성



B: 배치 (Batch), **T:** 타임스텝 (Time Steps), **H:** 히든 차원 (Hidden Dim, H=64)

앞으로의 방향

1️⃣ LSTM 모델 구축 후 베이스라인과의 성능 차이와 SHAP 분석을 통한 뉴스 지표의 실효성 확인

2️⃣ Patch TST 모델 구축을 통해 transformer 계열 시계열 처리에서의 성능차이를 Diebold-Mariano(DM) 검정을 통해 통계적 유의성을 확보

3️⃣ 백테스팅을 통한 실제 투자 성과 차이 비교로 통계적으로 예측이 잘 맞는 모델이 아닌 실제로도 더 유용한 모델인지 평가