# DAT 7th Capstone

# AdTrace AI

## 저관여 제품에서 생성형 AI 광고의 리스크와 ROI 임계점 기반 기업 의사결정 시스템 연구

기업 의사결정을 위한
AI-like risk × ROI simulator

DAT 7기 AIM
조하연 · 지우진 · 최서린 · 최은서

# 데이터 채택: Criteo 데이터는 사용자 여정과 전환 행동을 함께 분석할 수 있다

최종 채택 데이터: Criteo Attribution Dataset

**약 800,000행**

원본 광고 접촉 로그

- 광고 노출 → 클릭 → 전환 흐름 복원
- User Journey 생성 가능
- 행동 기반 전환확률 모델링
- ROI 시뮬레이션 로그 확보

**KEY TAKEAWAY** Criteo 데이터는 사용자 여정과 전환 행동을 함께 분석할 수 있어 본 연구에 적합하다.

# 데이터 전처리: 전환 이후 행동을 제거해 실제 집행 전 의사결정 상황을 재현했다

데이터 전처리 파이프라인

약 800,000행 ▸ 전환 사용자 추출 ▸ 전환 이후 행동 제거 ▸ 전환 이전 행동 유지 ▸ User Journey 생성

**39,263 행**

최종 User Journey

데이터 누수 방지: 전환 이후 행동은 모델 입력에서 제외

**KEY TAKEAWAY** 전환 이전 행동만 사용하여 데이터 누수를 방지하였다.

# 저관여 분류: 저관여는 상품 카테고리가 아니라 빠른 행동 패턴으로 정의했다

관여도 점수 하위 30% 기반 집단 추출

- clicks_before_conversion
- decision_time
- journey_length
- impressions_before_first_click
- avg_time_between_clicks

**관여도 점수 계산 → 하위 30% 추출**

**9,755행**

저관여 행동 집단

**KEY TAKEAWAY** 본 연구의 저관여는 상품 카테고리가 아니라 행동 패턴 기반으로 정의하였다.

# Snapshot: 초기 5회 광고 접촉만으로 구매 가능성을 추정했다다

Snapshot 모델링으로 사전 의사결정 시점의 propensity를 생성

초기 5회 터치 ▸ Snapshot 표본 ▸ 양성 전환 ▸ 희귀 이벤트 구조

**4,926명**
Snapshot 표본

**37건**
양성 전환

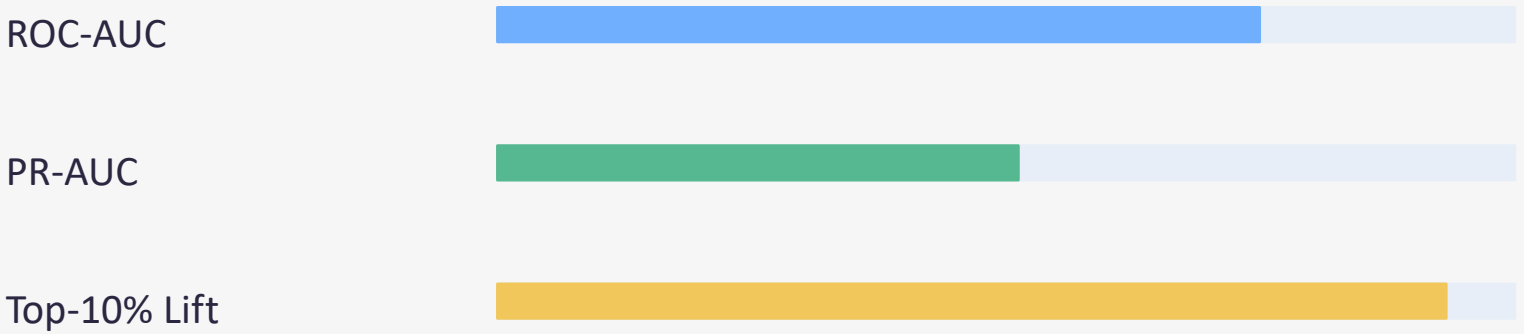
**0.75%**
양성률

정확도보다 ROC-AUC, PR-AUC, Top-k Lift 중심 평가가 필요한 구조

**KEY TAKEAWAY** 희귀 전환 구조에서 초기 행동 기반 전환 가능성을 추정하였다.

# 모델 선정: Logistic Regression은 ROI 파이프라인에 필요한 ranking 안정성을 확보했다

최종 전환확률 모델 성능




최종 모델

**Logistic Regression**

해석 가능성과 일반화 안정성을 함께 고려

**3.73**
Top-10% Lift

**약 3.2배**
랜덤 기준선 대비 PR-AUC

**Ranking 안정성**
핵심 목표

**KEY TAKEAWAY** 전환확률 모델은 ROI 분석에 필요한 사용자별 propensity 정보를 제공한다.

# Benchmark 보정: 모델 확률을 실제 시장 수준의 ROI 계산으로 연결했다

산업군 CVR, AOV를 결합해 기대 전환수와 기대 매출 산출

**내부 propensity**
사용자 ranking 정보

→

**산업군 CVR**
Food & Beverage / Base

→

**AOV 결합**
객단가 기반 매출화

→

**기대 매출 R**
ROI 입력값

| 20.31 | 14.72 | 2,353만원 | 863만원 | 486만원 |
|---|---|---|---|---|
| LR ROI 평균 | LR ROI 중앙값 | Top20% 평균 매출 | Middle60% | Bottom20% |

**KEY TAKEAWAY** Benchmark 보정은 모델 확률을 실제 시장 수준의 ROI 계산과 연결한다.

# 민감도 분석: AI ROI가 고정값이 아니라 조건부 결과임을 보여준다

H, r, p 3변수를 조합해 756개 ROI 시나리오 계산

**H**
Human 제작비
20만~150만원

**r**
AI 제작비 비율
3%~50%

**p**
AI 성과 패널티
0%~40%

**H**
Human 제작비
→
**r**
AI 제작비 비율
→
**p**
AI 성과 패널티
→
**ROI 재계산**
Human vs AI
→
**Breakeven**
AI 우위 조건

| 756개 | 14×6×9 | 200만원 | 4.0 |
|---|---|---|---|
| 총 조합 | 조합 구조 | 기준 광고비 A | λ 기준값 |

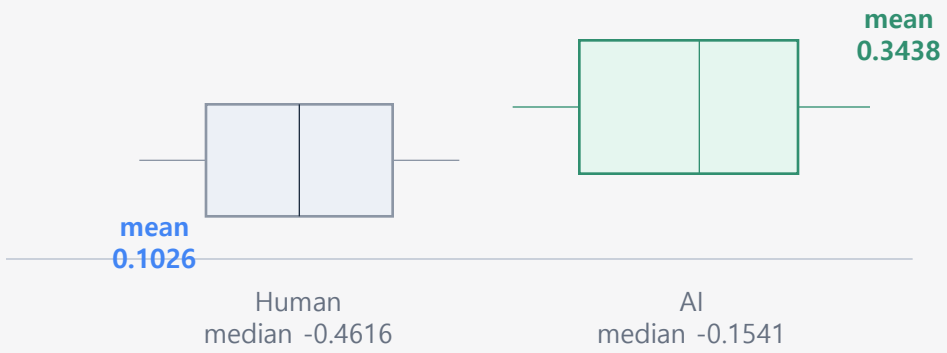
**KEY TAKEAWAY** AI ROI는 제작비, AI 비용 비율, 성과 패널티에 따라 달라진다.

# 동일 캠페인 기준 AI 광고 ROI 우위가 통계적으로 유의했다

Human vs AI ROI 비교

| 0.1026 | 0.3438 | +0.2412 | 91.4% |
|---|---|---|---|
| Human 평균 ROI | AI 평균 ROI | 평균 ROI 차이 | AI 우위 캠페인 |

## Human ROI vs AI ROI 분포 비교




| 지표 | Human | AI |
|---|---|---|
| 집계 ROI | 0.7583 | 0.9763 |
| ROI 중앙값 | -0.4616 | -0.1541 |

**KEY TAKEAWAY** 동일 캠페인 기준 AI 광고의 ROI 우위가 통계적으로 유의하게 나타났다.

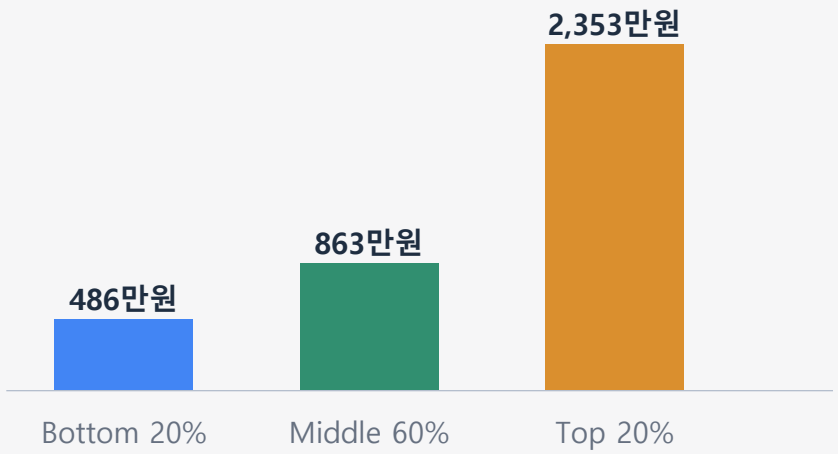
# Benchmark를 결합하면 고객 세그먼트별 ROI 차이를 해석할 수 있다

Food & Beverage 기준 Benchmark-adjusted ROI

Predicted Probability ↓ Industry Benchmark CVR ↓ Industry AOV ↓ Expected Revenue ↓ **ROI**

**20.31**
**평균 ROI**
Food & Beverage Base

**14.72**
**중앙값 ROI**
Food & Beverage Base

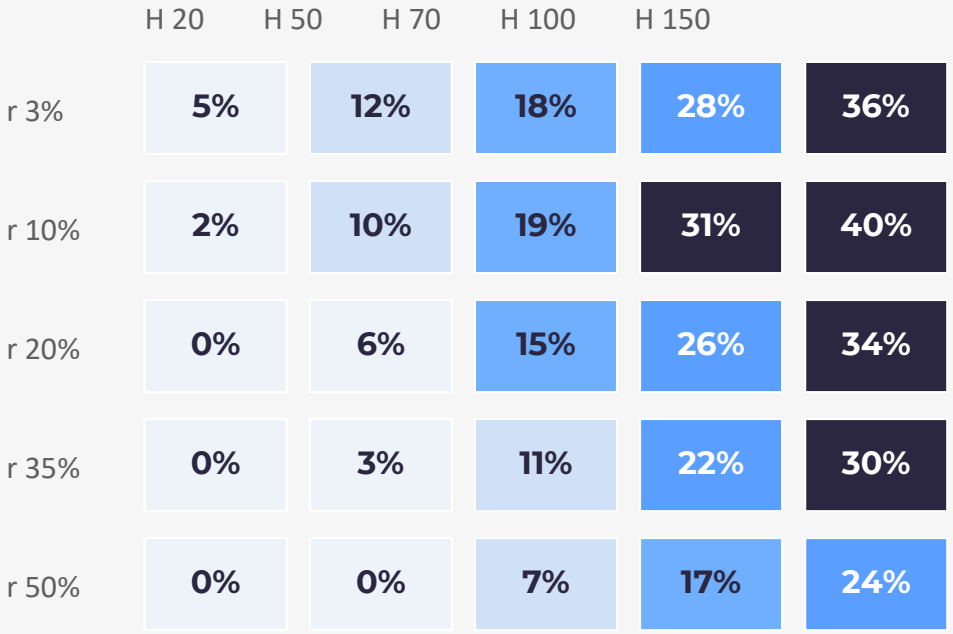



**Top 20% 고가치 세그먼트는 기대 매출이 커서 AI 패널티의 손실 규모도 함께 커진다**

**KEY TAKEAWAY** 전환확률과 산업군 Benchmark를 결합하면 고객 세그먼트별 ROI 차이를 해석할 수 있다.

# AI 광고는 성과 패널티가 일정 수준 이하일 때 ROI 우위를 확보한다

3변수 민감도 분석과 breakeven_p




p=0% 100%

p=10% 89.3%

p=20% 57.1%

p=30% 25.0%

p=40% 2.4%

**22.2%**

breakeven_p 중앙값

**19.1%**

기준 패널티

기준 패널티가 breakeven 중앙값보다 낮아 일반 이상 조건에서 AI ROI 우위 가능

**KEY TAKEAWAY** AI 광고는 성과 패널티가 일정 수준 이하라면 ROI 우위를 확보할 수 있다.

# AdTrace AI: 이미지의 AI-like 리스크를 ROI 변수로 변환한다

CNN 기반 의사결정 시스템 원리

**광고 업로드**
JPG · PNG · WebP

→

**EfficientNet-B0**
AI-like probability

→

**Risk Scoring**
0~100 리스크 점수

→

**Trust Penalty**
p_dynamic 생성

→

**ROI Simulator**
집행 의사결정

**124장**
AI 광고 학습 이미지

**115장**
Human 광고 학습 이미지

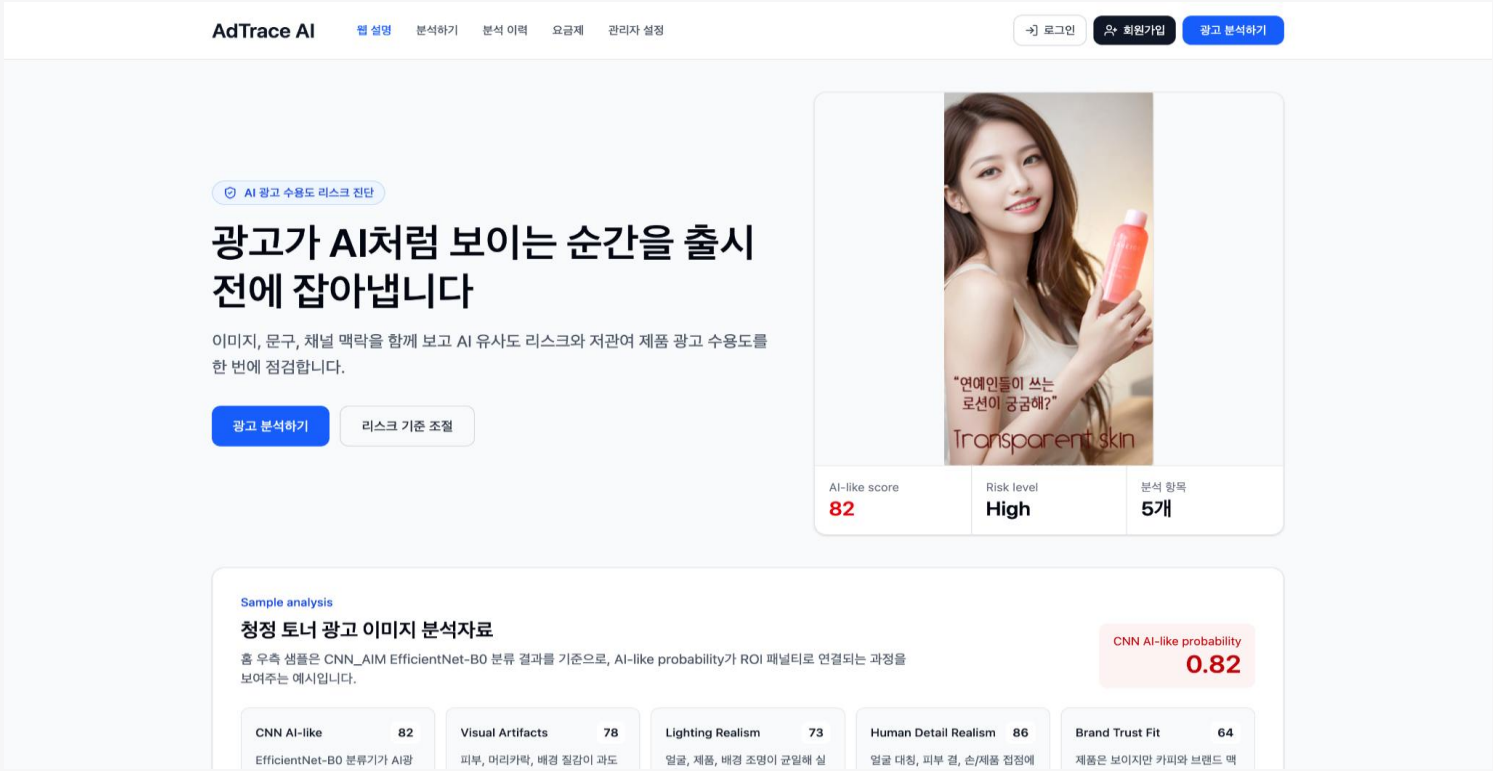
**239장**
총 reference dataset

**Risk + ROI**
최종 출력

**AI처럼 보이는 정도를 소비자 신뢰 하락과 ROI 감소 가능성으로 번역**

**KEY TAKEAWAY** AdTrace AI는 이미지의 AI-like 리스크를 ROI 변수로 변환한다.

# 시스템은 CNN 결과를 기업의 의사결정 대시보드로 확장했다




**82**
예시 AI-like score

**High**
Risk level

**0.82**
CNN probability

**5개**
분석 항목

**KEY TAKEAWAY** 분석 결과를 실제 기업의 의사결정 대시보드로 확장하였다.

https://adtrace-ai.vercel.app/

# 설문조사 시행:소비자는 Human 광고를 더 선호했지만 AI 광고 수용 가능성도 확인됐다

414명 설문조사 결과

**414명**
응답자

**2,070건**
총 선택 데이터

광고 선택 비중




**235명**
Human 선호 응답자

**179명**
AI 선호 응답자

**KEY TAKEAWAY** 소비자 선호는 Human 광고가 높지만 AI 광고 수용 가능성도 확인되었다.

# 연구를 마치며: AI 광고의 핵심은 생성 여부가 아니라 경제적 타당성이다

연구 의의, 한계 및 향후 과제

## 연구 의의

- AI 광고 연구를 ROI 기반 경제성 분석으로 확장
- 전환확률·Benchmark ROI·민감도 분석 통합
- ROI 임계점 관점의 정량 평가 프레임워크
- AI-like 리스크를 경제적 손익과 연결
- 집행 전 ROI 위험 사전 평가 기준 제공

## 연구의 한계

- 성과 패널티 19.1%는 선행연구 기반 가정값
- CNN 학습 데이터 239장으로 일반화 한계
- ROI 분석은 시뮬레이션 기반
- 실제 광고 플랫폼 환경을 완전히 반영하지 못함

## 향후 과제

- 웹 A/B 테스트로 CTR·CVR·ROI 검증
- AI-like Score와 실제 성과 관계 분석
- 산업군별 ROI 임계점 모델 개발
- 이미지 데이터 확대로 CNN 일반화 향상
- 실시간 ROI 예측·집행 지원 고도화

AdTrace AI는 AI 광고의 ROI를 예측하고 기업의 의사결정을 지원하는 데이터 기반 프레임워크를 제안한다.

**KEY TAKEAWAY** AI 광고의 핵심은 생성 여부가 아니라 경제적 타당성이다.

# 감사합니다

## Q&A

**AdTrace AI**

From AI Risk to ROI Decision

핀셋 최종 발표

# 이상구간에서 단기 유동성이 원/달러 환율 변동에 미치는 영향 분석

**핀셋** 김예정, 김한별, 이지은

**668**
이상구간 블록

**3,588**
관측일

**1995~2026**
분석 기간

01 연구 배경

# 왜 환율인가

### 📈 물가 파급

환율 상승 → 수입물가 상승 → 소비자물가·기업 비용에 직접 영향

### 🌐 무역·자본 흐름

수출입 채산성, 외국인 자금 흐름, 국내 자산가격과 직결

### 🏭 대외 개방 구조

원자재·중간재 수입 비중이 높은 한국 경제 특성상 환율 충격이 빠르게 전달

### 🏦 통화정책 연계

환율 변동은 환헤지 비용, 기업 부채 구조, 통화정책 판단과 긴밀하게 연결

01 연구 배경

# 금리차만으로 설명되지 않는 구간

### 기존 설명 방식

→ 한미 금리차는 환율 결정의 핵심 변수

→ 한국 금리 ↑ → 원화 수요 증가 → 원화 강세

→ 미국 금리 ↑ → 달러 선호 → 원/달러 상승

### ⚠ 설명력이 약해지는 국면

— 금융위기·팬데믹·글로벌 긴축·정치적 불확실성

— 금리차와 환율 방향이 달라지거나 관계 약화

— 최근 고환율 기간을 임의로 자르면 자의성 발생

### 연구 질문의 전환

**"최근 환율 상승의 원인" → "금리차 설명력이 약해진 시장 상태에서의 설명 변수"**

**이상구간 = 금리차 설명력이 약해지는 시장 상태의 반복적 레짐 (하나의 사건이 아님)**

# 분석 방향

01

### 전체 기간 거시 관계 확인

환율-금리차·M2·CPI 등 주요 변수의 장기 평균 선형 관계 파악

02

### 이상구간 레짐 정의

이동상관계수로 금리차 설명력이 약화된 구간을 데이터 기반으로 추출

03

### SHAP 기반 요인 분석

이상구간에서 어떤 변수가 환율 설명에 중요한 정보로 사용됐는지 확인

04

### 임계점 분석 (비선형 구조)

단기 유동성이 특정 수준 초과 시 환율 반응이 커지는 구조 검토

05

### Granger 검정 · 예측 모델

M2 변화의 시간 선행성과 이상구간 내 예측 정보 제공 여부 검증

# 데이터 구성

**목표 변수**

원/달러 환율 (일별)

**기준 변수**

한미 정책금리차

**통화량**

한국 M2 총량 / 미국 M2 총량

**M2 구성요소**

수시입출식저축성예금, 요구불예금 / MMF, 현금통화

**확장 변수**

CPI(한·미), 산업생산, KOSPI / 무역수지, 외국인투자, 소비자심리

## 단기 유동성의 정의

**이동 가능**

요구불예금
수시입출식저축성예금
MMF, 현금통화

**이동 어려움**

만기성 예금
장기 금융상품

02 데이터와 분석 설계

# 전처리와 데이터셋

- 날짜 형식 통일 및 긴 형식 변환 (열→행)
- 숫자 문자열 정리 및 결측 처리
- 일별 환율 × 금리 결합 → 한미 정책금리차 산출
- 월별 M2 자료를 일별 인덱스에 맞춤 (해석상 주의)

⚠ 월별 자료를 일별 인덱스에 맞추었다고 해서 실제 일별 관측치처럼 해석하지 않는다 — 본 연구의 주요 한계.

### 장기 일별 분석

환율 + 정책금리차
+ 한국 M2, 미국 M2

### 단기 유동성 일별

환율 + MMF 중심
단기 자금 흐름

### 월별 거시·금융 통합

CPI, 산업생산, KOSPI
무역수지, 외국인투자

# 이상구간 레짐 정의

## 레짐 정의 기준

| | |
|---|---|
| 이동창 | **30일** |
| 상관계수 임계값 | **−0.2 이하** |
| 최소 지속 기간 | **30일 이상** |
| 분석 기간 | **1995.01.01 ~ 2026.03.20** |
| 결과 | **668개 구간, 3,588 관측일** |

## 레짐 개념도 (모식)



■ 이상구간 (금리차·환율 디커플링)

하나의 긴 사건이 아니라 장기간 반복되는
시장 상태 (668개 구간)로 정의

**⚠ 구간 경계 처리**

서로 떨어진 구간을 단순 이어 붙이면 경계에서 가짜 점프 발생 가능 → Granger 분석 시 각 구간 내부에서만 변화율 계산

**이상구간은 하나의 사건이 아니라, 금리차 설명력이 약해지는 시장 상태의 반복적 레짐이다.**

03 분석 방법

# 전체 연구 절차

[데이터 구축 단계]

① 데이터 수집 및 전처리

② 장기 관계 분석

③ 이상구간 레짐 정의

④ SHAP 기반 요인 분석

⑤ M2 구성요소 분석

[분석 및 검증 단계]

⑥ 단기 유동성 임계점 분석

⑦ Granger 인과성 검정

⑧ 예측 모델 검증

⑨ 환율 영향 확장 분석

🔍 **설명 변수 탐색**

SHAP · 임계점 · 구성요소

⏱ **시간 선행성 검증**

Granger 인과성 검정

🎯 **예측 정보 확인**

이상구간 조건부 개선 여부

03 분석 방법

# 상관관계 분석 vs SHAP 분석

## 피어슨 상관관계

- ✓ 환율-거시변수 선형 관계 파악에 유용
- ✓ 장기 구간 평균 방향 확인
- × 비선형 관계 포착 불가
- × 임계점 구조에서 낮게 나타날 수 있음
- × 이상구간의 설명력 과소평가 가능성

## SHAP (설명가능 AI)

- ✓ 랜덤 포레스트 모델의 변수별 기여도 계산
- ✓ 비선형 관계·상호작용 포착 가능
- ✓ 상관계수 낮아도 SHAP은 중요 표시 가능
- ⚠ 인과관계 증명이 아닌 설명 도구
- → 이상구간 변수 선별의 근거로 활용

💡 선형 상관관계만으로는 이상구간의 환율 설명 구조를 충분히 포착하기 어렵다. SHAP은 이 간극을 채우는 보조 도구로 사용.

03 분석 방법

# 단기 유동성 임계점 분석

## 핵심 가설

### 선형 상관관계

M2↑ 시 환율 반응이
일정 (낮은 $R^2$)

→

### 임계점 가설

특정 수준 초과 시
환율 반응 급증

→

### SHAP과의 연결

비선형 모델에서는
M2 기여도가 높게 표시

## 분석 방법

① 환율 변화량 × 단기 유동성 변화량 계산 (일별)

② 여러 후보 임계값에 대해 더미·상호작용항 포함 회귀식 적합

③ 잔차제곱합(RSS) 최소화 → 최적 임계점 선택

④ MMF, CMA 구분하여 SHAP 의존도 분석

03 분석 방법

# Granger 인과성 검정

**Granger 인과성이란?**

변수 A의 과거값이 변수 B의 현재·미래 값을 예측하는 데 유의한 정보를 제공하는지 검정. 구조적 인과 증명이 아닌 시간 선행성 근거 제공.

## 양방향 검정

**M2 변화 → 환율 변화**

과거 M2 변화가 현재 환율 변화를
예측하는 데 정보를 제공하는가?

**환율 변화 → M2 변화**

과거 환율 변화가 현재 M2 변화를
예측하는 데 정보를 제공하는가?

**⚠ 이상구간 데이터 처리 방식**

여러 블록을 단순 이어 붙이면 경계에서 가짜 점프 발생 → 각 이상구간 내부에서만 변화율 계산, 경계 제거 후 분석

**Granger 검정은 M2 변화의 시간 선행성과 예측 정보 여부를 확인하기 위한 보조 검증이다.**

03 분석 방법

# 예측 모델 검증 설계

**목적: 전체 최적 예측이 아닌, 이상구간에서 단기 유동성 변수의 추가 설명 정보 제공 여부 확인**

| 모델 | 입력 변수 | 평가 초점 |
|---|---|---|
| 금리차 단독 LSTM | 환율 + 한미 정책금리차 (과거 30일) | 기준선 (baseline) |
| MMF 추가 LSTM | 환율 + 금리차 + MMF 일별 변화 | 이상구간 개선 여부 |
| 수시입출식 LSTM | 환율 + 금리차 + 수시입출식저축성예금 | 이상구간 개선 여부 |

## 평가 구성

- 예측 대상: 5영업일 후 환율 (과거 30일 입력)
- 평가 구간: ① 전체 기간 ② 고정 이상구간 ③ 이상구간 레짐
- 지표: weighted RMSE, weighted MAE
- 비교 기준: 금리차 단독 모델 대비 개선 여부에 초점

04 분석 결과

# 장기 환율 요인 분석 결과

## 정상구간 (장기)

→ M2, CPI ↑ → 환율과 양의 관계

→ 금리차 ↑ → 환율과 음의 관계

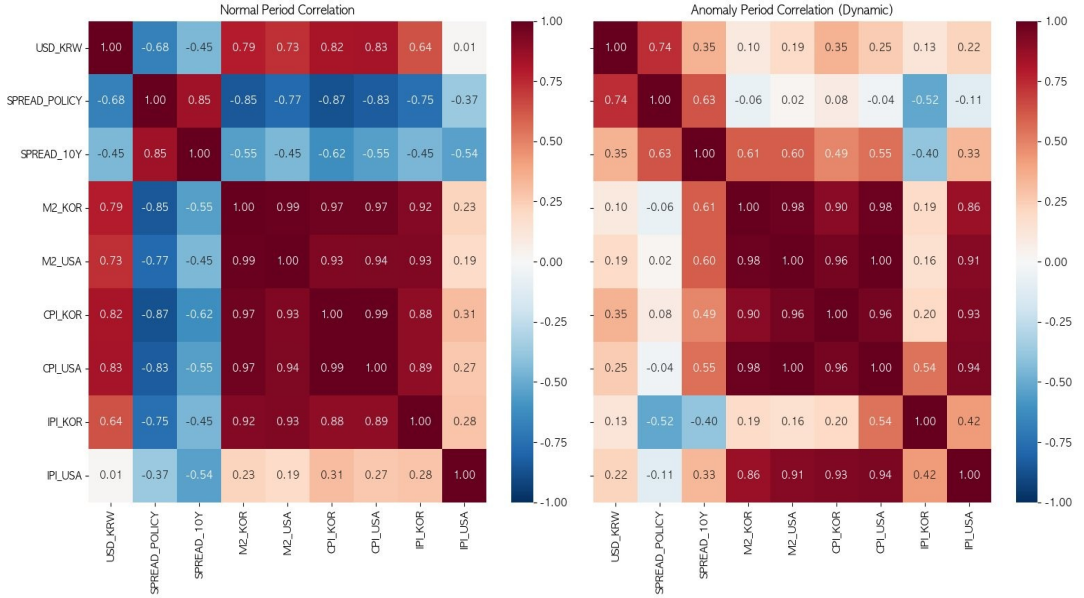
→ 강한 선형 패턴 관찰됨

## 이상구간

— M2-환율 선형 상관관계 약화

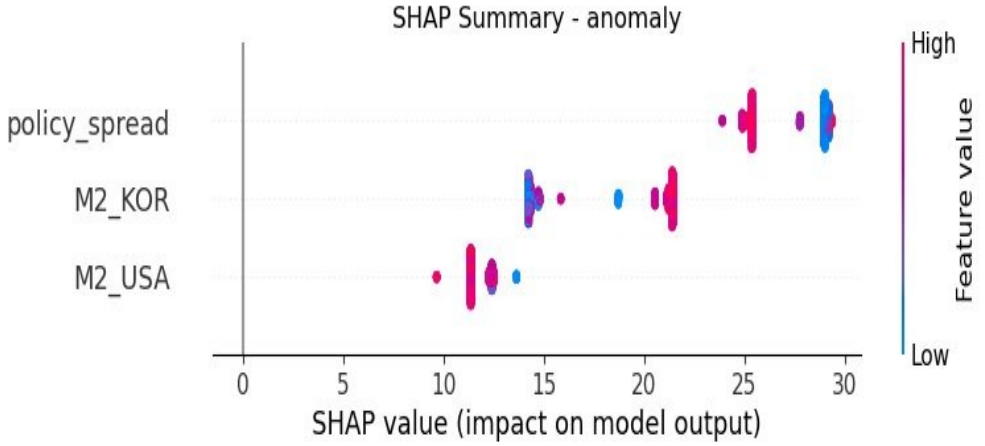
— 금리차 설명력 약화

— 선형 구조만으로는 설명 불충분




💡 상관관계가 낮다 ≠ 설명력이 없다. 비선형 구조에서는 상관계수가 낮아도 SHAP 기여도는 높게 나타날 수 있다.

# SHAP 분석 결과 — 이상구간 레짐




## 이상구간 레짐 SHAP 결과

| | |
|---|---|
| rows | **3,588 관측일** |
| 주요 변수 | **policy_spread, M2_KOR, M2_USA** |
| M2_KOR | **SHAP 기여도 중간~높음** |
| policy_spread | **가장 넓은 분포** |

### 단기 유동성 계열 중요

M2_KOR을 포함한 단기 유동성 변수가 이상구간 환율 설명에 중요한 정보로 사용됨

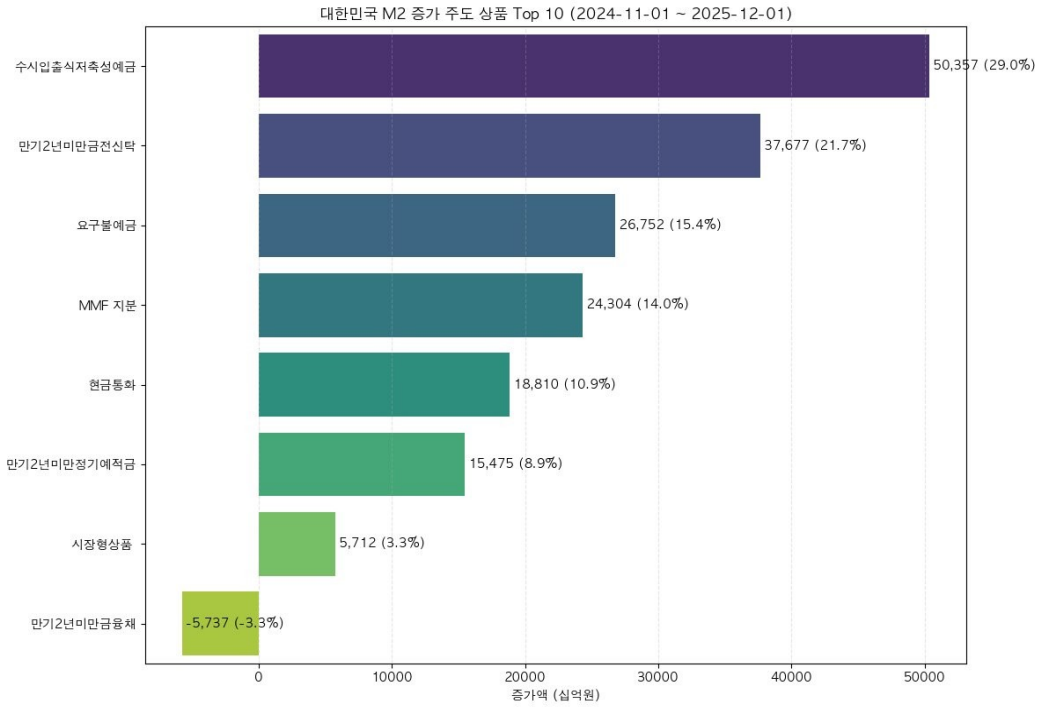
### SHAP ≠ 인과

랜덤 포레스트 기반 기여도이며, 구조적 인과관계를 직접 증명하지 않음

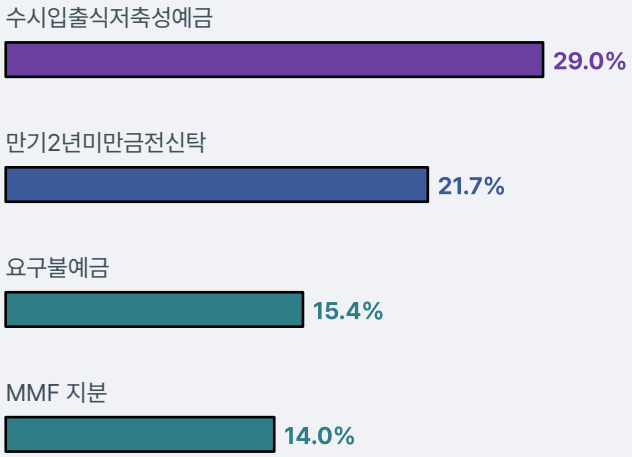
### 비선형 가능성

선형 상관관계와 SHAP 결과의 차이는 비선형 구조 가능성을 시사함

# M2 구성요소 분석 결과

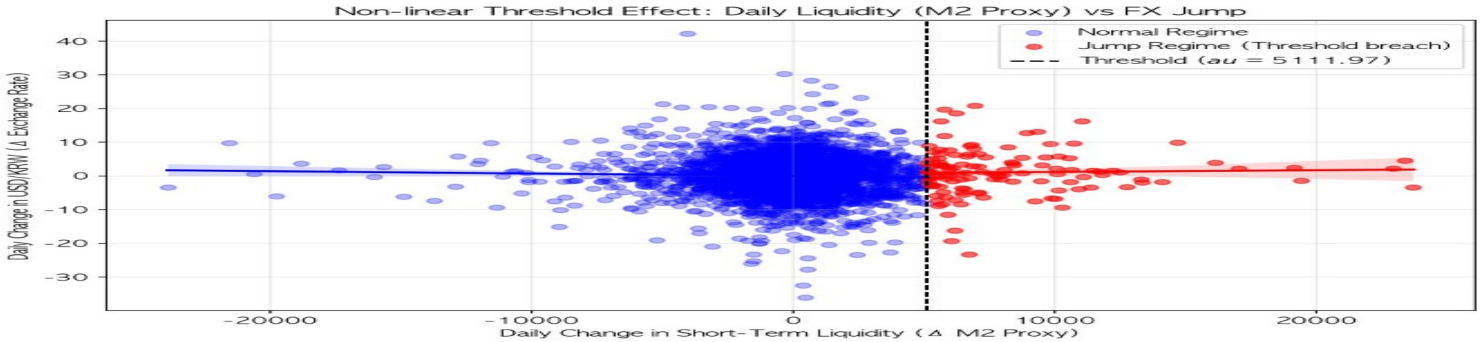



**이상구간에서**
**두드러진 자금 성격**



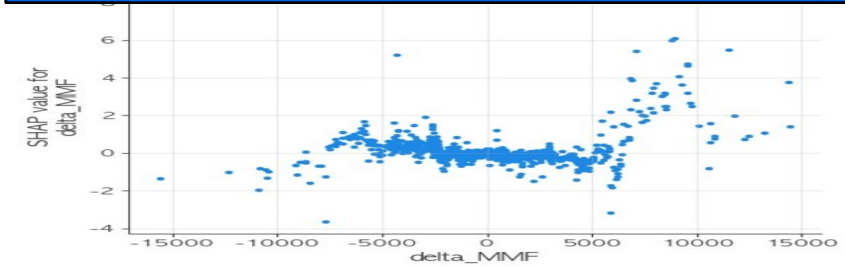

**→ 단기 대기성 자금 증가 두드러짐**
**(수시입출식, MMF, 요구불예금)**

# 임계점 가설 검증 결과

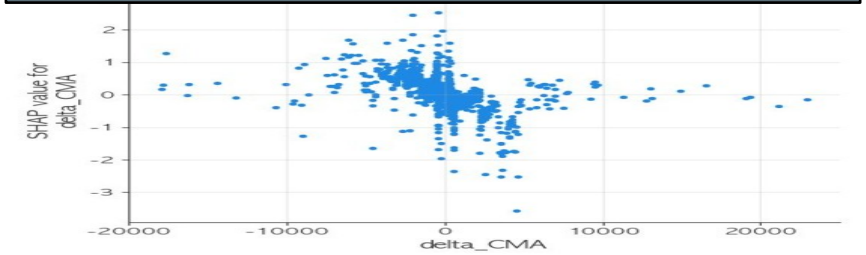



임계값 ≈ 5.1조 원 (기존 결과 기준, 표본 경험치) | 초과 구간에서 환율 반응 확대 패턴 관찰

**MMF — 임계 이후 기여도 가파르게 상승 (명확)**




**CMA — 같은 패턴 상대적으로 불명확**



04 분석 결과

# Granger 인과성 분석 결과

**M2 → 환율**

이상구간

**유의**

lag 1, 2, 3 모두 p < 0.01

**환율 → M2**

이상구간

**비유의**

lag 1, 2, 3 모두 p > 0.65

**M2 → 환율**

정상구간

**비유의**

이상구간의 조건부 현상임을 시사

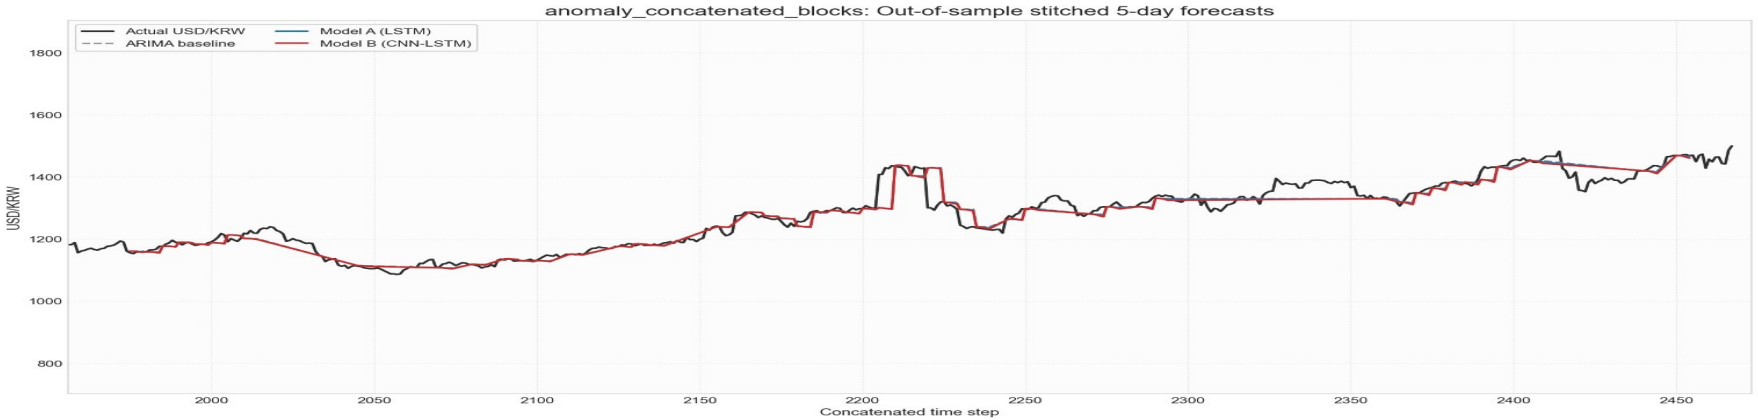
### 이상구간 p-value 상세

| 방향 | Lag 1 | Lag 2 | Lag 3 | 해석 |
|---|---|---|---|---|
| M2 → FX | p = 0.0004 | p = 8.3e-12 | p = 1.2e-12 | ✓ 유의 |
| FX → M2 | p = 0.757 | p = 0.885 | p = 0.680 | 비유의 |

⚠ Granger 인과성은 구조적 인과를 증명하지 않는다. 제3의 외생 충격(글로벌 위험회피, 정책 이벤트 등)이 M2와 환율을 동시에 움직였을 가능성은 남아 있다.

04 분석 결과

# 예측 모델 검증 결과



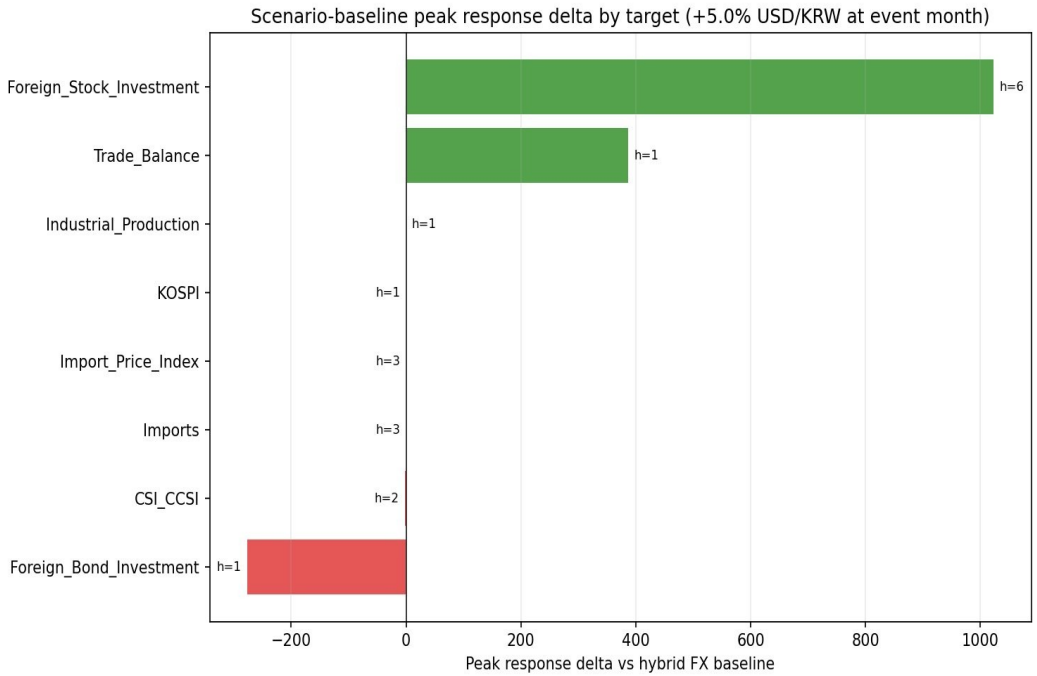

**MMF LSTM — 이상구간 레짐 확장 평가**

| 모델 | weighted RMSE | weighted MAE | 판정 |
|---|---|---|---|
| 금리차 단독 (baseline) | 21.16 | 19.50 | 기준선 |
| **MMF 추가** | **16.62 ▼** | **14.32 ▼** | **개선** |

수시입출식저축성예금 LSTM도 이상구간에서 유사한 개선 방향 확인 | 전체 기간에서는 금리차 단독 우위 또는 유사

04 분석 결과

# 환율 충격 이후 거시·금융 변수 반응




**분석 방법**

**사건 시점 기준**
**국소투영(Local Projection)**

**변수별 해석 가능성**

✓ 소비자심리지수

✓ 외국인 채권투자

✓ 수입액

⚠ 수입물가지수

⚠ 산업생산, KOSPI

⚠ 무역수지

✓ 비교적 일관 ⚠ 신중한 해석 필요

05 종합 논의

# 연구 결과 종합

### 🔗 구간별 설명 구조 차이

장기 구간에서는 금리차·M2 중심 관계 관찰. 이상구간에서는 단기 유동성이 더 중요한 정보 제공.

### 📊 SHAP & M2 구성요소

비선형 모델에서 M2 및 단기성 자금 기여도 확인. 이동성 높은 구성요소 중요성 부각.

### ⚡ 임계점 비선형 구조

일일 유동성 ~5.1조 원 초과 시 환율 반응 확대. 상관관계↔SHAP 결과 차이를 설명하는 연결고리.

### 🕐 Granger 선행성 & 예측 개선

이상구간에서 M2→환율 방향 유의(lag 1~3). 예측 모델도 이상구간에서 유동성 추가 시 개선.

05 종합 논의

# 연구의 의의

**금리차 설명의 보완**

금리차가 약해지는 국면에서 단기 유동성이 환율 리스크 신호로 기능할 수 있음을 제시

**데이터 기반 레짐 정의**

임의 기간 설정 대신 이동상관계수로 금리차 설명력이 약화된 구간을 체계적으로 추출

**비선형 영향 가능성 제시**

SHAP과 임계점 회귀로 상관계수에서 포착되지 않는 비선형 임계점 구조 확인

**시간 선행성 근거 보강**

Granger 검정으로 M2를 단순 동행 지표가 아닌 조기경보 지표 후보로 해석 가능

**실무적 확장 가능성**

MMF·요구불예금·수시입출식저축성예금 + 금리차-환율 디커플링 지표 결합 → 리스크 모니터링 체계

05 종합 논의

# 연구의 한계

### ⚠ 구조적 인과 미증명

Granger 인과성은 시간 선행성만 제공. 제3의 외생 충격이 M2·환율을 동시에 움직였을 가능성 존재.

### ⚠ SHAP 모델 의존성

랜덤 포레스트 기반 결과. 모든 모형에서 동일한 기여도 재현 보장 불가.

### ⚠ 월별→일별 보간 한계

월별 M2를 일별 인덱스에 맞춘 처리. 실제 일별 관측치처럼 해석 불가.

### ⚠ 이상구간 연결 방식

분리된 구간을 하나의 레짐으로 묶는 것은 연구 목적상 필요했으나 달력상 간격 제거 한계 존재.

### ⚠ 초기·최종 분석 정합성

CMA+MMF 초기 대리 지표, 고정기간 결과, 레짐 결과가 공존 → 최종 해석 시 레짐 결과 중심으로 구분 필요.

**결과는 구조적 인과가 아니라 조건부 설명력과 예측 정보의 관점에서 해석해야 한다.**

06 결론

# 결론

| | |
|---|---|
| 장기 구간 | 금리차와 환율 사이의 전통적 관계 어느 정도 관찰됨 |
| 이상구간 | 단기 유동성 변수가 더 중요한 설명 정보 제공 |
| SHAP 분석 | M2·단기성 자금 계열이 환율 상승 설명의 핵심 정보로 사용 |
| 임계점 분석 | 단순 선형이 아닌 비선형 임계점 구조 확인 (MMF에서 명확) |
| Granger 검정 | 이상구간에서 M2→환율 선행 방향 유의, 반대 방향 비유의 |
| 정상구간 | 같은 M2-환율 관계가 유의하지 않아 조건부 특성 확인 |

**단기 유동성은 모든 시기의 보편 변수는 아니지만,**
**금리차 설명력이 약화되는 이상구간에서는 조건부 설명력과 선행성을 보인다.**

07 향후 연구 방향

# 향후 연구 방향

01

## 실시간 단기 유동성 모니터링

MMF·수시입출식저축성예금·요구불예금 변화를 주기적 수집
→ 금리차-환율 이동상관계수와 함께 모니터링

02

## 환율 리스크 조기경보 지수

단기 유동성 증가율 + 임계값 초과 여부 + 이상구간 진입 + DXY·VIX 결합
→ 통합 위험지수 개발

03

## 외생 충격 반영

정책 이벤트·지정학적 리스크·중앙은행 커뮤니케이션 더미 변수 추가
→ 유동성 효과와 외생 충격 분리

04

## 파급효과 분석 고도화

단기 유동성 기반 환율 예측 + 사건 시점 국소투영 결합
→ '유동성 충격 → 환율 상승 → 거시 반응' 연쇄 시스템

**향후에는 단기 유동성 기반 환율 리스크 조기경보 시스템으로 확장할 수 있다.**

# 구음장애 발화의 의도 복원을 위한 멀티모달 음성인식 파이프라인 연구

WSLD 기반 발화 심각도 정량화 · LLM Judge–Editor Post-ASR Correction

**BERTScore +3.84%**

0.9402 → 0.9763

**Gold Standard**

9,832건 자동 구축

**Kruskal-Wallis**

$H=491.3 \quad p=2.1\times10^{-107}$

배경

# 연구 배경 및 접근 방식

## 문제 — 현행 ASR의 구조적 한계

· 구음장애 (뇌졸중·파킨슨·후두질환) 비유창성
= 반복·막힘·조음파열

· Whisper·Conformer 등 상용 ASR: 정상 화자 분포에 과적합

· 음향 모델 재학습 → 화자별 반복 fine-tuning 필요
→ 임상 확장성 低

· 한국어 구음장애 평가 자산 부재

## 접근 — Post-ASR Correction

→ 음향 모델 재학습 없이 LLM 추론 단계에서 의도 복원

→ 비유창성을 잡음이 아닌 복원 가능한 신호로 재정의

→ 텍스트(WSLD) + 오디오(Hesitation) 멀티모달 융합

→ 교차 화자 앵커 매칭으로 Gold Standard 자동 구축

## 연구 목표 4단계

01 피처 추출·정량화

02 통계적 타당성 검증

03 Gold Standard 구축

04 LLM Judge–Editor 실증

*피처 추출 → 통계 검증 → 벤치마크 구축 → 복원 실증*

데이터
·피처

# 데이터셋 개요 및 피처 설계

**6,104건**
분석 대상
7,874건 원본 → 필터링

**3그룹**
질환 그룹
TS01·TS02·TS03

**19,882개**
고유 문장 수
중복률 95.4% - Gold Standard 기반

**16kHz**
오디오 처리
30dB 임계값 Librosa

## 텍스트 피처 — WSLD Score

*Ambrose & Yairi (1999) 재설계 · 한국어 전사 기호 매핑*

**WSLD = [(PW+SS)×RU_avg] + (2×DP) + ε**

| | | |
|---|---|---|
| + | 반복 더듬음 | ×1.5 |
| * | 발음 불분명 | ×2.0 |
| / | 음절 탈락 | ×0.5 |

Imperfect Rate: Clean(0%) · Mild(≤2%) · Severe(>2%)

## 오디오 피처 — Hesitation_per_word

*H_w = Σ T_hes / N_word (< 1.5초 = 더듬음 / ≥ 1.5초 = 휴지)*

**발화 길이 교란 제거를 위한 어절 단위 정규화**

| 그룹 | 평균 H_w | 중앙값 | 증감 |
|---|---|---|---|
| Clean (0%) | 0.0528 | 0.0255 | baseline |
| Mild (≤2%) | 0.0789 | 0.0537 | ↑ +49% |
| **Severe (>2%)** | **0.1277** | 0.0941 | **↑ +142%** |

→ 심각도 증가에 따라 단조 증가 — 오디오가 독립적 심각도 정보를 운반

방법

# Gold Standard 구축 — 교차 화자 앵커 매칭

**핵심 원리: 전체 447,730건 중 고유 문장 19,882개 — 중복률 95.4%**

동일 낭독 대본을 다수 화자가 반복 발화 → 불완전 발화의 정답이 '다른 화자의 깨끗한 버전'에 존재

## 4단계 캐스케이드 매칭

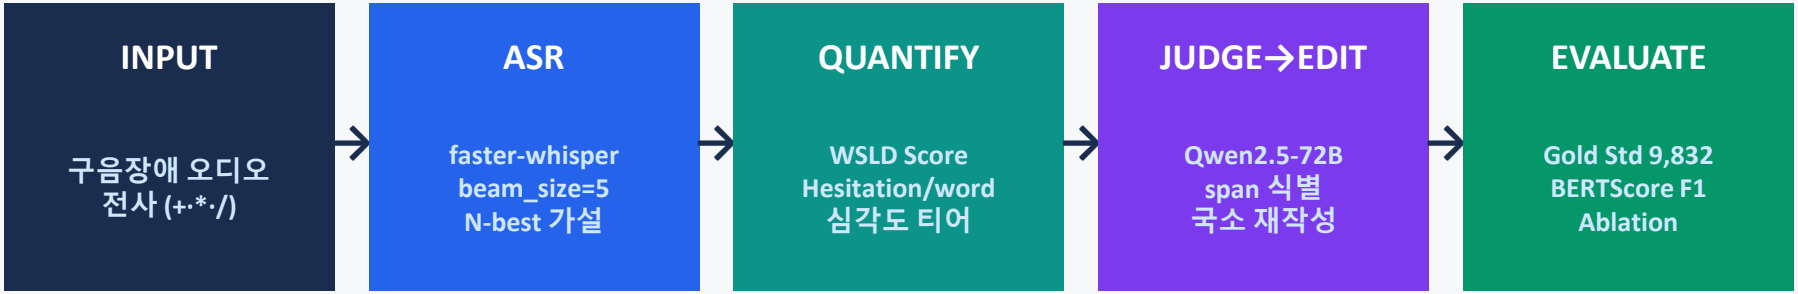
| | | | | |
|---|---|---|---|---|
| T1 Exact | sim ≥ 0.90 | 8,156건 | | 82.7% |
| T2 Partial | 0.80~0.90 | 1,178건 | | 11.9% |
| T3 Fuzzy | 0.70~0.80 | 296건 | | 3% |
| T0 Human | < 0.70 직접 청취 | 202건 | | 2% |
| T_noise | 노이즈 제외 | 20건 | | 0.2% |

**최종 Gold Standard: 9,832건 (99.7%) 자동화**

자동 커버리지 97.6% (T1+T2+T3) · 수동 의존 2.0% · 노이즈 0.2%

아키텍처

# LLM Judge–Editor 파이프라인




## JUDGE — 불확실 구간 탐지

· N-best 가설 간 span 단위 일관성 비교

· 합의 高 구간 → 원형 보존

· 충돌 구간 → UNCERTAIN 표시

· 전사기호(+·*·/)를 신뢰도 신호로 재정의

## EDITOR — 국소 재작성 + 3대 규칙

· UNCERTAIN 구간만 재작성 (문맥 + Soft Fusion 오디오)

· R1 Last-Attempt Wins — 마지막 시도어만 채택

· R2 No Deletion — 정상 단어 삭제 금지

· R3 No Creation — 미완성 문장 임의 완성 금지

*Soft Fusion: 오디오 피처 → 자연어 메타데이터 → LLM 프롬프트 주입 (폐쇄형 API 환경 최적화)*

결과 ①

# 통계 검증 — 텍스트와 오디오는 독립적이지만 상관된 신호

## Test 1 · Kruskal–Wallis H-test

3그룹(Clean/Mild/Severe) 간 H_w 분포 차이

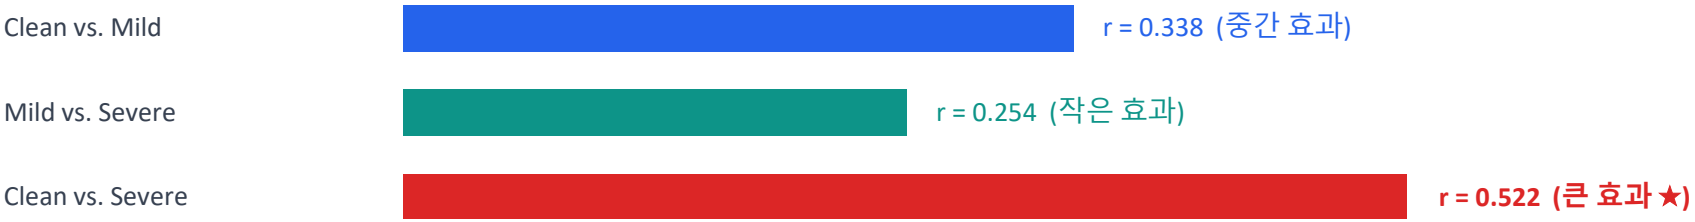
| | |
|---|---|
| H 통계량 | 491.255 |
| p-value | $2.11 \times 10^{-107}$ |

## Test 2 · Spearman ρ (WSLD ↔ 오디오)

텍스트 WSLD와 오디오 피처의 단조 관계 — ρ ≈ 0.4

| | | |
|---|---|---|
| 더듬음 횟수 | r = 0.377 | $p = 4.50 \times 10^{-49}$ |
| 더듬음 시간 | r = 0.400 | $p = 1.97 \times 10^{-55}$ |

## Test 3 · rank-biserial 효과크기 — 심각도 분류의 임상 변별력




→ ρ ≈ 0.4: 두 모달이 부분적으로만 겹침 = 보완 신호 확인 → Soft Fusion 타당성 핵심 근거

결과 ②

# BERTScore A/B Ablation 결과 (n=9,832)

### C0 · Baseline

**0.9402**

faster-whisper 1-best
교정 없음

### C1 · LLM Rule ★

**0.9763**

Judge–Editor + 3 invariants
텍스트 채널 단독

▲ +3.84% vs. C0

### C2 · LLM Multimodal

**0.9755**

C1 + 오디오 Soft Fusion

▲ +3.75% ▼ −0.08% vs. C1

### H1 ✓ LLM 사후 교정의 유효성 입증

· Judge–Editor 텍스트 규칙만으로 +3.84%p 향상

· 음향 모델 재학습 없이 BERTScore 개선 달성

· 교정 예시: '양은냄비+ 꺼내+ 양은냄비를+ 꺼내+'
→ '양은냄비를 꺼내'

### H2 ✗ Soft Fusion의 한계 노출

· 오디오 주입 시 C1 대비 −0.08%p 미세 하락

· 자연어 메타 변환 과정에서 음향 시그니처 소실

· 폐쇄형 API 환경의 구조적 제약

→ **frame-level acoustic embedding 결합 필요**

결과 ③

# Tier별 분석 및 한계

### Table 6. Tier별 BERTScore — 오디오 기여의 조건부 효용

| Tier | Baseline | Rule | Multimodal | 오디오 기여 |
|---|---|---|---|---|
| T0_human (직접청취) | 0.8755 | 0.9540 | **0.9565** | **+0.0025 ✓** |
| T1_exact (≥0.90) | 0.9503 | 0.9818 | 0.9809 | -0.0009 |
| T2_partial (0.80~0.90) | 0.9007 | 0.9549 | 0.9541 | -0.0008 |
| T3_fuzzy (0.70~0.80) | 0.8630 | 0.9263 | 0.9247 | -0.0016 |

→ 오디오 기여는 텍스트 손상 정도에 따라 조건부 발현.
T0_human(가장 심각한 구간)에서만 +0.0025 개선 — 음향 단서가 텍스트 규칙을 보완.

## 방법론적 한계

**L1 · Soft Fusion 정보 손실**

프레임 단위 음향 시그니처 소실 → hard fusion 필요

**L2 · 단일 전사자·IRR 미측정**

T0 계층 inter-annotator agreement(κ) 검증 부재

**L3 · Safety Trigger 미구현**

hallucination 구조적 차단 장치 (Reject 로직) 부재

**L4 · 표본 편향·외적 타당도**

TS03 73% 편중 · Validation Set 평가 미수행

결론

# 연구 기여 및 향후 과제

## 01 패러다임 전환

비유창성을 신호로 재정의.
한국어 WSLD 정량 척도 구체화.

## 02 벤치마크 공개

Gold Standard 9,832건
· WSLD Score 및 H_w 지표
→ 한국어 구음장애 ASR 평가 기준 후보

## 03 성능 실증

BERTScore +3.84%p
음향 재학습 없이 의사소통 보조 가능성

## 향후 과제 ROADMAP

**F1 · Frame-level 음향 임베딩**

Soft Fusion 한계 극복 · hard fusion 채널

**F2 · Safety Trigger 도입**

불확실성 임계 초과 시 Reject 로직 설계

**F3 · Cross-corpus 검증**

AI Hub 外 코퍼스 · 질환군 균형 표본

**F4 · 임상 보조 시스템화**

재활·언어치료 현장 실시간 의사소통 보조

**비유창성은 잡음이 아니라 신호다 — 정량화 가능하고, 복원 가능하다**

KR-FinBERT × LSTM

# 다중 모달 융합 기반 KODEX 200 수익률 예측 및 변동성 분석

매크로 팀 | 구다연 · 이예현 · 이지수 · 이찬영

DAT 7th 캡스톤 프로젝트 · 2026.06.04

| Hit Ratio (방향성 적중률) | Pearson 상관계수 |
|---|---|
| 73.56% | 0.5238 |
| **RMSE** | **최고 Hit Ratio (Ablation)** |
| 0.03695 | 73.86% |

연구 기간 : 2021.03 ~ 2026.03 (약 5년, ~1,150 거래일)

# 00 목차


01 **연구 배경 및 목적**
정형 데이터의 한계 · 기존 연구 한계 · 연구 목표

02 **데이터 구성 & KR-FinBERT**
5년 데이터셋 · 뉴스 임베딩 파이프라인 · 17개 기술지표

03 **모델 설계**
XGBoost Baseline · 2-Layer LSTM · AT-LSTM 비교

04 **실험 결과**
성능 비교 테이블 · Hit Ratio · Pearson 상관계수 · DM 검정

05 **Ablation Study**
뉴스 정보 기여도 정량 검증 · 비선형 시너지 실증

06 **피처 중요도 분석**
AT-LSTM 어텐션 가중치 · Bond_Yield_Change 핵심 발견

07 **결론**
3대 핵심 발견

08 **한계 및 향후 연구**
한계점 및 개선 방향

# 01 연구 배경 — 왜 정형 데이터만으로는 부족한가

## [1] 기존 통계 모델의 한계

ARIMA, GARCH 등은 가격, 거래량 등의 정형 시계열만 활용
→ 금리 결정, 기업 실적, 지정학적 리스크 등
텍스트 이벤트 포착 불가

## [2] 딥러닝 도입 이후에도 남은 과제

복잡한 Attention · Gate 메커니즘
→ 금융 데이터 특유의 고주파 노이즈, 무작위성으로
과적합 및 학습 불안정

## [3] 본 연구의 질문

"구조적 복잡성을 배제한 단순 결합(Concatenation)만으로도
정형+비정형 융합이 금융 중기 추세를 안정적으로 포착할 수 있는가?"

# 02 데이터 구성 — 5년간 ~1,150 거래일 통합 데이터셋

| 구분 | 기간 | 샘플 수 | 특징 차원 |
|---|---|---|---|
| 기술지표 | 2021.04.22 ~ 2026.03.10 | 1,194 | 17개 (+target) |
| 뉴스 임베딩 | 2021.03.10 ~ 2026.02.02 | 1,269 | 769 (768 + sentiment) |
| 결합 데이터셋 | 교집합 기간 | ~1,150 | 786 |

## 17개 기술지표 그룹

### 수익률/모멘텀

Return_Lag1 · Momentum_10D · Log_Return

### 변동성

Vol_5 · Vol_21 · RV_Trend_5_21 · RV_Trend_21_63 · ATR_Pct

### 기술지표

MACD · RSI · SMA_21_Disparity · SMA_63_Disparity

### 거래량/범위

Volume_MA_Ratio · Intraday_Range_Pct

### 거시지표 ★

VIX_Change · DXY_Return · Bond_Yield_Change

*★ 거시지표(VIX · DXY · Bond Yield)는 AT-LSTM 어텐션 분석에서 핵심 피처로 자동 선별됨*

# 02 KR-FinBERT — 한국어 금융 언어 모델 활용 파이프라인

**뉴스 기사 수집**
네이버 · 연합뉴스 등
국내 금융 뉴스

▶

**KR-FinBERT 인코딩**
KLUE-BERT 기반
금융 도메인 사전학습 모델

▶

**[CLS] 토큰 추출**
768차원 hidden state
문서 수준 표현

▶

**L2 정규화 + 평균 풀링**
동일 거래일 복수 기사
→ 일별 단일 벡터

▶

**MLP 차원 압축**
256 → 128 → 64 차원
LayerNorm + ReLU

### ① 뉴스 임베딩 벡터 (emb_0 ~ emb_767)

64차원으로 압축된 의미론적 맥락 벡터
→ 시장 배경 정보, 이벤트 텍스트 패턴 압축 표현

### ② 감성 점수 sentiment_score

범위: -1.0 (매우 부정) ~ +1.0 (매우 긍정)
수집 통계: 평균 0.112 · 표준편차 0.200 · 중앙값 0.082
→ 양성 편향(Positive Bias) 특성 확인

뉴스 없는 거래일(휴장 등): 임베딩 0-패딩 + news_missing 플래그 별도 피처로 추가 → 모델이 뉴스 부재를 명시적으로 인식

# 03 모델 설계 — 3단계 점진적 실험 설계

Baseline

## XGBoost Regressor

단일 시점 입력 · 기준선 확립

- 입력: 전일 기술지표 + 뉴스 감성 점수 (단일 시점)
- 그래디언트 부스팅 앙상블 알고리즘
- 하이퍼파라미터: n_est=150, depth=3, lr=0.02
- 시계열 구조 미활용 → 방향성 포착 한계 확인

제안 모델

## 2-Layer Stacked LSTM

최종 제안 · 다중 모달 단순 결합

- 입력: 기술지표(13d) + 감성점수(1d) + 임베딩(64d) → Concat
- Lookback Window T=20, Hidden=192, Dropout=0.07
- 출력: 미래 5거래일 누적 로그수익률
- 손실: MSE, 최적화: Adam (lr=0.0004)

비교 모델

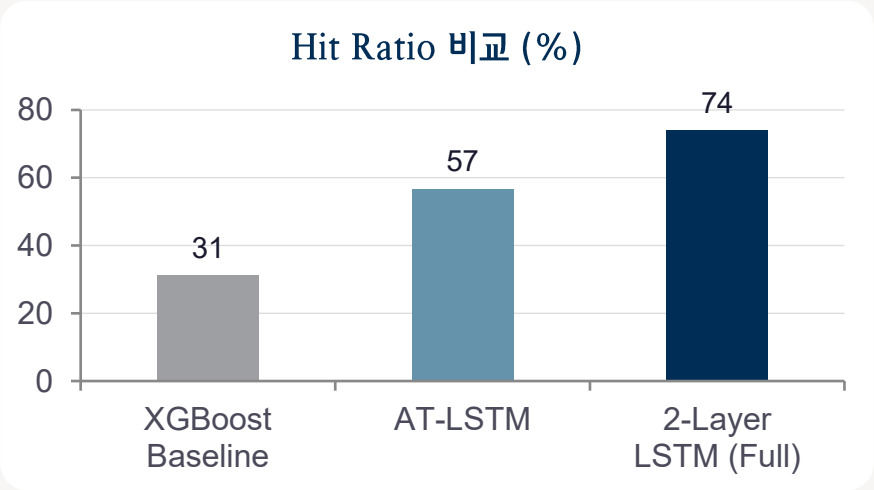
## AT-LSTM

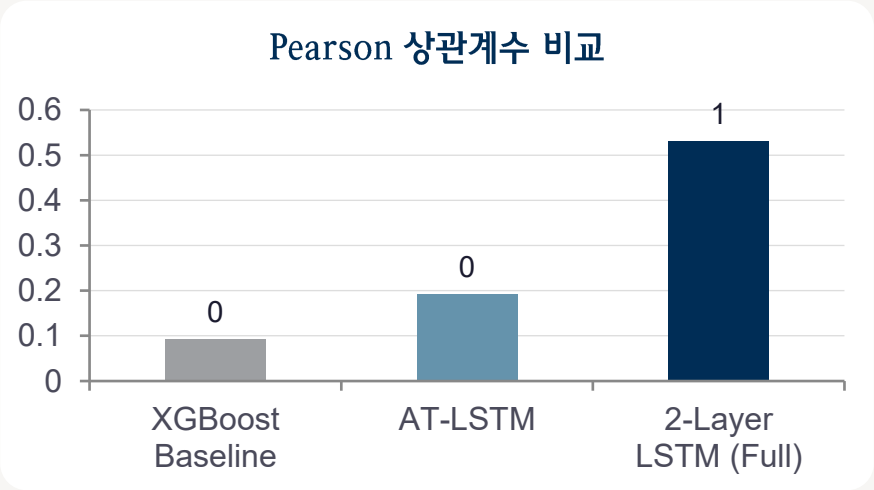
Feature Attention 메커니즘 · 해석 가능성

- 매 타임스텝 피처별 중요도 가중치 $\beta_t$ 동적 산출
- Attention → LSTM 2단계 구조
- 하이퍼파라미터: hidden=128, attn=16, lr=0.0002
- 시장 국면별 피처 기여도 해석 목적

# 04 실험 결과 — 모델 성능 비교 (테스트 기간: 90 거래일)

| 모델 | RMSE | MAE | Hit Ratio | Corr (상관계수) | 비고 |
|---|---|---|---|---|---|
| XGBoost Baseline | 0.04797 | 0.04117 | 31.03% | 0.0919 | 기준선 |
| AT-LSTM | 0.0890 | N/A | 56.67% | 0.191 | 비교 |
| 2-Layer LSTM (Full) | 0.03695 | 0.02894 | 73.86% | 0.5299 | ✓ 최고 |




Diebold-Mariano 검정 | 2-Layer LSTM vs XGBoost: Squared Error p = 0.0369 (*) · Absolute Error p = 0.00585 (***)

→ 통계적으로 유의한 성능 우위

# 05 Ablation Study — (보고서 오류 수정)

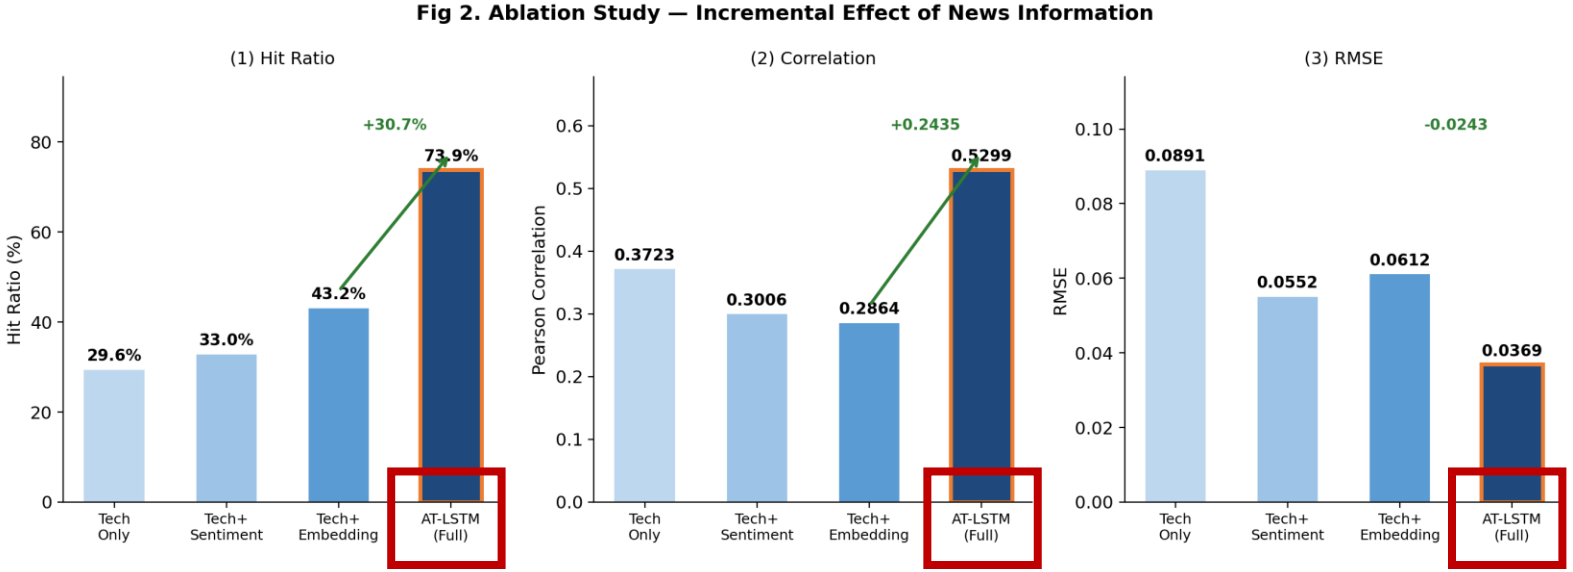
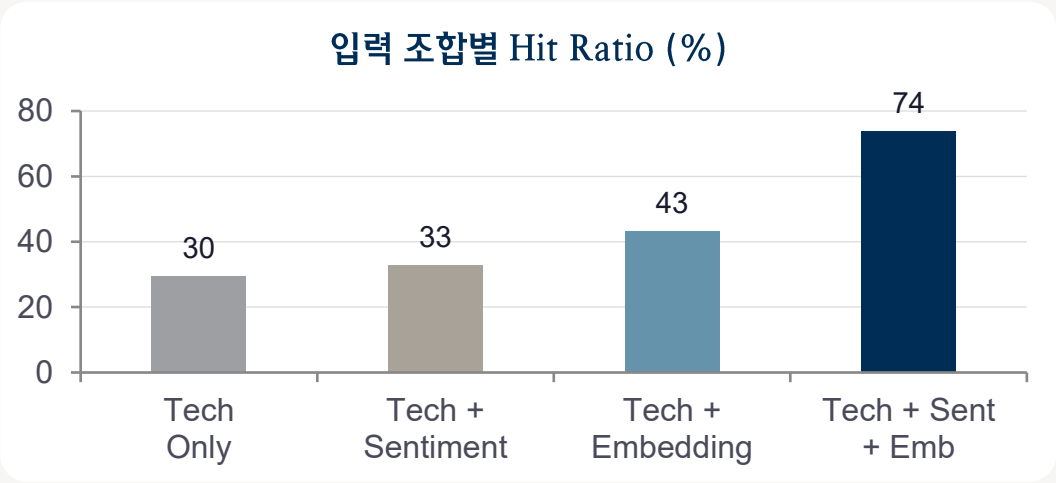



그림 4-5. 2-Layer LSTM Ablation Study: 입력 모달리티 단계별 추가에 따른 성능 변화

| 모델명 | RMSE | MAE | Hit Ratio | Corr |
|---|---|---|---|---|
| Tech_only | 0.0891 | 0.0800 | 29.55% | 0.3723 |
| Tech_Sentiment | 0.0552 | 0.0459 | 32.95% | 0.3006 |
| Tech_Embedding | 0.0612 | 0.0525 | 43.18% | 0.2864 |
| Tech_Sentiment_Embedding | 0.0369 | 0.0290 | 73.86% | 0.5299 |

# 05 Ablation Study — 뉴스 정보의 기여도 정량 검증

| 모델명 | RMSE | MAE | Hit Ratio | Corr | Shape Score |
|---|---|---|---|---|---|
| Tech_only | 0.0891 | 0.0800 | 29.55% | 0.3723 | 0.0809 |
| Tech + Sentiment | 0.0552 | 0.0459 | 32.95% | 0.3006 | 0.0646 |
| Tech + Embedding | 0.0612 | 0.0525 | 43.18% | 0.2864 | 0.0643 |
| Tech + Sentiment + Embedding | 0.0369 | 0.0290 | 73.86% | 0.5299 | 0.0306 |

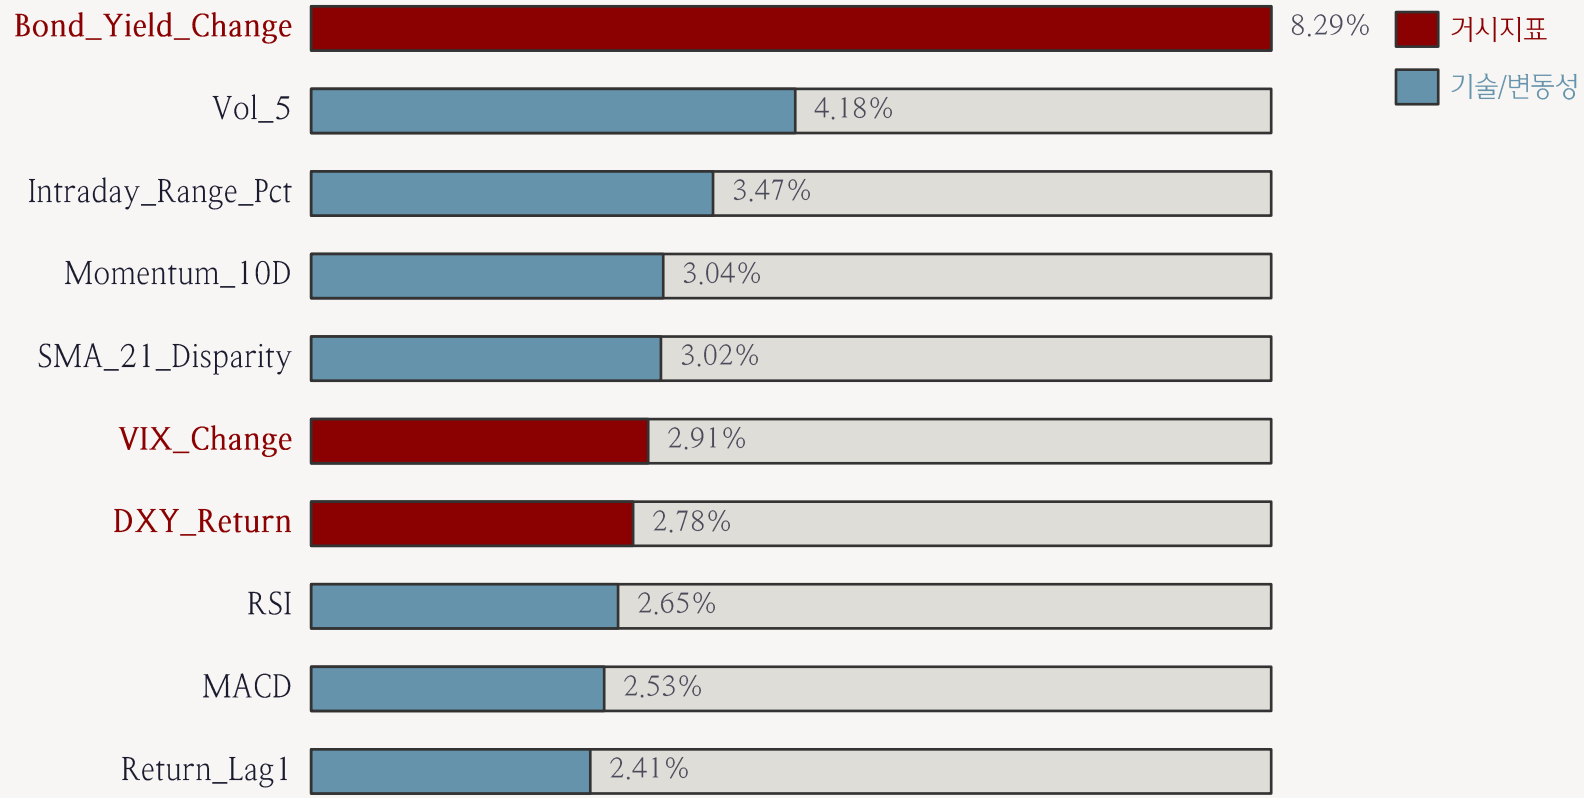



## Diebold-Mariano 검정

| 비교 | 유의성 |
|---|---|
| Tech_only vs Tech+Sent | *** (p<0.001) |
| Tech_only vs Tech+Emb | ** (p<0.01) |
| Tech_only vs Full | *** (p<0.001) |
| Full vs Tech+Sent | ** (p<0.01) |
| Full vs Tech+Emb | *** (p<0.001) |

감성 점수(단기 방향 신호) + 뉴스 임베딩(풍부한 맥락)의 동시 결합 시 비선형 시너지
→ 각 단독 효과의 단순 합산을 크게 상회하는 Hit Ratio 73.86% 달성

# 06 피처 중요도 분석 — AT-LSTM 어텐션 가중치 (테스트 셋 기준)




Bond_Yield_Change 가중치(8.29%) = 2위 Vol_5(4.18%)의 약 2배
→ 2022~2024 글로벌 금리 인상 사이클 환경에서 채권 수익률 변화를 KODEX200 단기 예측의 핵심 트리거로 모델이 자동 인식

# 07 결론

① **단계적 · 통계적으로 유의한 성능 향상**

기술지표 단독(29.55%) → + 감성(32.95%) → + 임베딩(43.18%) → **전체(73.86%)**

모든 단계의 성능 개선이 Diebold-Mariano 검정으로 통계적 유의성 확인

② **뉴스 정보의 비선형 시너지 실증**

단기 방향 신호(감성 점수) + 풍부한 배경 맥락(768d 임베딩) 동시 결합

→ 단독 활용 대비 비선형 시너지 → 단순 복잡성 증가 없이 압도적 성능 향상

③ **Bond_Yield_Change = 핵심 예측 트리거**

AT-LSTM 어텐션 가중치 8.29% (2위 대비 2배)

→ 금리 인상 사이클 시 채권 수익률 변화가 KODEX200 단기 예측에서 가장 중요한 거시 지표임을 모델이 자동 학습

# 08 한계점 및 향후 연구

한계점

① 테스트 셋 규모 제한 (90거래일)

② 수익률 절대 크기 예측 보수적 편향 (MSE 손실 구조)

향후 연구

① 비대칭 손실함수 도입

② 뉴스 발행 시의성 반영

③ 예측 기간 확장

# 감사합니다.

매크로 팀 | 구다연 · 이예현 · 이지수 · 이찬영

DAT 7th 캡스톤 프로젝트 · 2026.06.04

CAPSTONE PROJECT · DAT 7기

# 지식 주입형 언어모델 기반 승정원일기 자동 번역 최적화 연구

프롬프트 전략 및 개체명 주입 방식의 단계적 비교 실험

말모이 팀 · 길다인 · 오성민 · 이승민 · 배진형

2026.06.04

# 왜 지금, 승정원일기인가

3,243책 · 약 2억 4,250만 자 · 유네스코 세계기록유산 등재 · 현재 번역 완료 37.4%

**37.4%**
현재 국역 완료율

**8.3%**
고유명사 오역률

**2062년**
완역 예상 시점

### ① 고유명사 오역

인명·관직명 오역률 8.3%
→ 역사적 사실 자체를 왜곡하는 결과 초래

### ② 문체 불일치

"아뢰기를" → "말씀하기를" 현대어 대체
→ 사료로서의 문어체 신뢰성 훼손

**해법 ▶ 파인튜닝 없이 프롬프트 엔지니어링 + 인물 KB 주입으로 두 문제를 동시 해결**

# 6단계 번역 파이프라인

SillokBERT(인코더) + Gemma-4-26B(디코더) — 가중치 이관 불가 → 프롬프트 기반 지식 전달로 전환

| 01 | 02 | 03 | 04 | 05 | 06 |
|---|---|---|---|---|---|
| **원문 입력** | **NER 추출** | **KB 대조** | **Entity Link** | **프롬프트 증강** | **번역 출력** |
| 승정원일기<br>원문 | SillokBERT-NER<br>개체명 인식 | KB 매핑<br>시기 필터링 | 팩트 생성<br>한자↔한글 | NERinject<br>블록 삽입 | Gemma-4-26B<br>한국어 출력 |

**핵심 설계 결정 — 아키텍처 이질성 극복**

SillokBERT(인코더)와 Gemma(디코더)는 내부 표현 공간·레이어 구성이 이질적 → 가중치 직접 이관 불가능
⟹ 지식을 가중치 대신 프롬프트 형식으로 전달하는 방식 채택 — 연구 방향 전면 수정

**33,002**
KB 등재 인물

**62,176**
병렬 코퍼스 쌍

**300**
평가셋 (층화)

**527**
총 인명 엔티티

# 코퍼스 & 지식 베이스

실록 188,206건 + SJW 130,899건 → V82 매칭 후 병렬 62,176쌍 · 인물 KB 33,002명

## 코퍼스 수집 & 정제

**188,206건** 조선왕조실록
광해군~순종 · Go 기반 크롤러

**130,899건** 승정원일기
인조~정조 · SJW 병렬 크롤러

**62,176쌍** 최종 병렬 코퍼스
V82 매칭 통과 · 인조 전 기간

6단계 정제: 서지정보·각주·저작권·기호·한자·V82 매칭 엔진

## 지식 베이스 & 모델 적응

**인물 KB — 33,002명 (인조 + 정조)**

- person_master.json — 통합 인물 DB (표준 ID · 한자·한글명 · 관직)
- inverted_index.json — 역색인 (본명·자·호·약칭 → O(1) 탐색)
- id_lookup.json — 관직·활동 연도 → 동명이인 시공간 필터링

**SillokBERT CPT (도메인 적응)**

승정원일기 원문 ~25MB · MLM · T4 GPU · 3 Epoch

**5.8** → **5.1~5.2**
Loss 수렴 · 24,546 steps

출처: 국사편찬위원회 조선왕조실록·승정원일기 (2026년 4월 수집)

# 4단계 Ablation 실험 설계

누적 전략 구조 — 각 개입 효과를 단계적으로 분리 측정 · Gemma-4-26B · temperature=0.0

| 1 Baseline | 2 Few-shot | 3 NERfix | 4 NERinject |
|---|---|---|---|
| ZERO-SHOT | STYLE | POST-HOC | PRE-INJECT |
| **최소 프롬프트 원문만 입력** | **REP 패턴 예시 5개 고정** | **번역 후 hanja 음독 교정** | **인물 KB 번역 전 주입** |
| 최소 지시문<br>번역문만 출력 | 일관성 > 다양성<br>동적 선택보다 고정 우수 | 오독 교정 가능<br>생략 인명 교정 불가(한계) | 한자↔한글 매핑<br>생략 자체를 방지 |

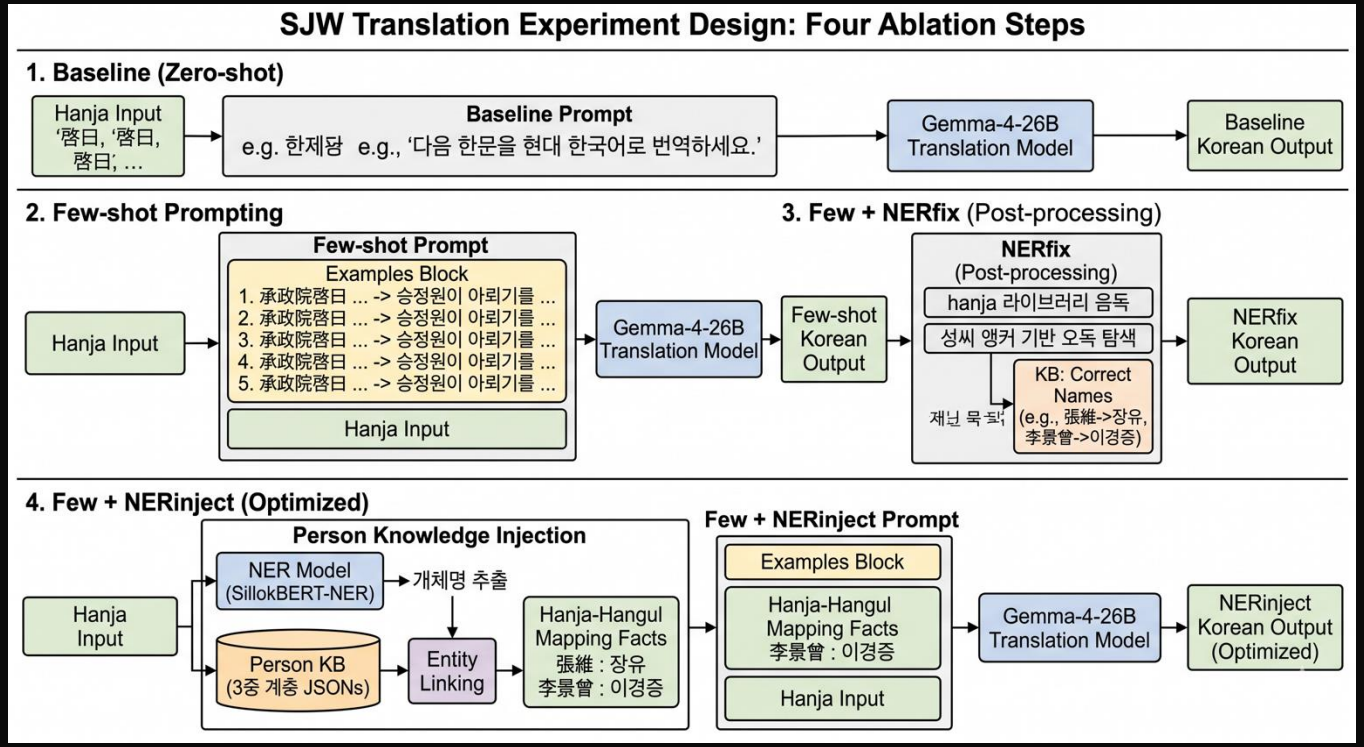
**NERfix vs NERinject — 핵심 차이**

NERfix: 번역 후 오독 교정 (단, 번역 중 생략된 34개 케이스는 사후 교정 불가 → ETS 0.825 천장)
NERinject: 번역 전 인물 KB 주입으로 생략 자체를 방지 → 더 높은 ETS 달성

평가셋 300개 층화 샘플링 (KL div 길이 ~0.000 · 패턴 ~0.001) · 비교 모델: Qwen3, Phi4-mini, DeepSeek-v3

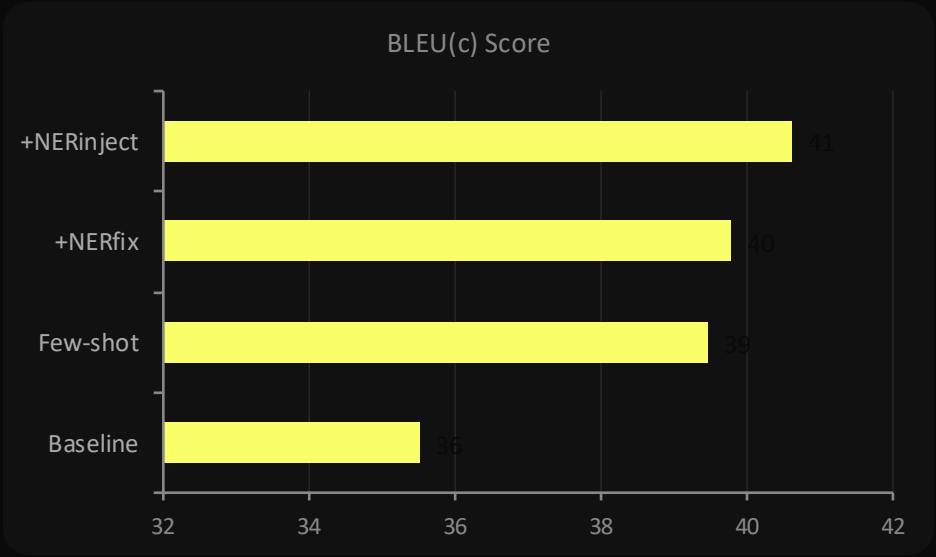
# 4단계 Ablation 실험 설계

누적 전략 구조 — 각 개입 효과를 단계적으로 분리 측정 · Gemma-4-26B · temperature=0.0



# 4단계 Ablation 최종 결과

BLEU(c)와 ETS 동시 최적화 — NERinject가 두 목표를 모두 달성




ETS →

| | BLEU(c) | ETS |
|---|---|---|
| Baseline | 35.51 | 0.744 |
| Few-shot | 39.46 | 0.732 ↓ ETS 하락 |
| +NERfix | 39.78 | 0.825 |
| **+NERinject** | 40.61 | **0.888** |

**Gemma 기여 분리 분석 (491개 엔티티)**

| 74.9% | +13.8% | −0.6% | 10.6% |
|---|---|---|---|
| Gemma 단독 정답 | NER 순수 기여 | NER 역효과 | 둘 다 오답 |

# Closed Loop 문제 & ETS 설계

평가 지표의 독립성이 결과의 신뢰성을 결정한다 — 본 연구의 핵심 방법론적 기여

## 기존 NER Recall

닫힌 고리 (Closed Loop)

정답지 생성 → SillokBERT-NER

NERinject 주입 소스 → 동일 KB 공유

주입된 인명 잔존만으로 정답 처리

**실제 번역 품질과 무관하게 1.000 산출**

**NER Recall = 1.000 (인위적 수치)**

## ETS — 독립 소스 설계

Entity Translation Score

국편 SJW HTML 수집

span.idx_person → 역사학자 직접 어노테이션

SillokBERT와 완전 독립된 정답지 구축

**→ 순환 평가 문제 원천 제거**

**ETS = 0.888 (실제 인명 보존율)**

**ETS = 번역문에 올바르게 등장한 인명 수 / 원문의 총 인명 수**

# 연구의 한계 및 향후 과제

현재 ETS 0.888 — 세 가지 한계가 다음 단계를 정의한다

KB

**KB 커버리지 한계**

현재 KB는 인조·정조 시기 33,002명에 한정. KB 미등재 인명은 주입 자체가 불가 → ETS 0.888이 이론적 천장.

→ 국사편찬위원회 인물 DB 연계 + KB 자동 확장 방법론 개발 필요

ETS

**평가 지표 확장 필요**

현재 ETS는 인명 보존율만 측정. 관직명·지명 오역은 포착 불가 — 사료 번역 완성도 미반영.

→ 관직명·지명 포함 종합적 Entity Translation Score로 확장

LLM

**단일 모델 검증 한계**

Gemma-4-26B 단일 모델에 집중. 동일 전략이 다른 LLM에서도 유효한지 미검증.

→ SJW 전 시기(인조~순종) 확대 + 다모델 비교 실험으로 범용성 확인

향후 과제 · SJW 전 시기 평가 확대 · KB 미등재 인명 음독 자동 생성 · 반자동 완역 파이프라인 구축

# 결론

파인튜닝 없이 프롬프트 + KB 주입으로 실용적 번역 성능 달성 — 평가 방법론 기여까지

**NERinject · BLEU(c) 40.61 (+5.10p) · ETS 0.888 (+13.2pp ETS-B) · KB 등재 정확도 99.4%**

01

**일관성 > 다양성**

번역 도메인에서 Few-shot 예시의 일관성이 다양성보다 중요. 고정 5개 예시가 동적 선택·10개·20개보다 우수.

02

**문체 ↔ 인명 트레이드오프**

Few-shot 단독은 BLEU +3.95p에도 ETS -0.012 하락. KB 사전 주입(NERinject)으로 두 목표를 동시 최적화.

03

**평가 독립성 = 신뢰성**

NER Recall 1.000 vs ETS 0.888 — 0.112 차이가 순환 평가 부풀림. 독립 소스 ETS 설계가 방법론적 기여.

파급 효과 · NERinject 파이프라인 자동화 → 전문 번역가 검토 전 1차 초안 자동 생성 → 완역 목표 시점 2062년 조기 달성 가능

# DAT CAPSTONE
# 최종 발표

## Nabi-Effect Team

### EV 배터리 공급망 리스크는 주가로 전파되는가?

뉴스 감성 × 공급망 지식그래프 × GAT 기반 실증 분석

권가경 · 이소은 · 이종민 · 한지원

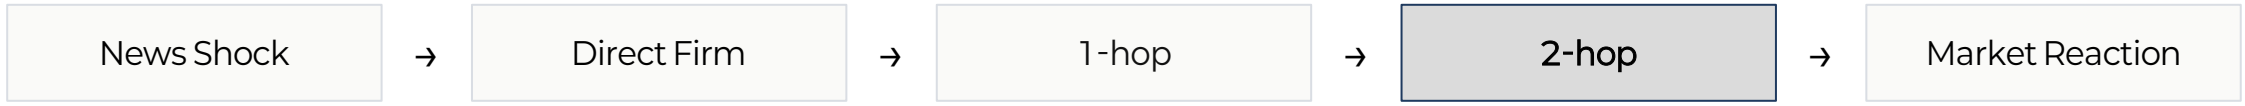
# 공급망 충격은 어디까지 번지는가?

직접 기업보다, 네트워크를 따라 연결된 기업의 반응이 핵심이다.

**Q1 · Direct Effect** 뉴스 이벤트는 직접 기업의 CAR을 움직이는가?

**Q2 · Contagion** 충격은 1-hop, 2-hop 기업으로 전파되는가?

**Q3 · Graph Signal** 공급망 구조는 수익률 방향 예측에 기여하는가?



# End-to-End Analysis Pipeline

News Sentiment × Supply-Chain Knowledge Graph × Graph Attention Network

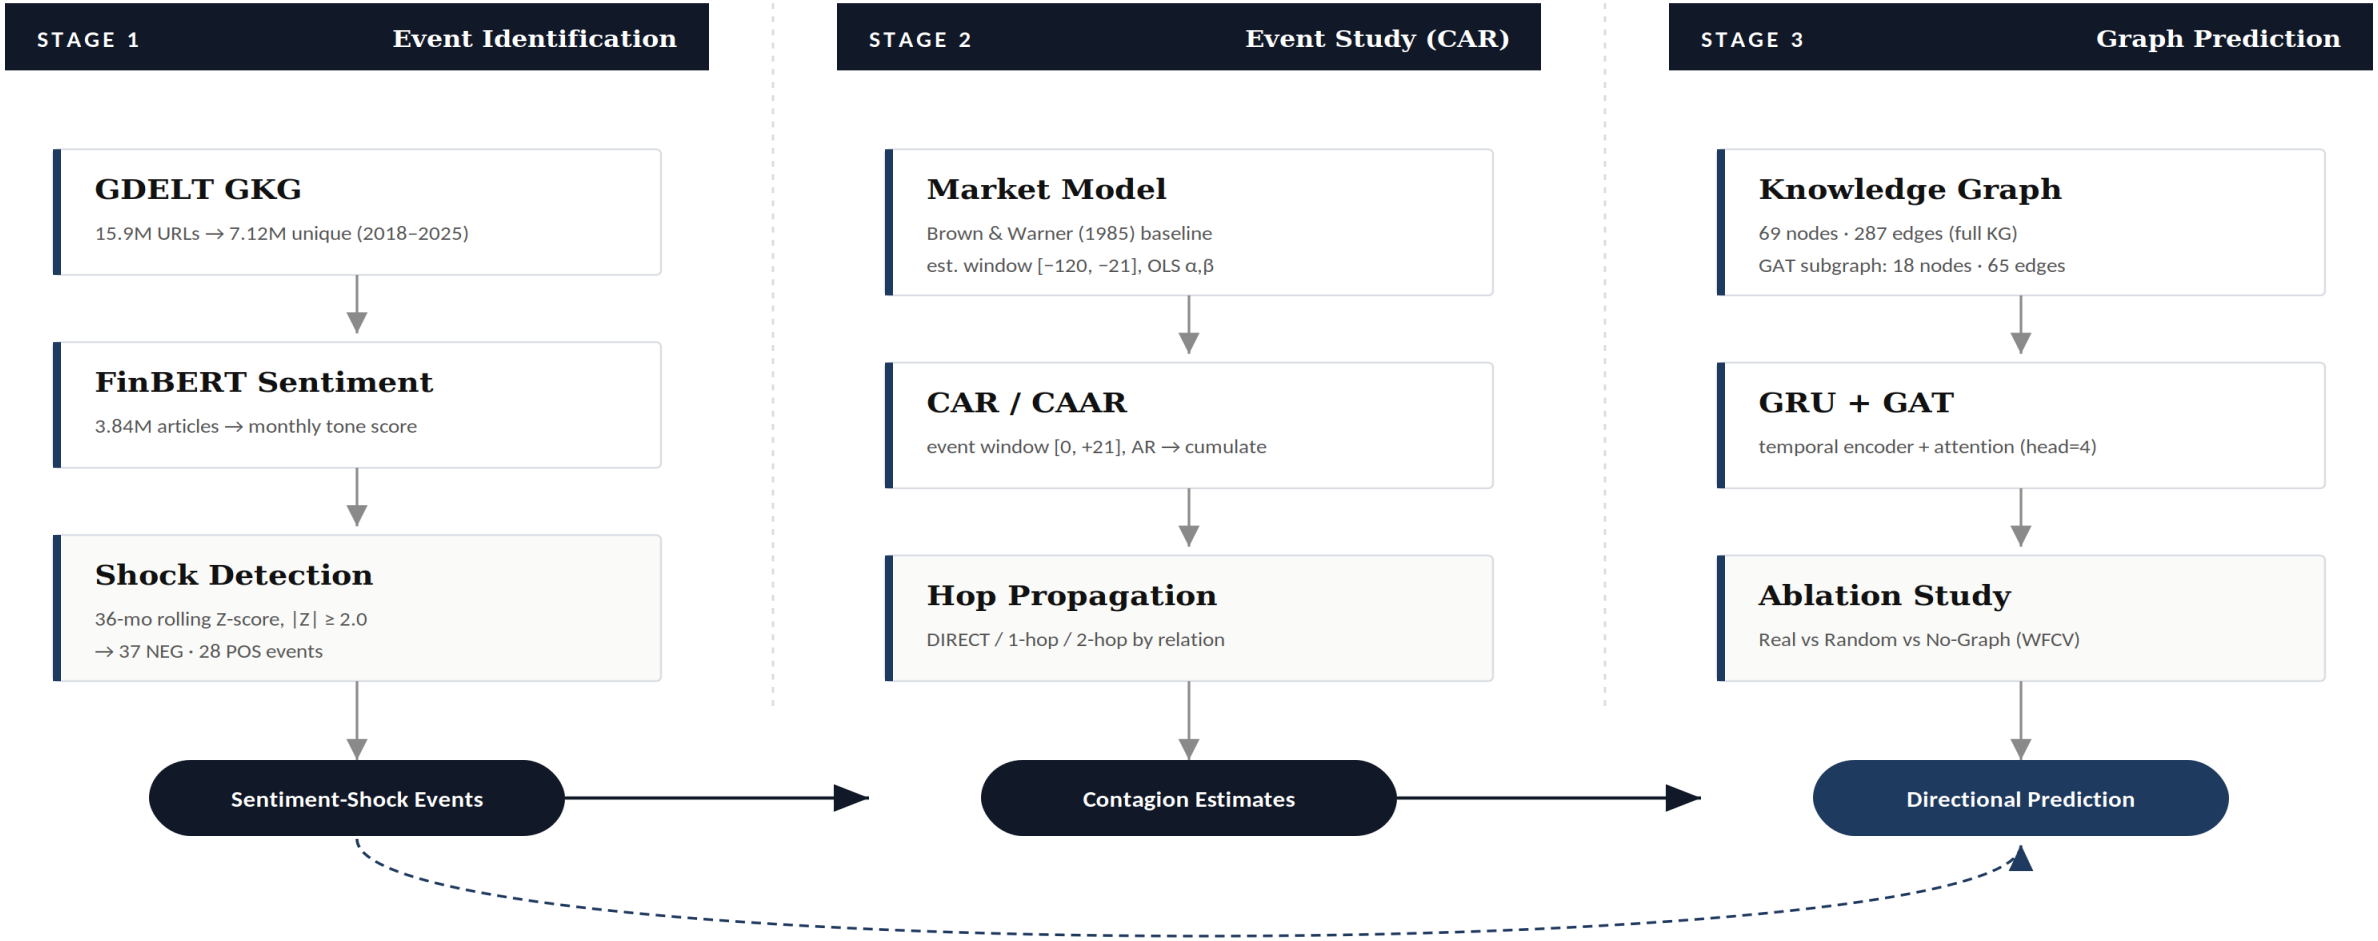
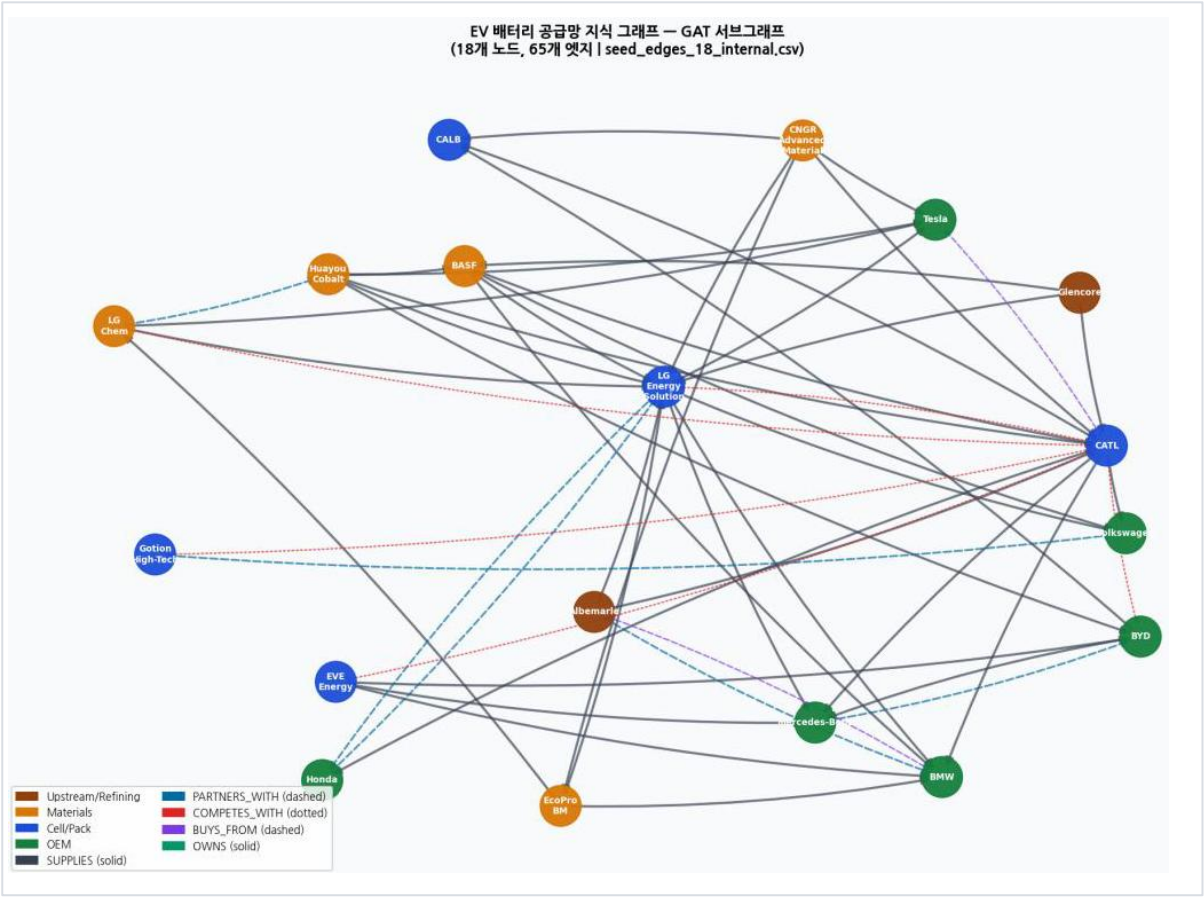



*Figure. Three-stage pipeline: news-based event identification → market-model CAR event study → graph attention prediction. Solid arrows = data flow; dashed = feature feed.*

# 공급망을 그래프로 모델링했다

- 전체 KG: 44 firms + 25 non-firm nodes
- 69 nodes · 287 edges
- GAT subgraph: 18 firms · 65 edges
- Hub · bottleneck 구조가 드러남

> *CATL·BYD act as hubs; upstream mineral firms form bottleneck links.*




*The graph encodes supplier, partner, competitor, and ownership relationships.*

# 직접 효과는 약했지만, 긍정 충격은 유의했다

POS shock

**+3.62%**

p = 0.030 · Significant

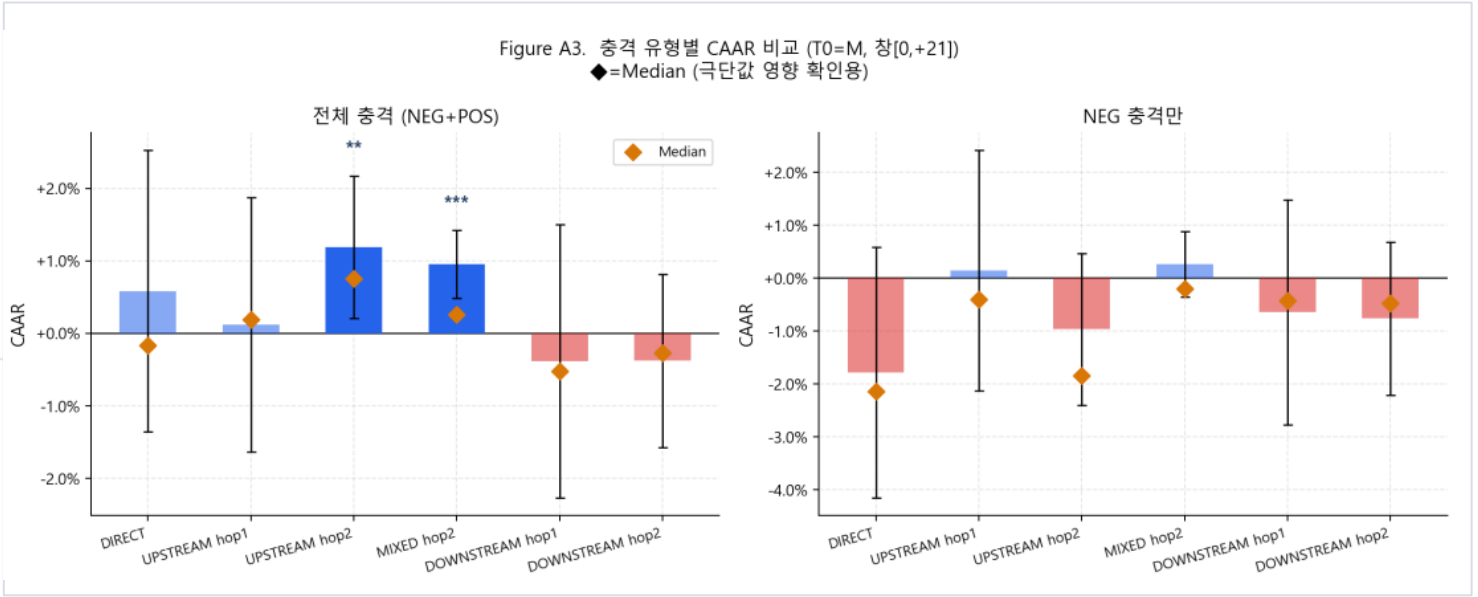
NEG shock

**−1.73%**

p = 0.167 · Not significant

*All direct events: CAAR +0.62%, p = 0.544.*

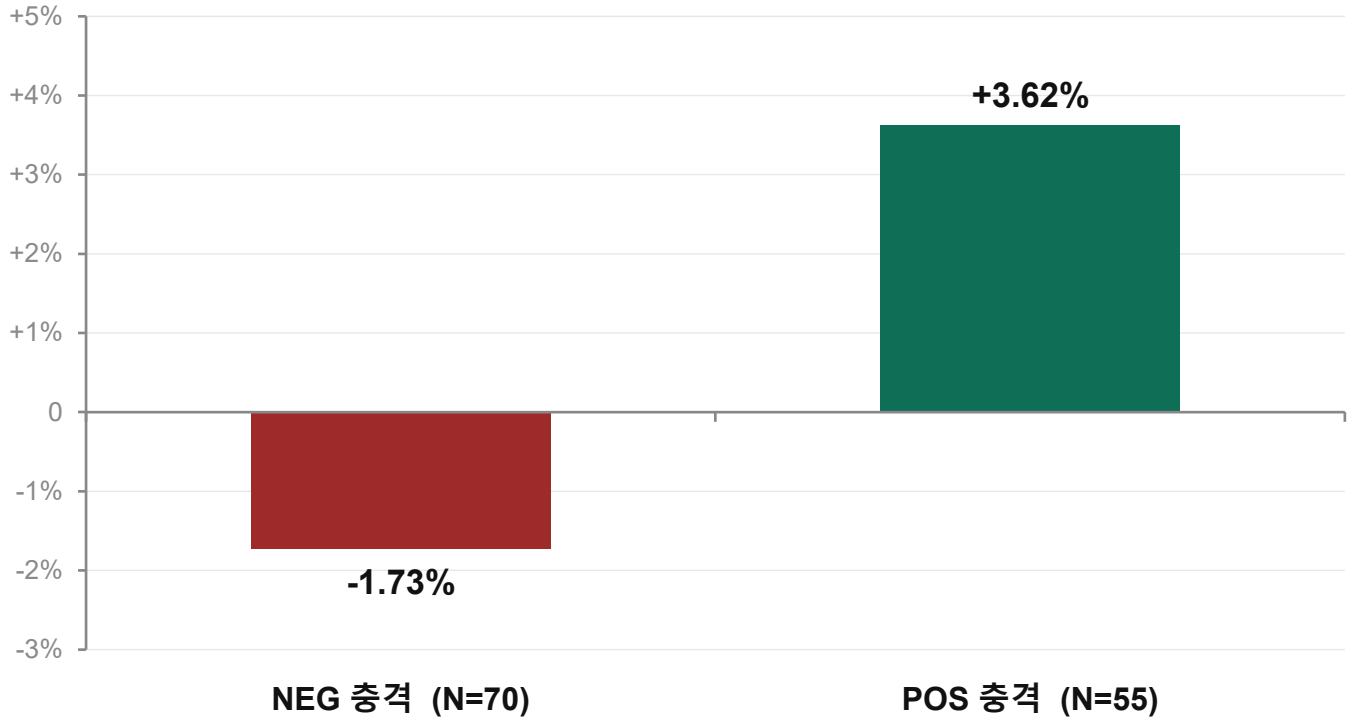
EVIDENCE · REPORT FIGURE




*Positive shocks are priced more clearly than negative shocks.*

# 충격 유형별 직접 반응: POS만 유의했다

이벤트 창 [0,+21] 충격 유형별 CAAR. 부정 충격은 음의 방향이나 비유의, 긍정 충격만 통계적으로 유의하다.




*Recreated from Table 3 values · event window [0,+21]*

POS shock

**+3.62%** p=0.030

Significant — 호재가 빠르게 가격에 반영

NEG shock

**−1.73%** p=0.167

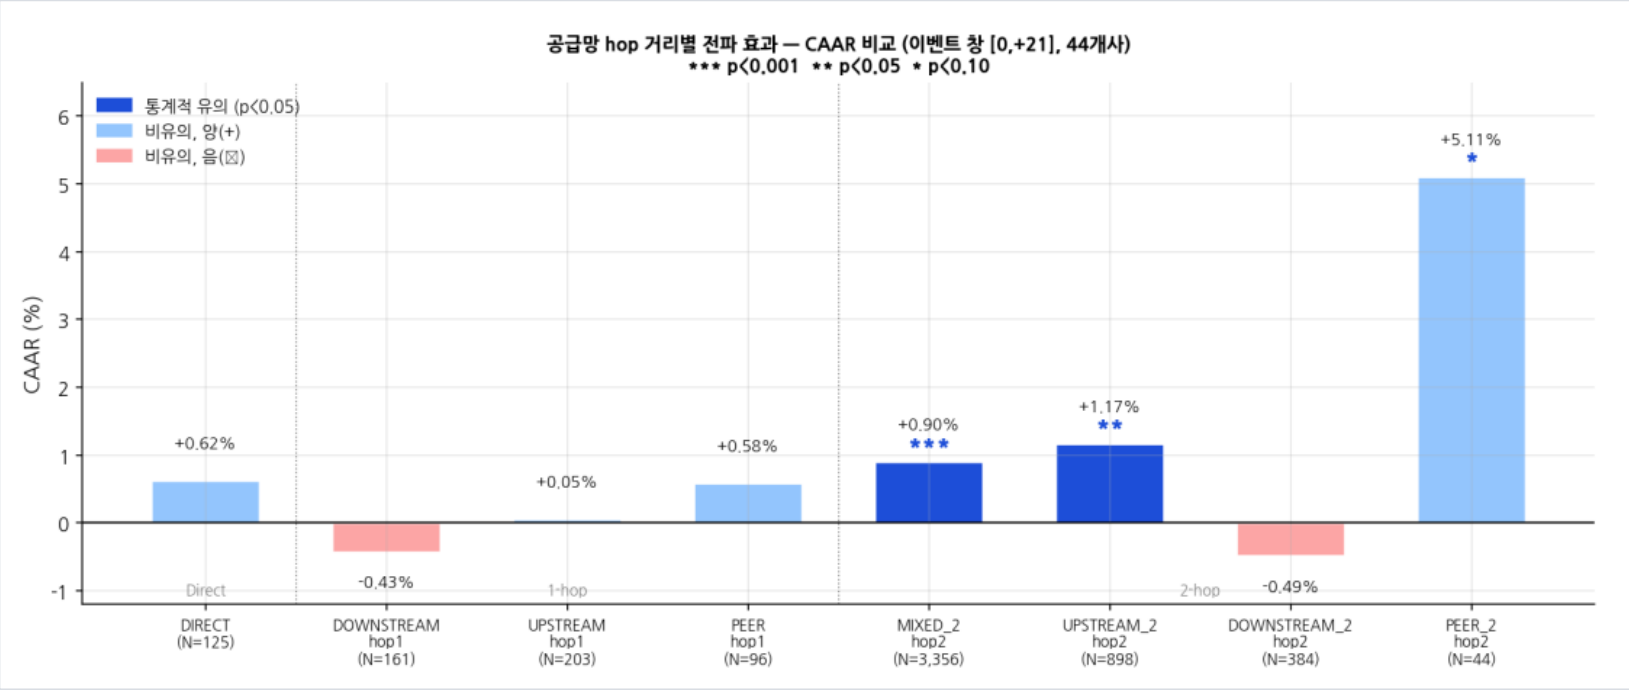
Not significant — 반응 분산이 크고 불확실

> *전체 직접 효과 CAAR +0.62% (p=0.544) — 시장의 정보 비대칭 반영 패턴.*

# 가장 강한 신호는 2-hop에서 나타났다

## 1-hop은 비유의, 2-hop은 유의.

MIXED_2 **+0.90%** p<0.001 UPSTREAM_2 **+1.17%** p=0.022




2-hop signal appears; 1-hop signal does not.

*This supports an information-friction interpretation: markets react more clearly after network propagation.*

# 어떤 연결이 전파 경로가 되는가?

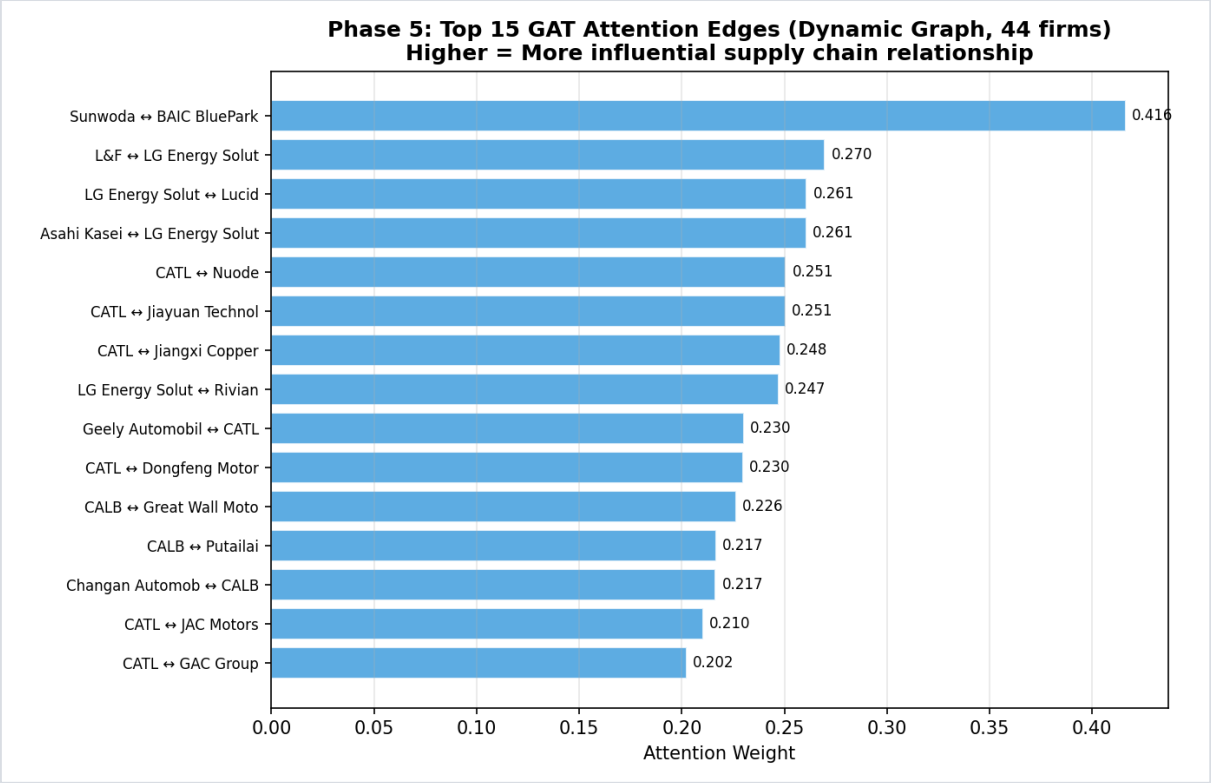
GAT attention weights provide interpretability for supply-chain transmission channels.

1 소재–OEM, 셀–광물 연결에서 높은 attention 관찰

2 중국 공급망 내부 연결이 주요 경로로 부상

3 attention은 예측 시 모델이 중시한 관계를 보여줌

EVIDENCE · REPORT FIGURE



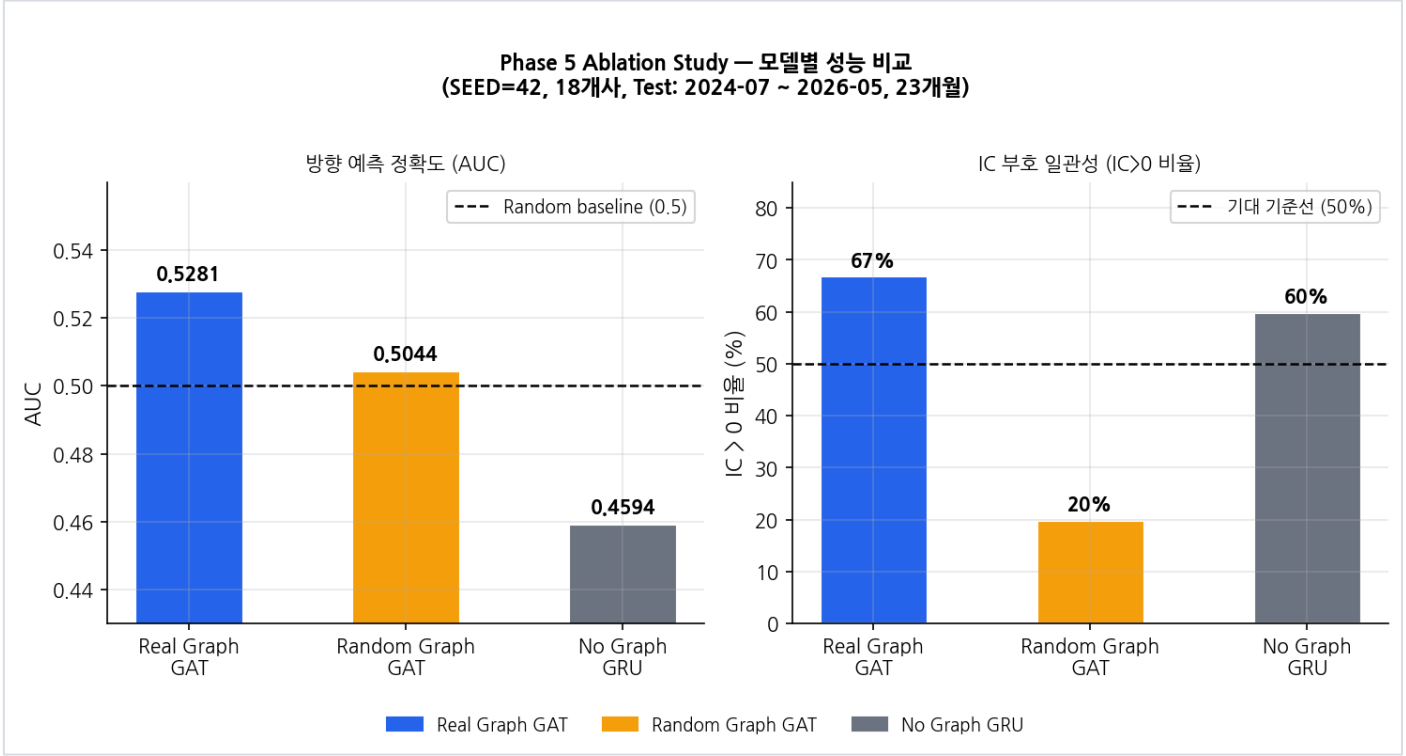

*Attention weights identify likely transmission channels rather than simple correlations.*

# 실제 그래프 구조는 예측 성능을 높였다

| | |
|---|---|
| Real Graph GAT | 0.5281 |
| Random Graph GAT | 0.5044 |
| No Graph GRU | 0.4594 |
| IC>0 ratio (Real) | 67% |

*Exploratory evidence only: permutation test p = 0.398.*

EVIDENCE · REPORT FIGURE




*The real supply-chain topology outperforms random and no-graph baselines.*

# 기여: 뉴스·금융·그래프를 하나의 실증 설계로 연결

01

## Data

GDELT 3.84M 뉴스 기반 이벤트 식별

02

## Empirical Test

CAR 이벤트 스터디로 hop별 전파 검증

03

## Model

GAT Ablation으로 그래프 구조 기여도 검증

**EV 배터리 공급망 리스크를 기업 단위가 아니라 네트워크 단위로 분석했다.**

# 한계점과 향후 보완 방향

표본·검정력의 한계를 인정하고, 고빈도·대규모·동적 모델링으로 확장한다.

## LIMITATIONS

1 **표본 규모**
44개 기업·129건 이벤트 — 클러스터 SE 적용 후 유의성 약화

2 **이벤트 정의**
월별 감성 충격 기반의 날짜 모호성 — 일별 분석으로 개선 가능

3 **검정력**
18개 기업 소규모 네트워크 — permutation p=0.398, GNN 효과 미입증

4 **인과 추론**
상관 기반 분석 — 인과 규명에는 DID 등 설계 보완 필요

## FUTURE WORK

1 **고빈도 분석**
일별 뉴스–주가 분석으로 이벤트 식별력 강화

2 **유니버스 확장**
100개 이상 기업으로 확대 및 GDELT 커버리지 검증

3 **동적 모델링**
Temporal GNN(TGAT·DyRep)으로 동적 엣지 가중치 학습

4 **일반화**
반도체·희토류 등 타 산업으로 방법론 확장

5 **LLM을 이용한 감성분석**

# 공급망 리스크는 네트워크 단위로 읽어야 한다

01 Direct effects are limited, except POS shocks.

02 2-hop contagion is the strongest empirical signal.

03 Real graph structure provides exploratory predictive value.

---

*Risk management should move from firm-level screening to network-level exposure analysis.*

Thank you · Q&A

# HUFS DAT 7th

Data Analysis & Technology



# 감사합니다

Thank you