

# [1주차] 프로젝트 주제 선정 보고서

2026년 8월 9일

00:7 | 배진형 최서린 박서진 강지수

## 1 프로젝트 개요 및 주제 선정 배경

### 1.1 프로젝트명

전자공시 공개일 정렬을 활용한 기업부실 예측모형의 시점 누출 측정 및 사업보고서 텍스트 기반 보완

### 1.2 프로젝트 개요

금융감독원 전자공시시스템(DART) 자료를 활용하여, 상장기업의 부실 발생 여부를 예측하는 기존 연구의 시점 처리를 검증한다. 재무제표는 결산일이 아니라 사업보고서가 실제 접수된 날에 공개되므로, 결산일 기준으로 정렬된 학습 자료에는 예측 시점에 존재하지 않았던 정보가 포함된다. 본 프로젝트는 자료 정렬 조건만 달리한 통제 실험으로 이로 인한 성능 과대추정분을 측정하고, 같은 시점에 이미 공개되어 있던 사업보고서 본문 텍스트로 이를 어느 정도 보완할 수 있는지 확인한다. 최종 결과물은 정렬 조건별 성능 격차의 정량적 측정치와, 국내 선행연구의 시점 처리 현황을 정리한 감사표이다.

### 1.3 연구 질문

- 1.3.1 사업보고서의 실제 공개일을 기준으로 자료를 재정렬할 때, 기존 연구가 보고한 예측 성능은 얼마나 하락하는가.
- 1.3.2 하락분을 예측 시점에 실제로 이용 가능한 텍스트 및 기업 간 유사도 정보로 보완할 수 있는가.
- 1.3.3 기업 간 유사도 그래프를 전체 기간 문서로 한 번에 구성하는 방식 자체가 또 다른 형태의 시점 누출을 발생시키는가.

### 1.4 주제 선정 동기

상장기업의 사업보고서는 결산일로부터 90일 이내에 제출되므로, 12월 결산 법인의 재무제표는 다음 해 3월 말에야 공개된다. 그런데 관리종목 지정 사유의 상당수는 감사의견 거절과 같이 그 사업보고서에서 처음 드러나며, 실제 지정도 3~4월에 집중된다. 예측 대상 사건과 예측에 사용하는 자료가 같은 문서에서 발생하는 구조다.

국내 기업부실 예측 논문 10편을 확인한 결과 자료의 가용 시점을 명시한 논문은 없었으며, 한 논문은 3월에 지정된 기업을 같은 해 재무제표로 예측하여 82.7%의 정확도를 보고했다. 반대로 재무제표의 공시 지연을 인지하고 뉴스·시장 자료로 우회한 연구도 존재한다. 문제를 인지한 연구와 인지하지 못한 관행이 공존하나, 그 격차의 크기를 측정한 사례는 확인되지 않았다. 사전 검증에서 정렬 조건만 바꾸었을 때 0.245의 성능 격차를 확인했으며, 본 프로젝트는 이를 표본과 기간을 확장하여 정식으로 측정한다.

## 2 핵심 목표 및 분석 방향

## 2.1 필요 데이터

2.1.1 DART 전자공시 자료 (금융감독원 전자공시시스템 Open API), 2015~2024년

- 관리종목 지정 및 상장폐지 관련 공시 전수. 예측 대상 라벨로 사용한다.
- 사업보고서 재무제표 및 재무비율 21개. 복제 대상 논문의 변수 구성을 그대로 따른다.
- 각 보고서의 접수일자(recept\_dt). 실험 조건을 구분하는 핵심 필드이다.
- 사업보고서 「II. 사업의 내용」 본문. 전략 서술 문장 추출에 사용한다.

2.1.2 표본은 현재 상장 종목 목록이 아니라 사건 공시에서 출발하여 구성한다. 상장 종목에서 시작하면 이미 상장폐지된 기업이 누락되어 생존편향이 발생한다.

2.1.3 파생변수: 사업보고서 제출 지연일수, 직전 두 보고서 간 전략 서술 변화량, 텍스트 유사도 기준 상위 유사 기업 집합 대비 재무비율 상대값, 유사 기업의 직전 12개월 부실 발생률. 모든 변수는 예측 시점 이전에 공개된 문서만으로 계산한다.

## 2.2 분석 목표 및 평가 지표

2.2.1 자료 정렬 조건만 달리한 네 개의 실험을 구성한다. A는 결산일 기준 정렬로 기존 논문을 복제하고, B는 접수일 기준으로 정렬하며, C는 B에 텍스트 및 유사도 기반 변수를 추가한다. D는 유사도 그래프를 전체 기간 문서로 구성한 경우와 예측 시점까지의 문서만으로 구성한 경우를 비교한다.

2.2.2 A-B를 시점 누출로 인한 성능 과대추정분, B-C를 보완분, D의 두 조건 간 차이를 그래프 구성 단계의 누출분으로 정의한다. 부실 기업 비율이 낮으므로 정확도는 사용하지 않고 AUC와 소수 클래스 F1을 주 지표로 삼는다.

2.2.3 A-B 격차가 복제 대상 논문이 사용한 모델 6종 전반에서 일관되게 나타나는지 확인한다. 모델 종류와 무관하게 나타나야 원인이 알고리즘이 아니라 자료 정렬에 있음이 성립한다.

2.2.4 예측 시점을 월 단위로 이동시켜, 재무제표 공개 직전에 격차가 최대가 되고 공개 직후 감소하는 패턴이 나타나는지 검증한다. 아울러 연도와 시장(KOSPI/KOSDAQ)을 달리하여 반복한다.

2.2.5 실험 C는 변수군을 블록으로 나누어 각각의 기여도를 개별 보고한다. 사건 표본 수가 제한적이므로 전체 변수를 한 번에 투입하면 차원 증가로 인한 성능 저하와 정보 부족을 구분할 수 없다. B-C가 유의하지 않게 나오는 경우에도 이는 실패가 아니라 측정 결과로 보고한다.

## 3 기대 효과 및 활용 방안

### 3.1 학술적 가치

미국 연구에서 널리 사용되는 Compustat에는 재무제표의 실제 공개일이 기록되지 않아 통상 일괄적인 3개월 지연을 가정한다. 기업별 실제 접수일자가 기록되는 DART 환경에서는 이 근사 없이 정렬이 가능하며, 본 프로젝트는 이 조건을 이용해 누출의 크기를 직접 측정한다. 또한 재무비율뿐 아니라 기업 간 관계를 텍스트로 추정하는 단계에서도 동일한 문제가 발생함을 함께 제시한다. 사업 서술 텍스트로 기

업 간 유사도를 구성하는 접근은 Hoberg and Phillips(2016)의 미국 사례가 있으나 국내 적용은 확인되지 않았다.

### 3.2 실무적 활용

부실 예측 모형을 실제로 운용할 때 어느 시점에 어떤 자료까지 사용할 수 있는지에 대한 설계 기준을 제공한다. 보고된 성능 가운데 실제 운용에서 재현되지 않는 부분을 사전에 가늠할 수 있으며, 재무제표 공개 이전 구간에서 대체 가능한 정보원의 유효성을 함께 제시한다.

### 3.3 기술적 역량

본 프로젝트를 통해 팀원들은 DART Open API를 이용한 대규모 공시 수집과 상장폐지 기업을 포함한 표본 구성, 시점 정렬 데이터셋 설계와 정보 누수 방지, LLM을 이용한 문장 추출 및 Sentence-BERT 임베딩 기반 유사도 계산, 통제 실험 설계와 모델 간 비교 검증 기법을 습득한다.

## 4 회의 사진

