

[2 주차] 선행 연구 조사 보고서

2026 년 8 월 16 일

00:7 | 배진형 최서린 박서진 강지수

1. 프로젝트 조사 개요 및 방법

1.1 프로젝트명

전자공시 공개일 정렬을 활용한 기업부실 예측모형의 시점 누출 측정 및 사업보고서 텍스트 기반 보완

1.2 프로젝트 개요

금융감독원 전자공시시스템(DART) 자료를 이용하여 국내 기업부실 예측 연구의 시점 처리를 검증한다. 재무제표는 결산일이 아니라 사업보고서가 실제 접수된 날 이후에 이용할 수 있으므로, 결산일 기준으로 정렬된 학습자료에는 예측 시점에 존재하지 않던 정보가 포함된다. 본 프로젝트는 자료 정렬 조건만 달리한 통제 실험으로 이로 인한 성능 과대추정분을 측정하고 ($A \rightarrow B$), 같은 시점에 이미 공개되어 있던 사업보고서 텍스트와 기업 간 유사도 정보를 이를 어느 정도 회복할 수 있는지 확인한다($B \rightarrow C$). 나아가 유사도 그래프를 구성하는 단계 자체가 또 다른 누출 경로가 되는지도 함께 검증한다(D).

1.3 주제 선정 동기

사업보고서는 결산일로부터 90 일 이내에 제출되므로 12 월 결산 법인의 재무제표는 다음 해 3 월 말에야 공개된다. 그런데 관리종목 지정 사유의 상당수는 감사의견 거절과 같이 그 사업보고서에서 처음 드러나며, 실제 지정도 3~4 월에 집중된다. 예측 대상 사건과 예측에 사용하는 자료가 같은 문서에서 발생하는 구조다. 국내 기업부실 예측 논문 10 편을 확인한 결과 자료의 가용 시점을 명시한 논문은 없었고, 사전 파일럿에서 정렬 조건만 바꾸었을 때 PR-AUC 기준 0.245 의 격차를 확인했다. 문제를 지적인 연구는 존재하나 그 격차의 크기를 국내 자료로 측정할 사례는 확인되지 않았다.

1.4 선행연구 조사 방법

검토를 네 갈래로 나누었다. ① 복제 대상: 국내 관리종목 지정 예측 연구 가운데 재무데이터만으로 다수 모델을 비교한 논문. ② 시점 누출의 측정 방법론: 기존 연구를 복제한 뒤 누출을 제거하여 성능 변화를 측정할 사례와, 누출을 유형화한 방법론 문헌. ③ 텍스트를 통한 보완: 연차보고서·사업보고서 텍스트를 부실예측에 결합한 연구. ④ 공시 시점과 기업 간 관계: 공시의 시점 자체를 신호로 다룬 연구와 텍스트로 기업 간 관계를 구성한 연구. 각 문헌은 「무엇을 보였는가 → 무엇이 비어 있는가 → 우리 실험의 어느 칸에 대응하는가」의 순서로 정리하였다.

2. 주요 선행 연구 및 사례 분석

2.1 복제 대상 — 윤양현·김태경·김수영(2022)

KOSDAQ 관리종목 지정 기업과 비지정 기업의 재무데이터를 표본으로, 로지스틱 회귀분석·의사결정나무·서포트 벡터 머신·소프트 보팅·랜덤 포레스트·LightGBM 여섯 모형의 예측 성능을 비교하였다. LightGBM 이 분류 정확도 82.73%로 가장 우수했고 의사결정나무가 71.94%로 가장 낮았으며, 앙상블 계열이 단일 학습 모형을 대체로 상회하였다.

한계점 및 시사점: 재무비율에 예측 시점에 실제로 이용 가능했는지를 통제하는 절차가 제시되지 않는다. 관리종목 지정이 3~4 월에 집중되고 같은 시기에 공개되는 사업보고서 재무제표를 입력으로 사용하면, 모형이 학습하는 것은 부실의 전조가 아니라 부실의 결과일 수 있다. 부실 표본이 희소한 자료에서 정확도를 주 지표로 삼은 점도 한계다. 본 프로젝트는 이 논문의 변수 구성과 모델 6 종을 그대로 재현하여 실험 A 의 기준선으로 삼되, 평가지표는 AUC 와 소수 클래스 F1 으로 교체한다.

2.2 시점 누출의 측정 방법론 — Zhang, Zhu & Linnainmaa(2025); Kapoor & Narayanan(2023)

Zhang 외(2025)는 랜덤 포레스트로 애널리스트 예측오차를 추정할 선행연구를 복제한 뒤, 75 개 입력변수 가운데 하나가 예측 시점에는 알 수 없는 미래 실현이익이었음을 밝혔다. 이 변수 하나만 예측일 기준으로 이용 가능한 값으로 교체하자 월간 알파가 1.54%에서 0.41%로 줄어 통계적 유의성을 잃었고, 2 년 후 이익 예측의 정확도 개선분 가운데 약 4 분의 3 이 이 편익에서 비롯된 것으로 보고되었다. 저자들은 나아가 $h+1$ 기 예측치가 h 기 실현치를 설명하는지 보는 회귀를 통해 편익의 소재를 간접 추론이 아니라 직접 지목하였다.

Kapoor & Narayanan(2023)은 17 개 분야 294 편에서 누출이 확인됨을 보이고 이를 여덟 가지 유형으로 분류했으며, 내전 발생 예측 사례에서 누출을 바로잡자 머신러닝이 전통적 회귀모형보다 우수하다는 결론이 사라짐을 보였다.

한계점 및 시사점: 두 연구는 대상 분야가 각각 자산가격과 정치학으로 우리와 다르다. Zhang 외는 미국 자료를 사용하므로 재무자료의 실제 공개일을 관측하지 못하고 특정 변수의 정의 오류를 지목하는 방식이며, Kapoor & Narayanan 은 유형화와 점검표 제안에 무게가 있어 개별 분야에서 누출의 크기가 얼마인지는 측정하지 않는다. 본 프로젝트는 두 연구가 공유하는 「복제 → 누출 제거 → 성능 변화 측정」의 3 단 구조를 국내 부실예측에 적용하되, 단일 변수의 오류가 아니라 자료 정렬 규칙 전체를 처치 변수로 삼는다.

2.3 텍스트를 통한 보완 — Chen et al.(2023); Hajek & Munk(2024); Mai et al.(2019)

Chen 외(2023)는 1994~2018 년 미국 기업을 대상으로 연차보고서의 가독성·어조 기반 변수를 재무비율에 추가했을 때 로지스틱 회귀분석·랜덤 포레스트·XGBoost·SVM 네 모형의 정확도·F1·AUC 가 전반적으로 개선되며, 특히 XGBoost 와 랜덤 포레스트에서 개선폭이 컸다고 보고하였다. Hajek & Munk(2024)는 주요 글로벌 거래소에 상장된 2,545 개 기업의 연차보고서 중 위험 관련 서술에 BERT 기반 문맥 임베딩을 적용해 재무 감성과 토픽을 추출하고, 사전 기반 및 비문맥 임베딩 방식보다 우수한 재무곤경 예측 성능을 얻었다. Mai 외(2019)는 11,827 개 미국 상장사의 MD&A 를 평균 임베딩 신경망으로 처리하여 텍스트만으로 AUC 0.784, 재무·시장 변수와 결합해 0.856 을 보고하였다.

한계점 및 시사점: 세 연구 모두 「텍스트를 더하면 예측이 좋아지는가」를 묻지, 재무정보가 실제로 공개된 시점을 기준으로 그 개선분을 재평가하지는 않는다. 특히 Mai 외(2019)는 회계 항목에 일괄 4개월 지연을 가정하는데, 이는 기업별 실제 공개일이 기록되지 않는 Compustat 환경에서 불가피한 근사다. 본 프로젝트는 텍스트의 예측 가치를 처음부터 예측 시점 기준 (point-in-time) 조건에서 평가하며, 보고서별 접수일자를 사용해 이 근사 없이 정렬한다. 문장 임베딩을 사용하는 방법론적 근거는 Hajek & Munk(2024)에서 가져오되, 우리는 이를 감성 추출이 아니라 기업 간 유사도 산출에 사용한다.

2.4 공시 시점과 비재무 신호 — 어균선·이건창(2022); 김준현(2018)

어균선·이건창(2022)은 재무비율에 CEO 얼굴의 가로·세로 비율(fwhr)과 사업보고서에서 LDA로 추출한 토픽 요인을 함께 투입하고, Relief.F로 변수를 선택한 뒤 DECORATE 앙상블로 결합한 모형이 가장 높은 성과를 보였다고 보고하였다. 김준현(2018)은 분기 잠정이익의 공정공시를 대상으로, 비기대이익이 낮을수록 잠정이익을 공시할 가능성이 낮아지고 공시하더라도 시점이 늦어지며, 그러한 공시전략을 사용한 경우 이익정보에 대한 시장반응도 상대적으로 낮게 나타남을 보였다.

한계점 및 시사점: 어균선·이건창(2022)은 변수군을 하나씩 제거한 절제 비교가 없어 재무·얼굴·텍스트 가운데 무엇이 성능을 끌어올렸는지 분리되지 않으며, 사업보고서의 결산연도만 맞추고 실제 접수일을 맞추지 않으면 예측 시점에 없던 정보가 유입된다. 본 프로젝트는 외형 정보 대신 예측 시점에 이미 공개되어 있던 문장에 집중하고, 실험 C에서 변수군을 블록으로 나누어 증분 기여를 개별 보고한다. 김준현(2018)은 부실예측 모형이 아니라 공시 행태 자체를 설명하는 연구이지만, 제출이 늦어졌다는 사실 자체에 경영자의 선택과 부정적 정보가 반영될 수 있음을 보여준다. 이는 제출 지연일수를 단순한 행정상 날짜 차이가 아니라 비재무 신호로 사용하는 실험 C 파생변수의 설계 근거가 된다.

2.5 텍스트 기반 기업 간 관계 — Hoberg & Phillips(2016)

10-K의 제품·사업 설명 텍스트로 기업 쌍의 유사도를 연도별로 측정하여, 각 기업이 서로 다른 경쟁기업 집합을 갖는 텍스트 기반 산업분류(TNIC)를 제시하였다. 고정된 SIC·NAICS 분류와 달리 경쟁관계가 매년 갱신되며, 경영진이 직접 언급하는 경쟁 강도나 산업 충격 이후의 경쟁기업 변화를 기존 분류보다 잘 설명하였다.

한계점 및 시사점: 이 연구의 목적은 산업분류와 제품시장 경쟁 분석이지 기업부실 예측이 아니며, 국내 적용 사례도 확인되지 않는다. 더 중요한 점은 유사도 그래프를 전체 기간 코퍼스로 한 번에 구성할 경우 예측 시점 이후의 문서가 그래프의 이웃 구조에 반영되어, 입력변수 수준이 아니라 그래프 구성 단계에서 누출이 발생할 수 있다는 것이다. 본 프로젝트는 이를 실험 D로 분리하여 측정한다.

2.6 선행연구와 실험 설계의 대응

실험	정렬·구성 조건	대응 선행연구	측정 대상
A	결산일 기준 정렬(관행 재현)	윤양현 외(2022)	비교 기준선
B	DART 접수일 기준 정렬	Zhang 외(2025), Kapoor & Narayanan(2023)	A-B = 시점 누출로 인한 성능 과대추정분
C	B + 사업보고서 텍스트·공시지연·유사기업 변수	Chen 외(2023), Hajek & Munk(2024), Mai 외(2019), 어균선·이건창(2022), 김준현(2018)	B-C = 동일 시점 가용 정보로 회복되는 분
D	전 기간 코퍼스 그래프 vs 확장 윈도우 그래프	Hoberg & Phillips(2016)	그래프 구성 단계에서 발생하는 누출분

3. 프로젝트의 차별성

3.1 지적에서 측정으로. 기존 문헌은 누출을 유형으로 분류하거나(Kapoor & Narayanan, 2023) 특정 변수의 정의 오류를 지목한다(Zhang 외, 2025). 본 프로젝트는 자료 정렬 규칙만을 처치로 두고 나머지 조건을 고정한 통제 실험으로, 국내 관리종목 지정 예측에서 누출로 인한 과대추정분의 크기를 수치로 제시한다. 이 격차가 복제 대상 논문의 모델 6종 전반에서 일관되게 나타나야 원인이 알고리즘이 아니라 자료 정렬에 있음이 성립하며, 예측 시점을 월 단위로 이동시켜 사업보고서 공개 직전에 격차가 최대가 되고 직후 감소하는 패턴을 위약 검정으로 확인한다.

3.2 근사가 아닌 실제 공개일. 미국 연구의 표준 자료원인 Compustat에는 재무제표의 실제 공개일이 기록되지 않아 일괄적인 지연을 가정하는 것이 관례이며, Mai 외(2019)의 4개월 lag가 그 예다. DART는 보고서별 접수일자(rcept_dt)를 제공하므로 이 근사 없이 정렬이 가능하다. 미국 자료로는 수행하기 어려운 측정이라는 점이 본 프로젝트의 자료상 비교우위다.

3.3 누출 검증 층위의 확장. 기존 논의는 입력변수 수준의 누출에 머문다. 본 프로젝트는 텍스트로 기업 간 관계를 추정하는 단계에서도 같은 문제가 발생함을 함께 제시한다. Hoberg & Phillips(2016)의 유사도 구성을 국내 사업보고서 「II. 사업의 내용」에 적용하되, 유사기업의 재무비율 상대값과 직전 12개월 부실 발생률을 예측변수로 확장하고, 그래프를 전체 기간 문서로 구성한 경우와 예측 시점까지의 문서만으로 구성한 경우를 나누어 비교한다.

3.4 보고 원칙. 부실 표본이 희소하므로 정확도 대신 AUC와 소수 클래스 F1을 주 지표로 삼고, 실험 C는 변수군을 블록으로 나누어 각각의 기여도를 개별 보고한다. B-C가 유의하지 않게 나오는 경우에도 이는 실패가 아니라 측정 결과로 보고하며, C가 A를 상회하는 결과가 관측되면 축하에 앞서 C의 전 변수에 대한 시점 감사를 먼저 수행한다.

참고문헌

윤양현·김태경·김수영(2022), 「머신러닝 기반 KOSDAQ 시장의 관리종목 지정 예측 연구: 재무적 데이터를 중심으로」, 『벤처창업연구』, 17(1), 229-249. DOI: 10.16972/apjbve.17.1.202202.229

- 어균선·이건창(2022), 「재무적 부실예측을 위한 CEO 의 fWHR 과 사업보고서 LDA 토픽요인 통합: 데코레이트 앙상블을 중심으로」, 『정보과학회 컴퓨팅의 실제 논문지』, 28(12), 573-586. DOI: 10.5626/KTCP.2022.28.12.573
- 김준현(2018), 「잠정이익 공정공시에 대한 기업의 전략적 공시 행태」, 『회계저널』, 27(6), 29-60. DOI: 10.24056/KAJ.2018.09.002
- Chen, T.-K., Liao, H.-H., Chen, G.-D., Kang, W.-H., & Lin, Y.-C. (2023). Bankruptcy prediction using machine learning models with the text-based communicative value of annual reports. *Expert Systems with Applications*, 233, 120714. DOI: 10.1016/j.eswa.2023.120714
- Hajek, P., & Munk, M. (2024). Corporate financial distress prediction using the risk-related information content of annual reports. *Information Processing & Management*, 61(5), 103820. DOI: 10.1016/j.ipm.2024.103820
- Hoberg, G., & Phillips, G. (2016). Text-based network industries and endogenous product differentiation. *Journal of Political Economy*, 124(5), 1423-1465. DOI: 10.1086/688176
- Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9), 100804. DOI: 10.1016/j.patter.2023.100804
- Mai, F., Tian, S., Lee, C., & Ma, L. (2019). Deep learning models for bankruptcy prediction using textual disclosures. *European Journal of Operational Research*, 274(2), 743-758. DOI: 10.1016/j.ejor.2018.10.024
- Zhang, Y., Zhu, Y., & Linnainmaa, J. T. (2025). Man versus machine learning revisited. *The Review of Financial Studies*, 38(12), 3768-3790. DOI: 10.1093/rfs/hhaf066

4. 회의 사진

