

[3 주차] 방학 스터디 최종 보고서

전자공시 공개일 정렬을 활용한 기업부실 예측모형의 시점 누출 측정

2026 년 8 월 23 일 | 00:7 | 배진형 · 최서린 · 박서진 · 강지수

1. 주요 결과물 요약

1.1 데이터 개요 및 인사이트

방학 기간 동안 파일럿 검증을 마치고 본 수집까지 완료했다. 수집은 전량 DART Open API 와 KRX KIND 에서 직접 받았으며, 상용 데이터베이스는 쓰지 않았다.

표 1. 수집 현황 (KOSDAQ, 2015~2024)

자료	파일럿	본 수집
라벨(사건)	DART 사유발생 105 건 / 84 개사	KIND 확정 지정 523 건 / 424 개사
보고서 접수일	사업보고서 8,264 건	사업·반기·분기 68,678 건 / 1,802 개사
재무비율	1,806 건 / 416 개사	11,953 건 / 1,737 개사
변수 결측률	1.2% 이하	3.6% 이하

라벨은 5 배, 재무비율은 6.6 배로 늘었다. 조회 실패 33.7%는 상장 전·폐지 후 구간이며, 사건기업의 85%가 재무비율을 갖는다.

인사이트 1 — 사건은 재무제표가 공개되는 달에 몰린다. 관리종목 지정 523 건의 최빈월은 3 월(224 건)이고 1~4 월에 62.0%가 몰린다. 3 월은 12 월 결산 법인의 사업보고서가 공개되는 달이다. 맞히려는 사건과 예측에 쓰는 자료가 같은 시기·같은 문서에서 나온다는 이 연구의 전제가 직접 확인된다.




그림 1. 사건 발생 월별 분포(파일럿 라벨 = DART 사유발생 공시 105 건). 확정 지정 라벨 523 건에서도 같은 편중이 나타난다 — 최빈월 3 월(224 건), 1~4 월 62.0%.

인사이트 2 — 공개일은 기업마다 다르며, 일괄 가정은 크게 틀린다. 같은 사업연도라도 최초 제출과 최종 제출이 수개월 벌어진다(FY2022: 2 월 28 일 ~ 9 월 4 일). 실물 확인에서 표본 10 곳 중 9 곳(90%)이 "모두 3 월 31 일에 공개한다"는 가정과 어긋났고, 평균 15 일·최대 52 일 차이가 났다. 가장 이른 곳과 늦은 곳은 75 일 벌어졌다. 미국 연구의 표준 자료원인 Compustat 에는 실제 공개일이 없어 일괄 지연을 가정하는 것이 관례인데, DART 는 이 근사가 필요 없다.

인사이트 3 — 지정 사유의 상당수가 재무제표에서 유래한다. 표본 10 건을 정밀 확인하면 80%, 전수 523 건을 공시 제목만으로 분류하면 35%다. 후자가 보수적 추정치이며 두 값을 함께 제시한다.

1.2 활용 모델 및 고도화 계획

모델은 성능 경쟁의 대상이 아니라 비교를 공정하게 만드는 통제 장치다. 복제 대상 논문(윤양현 외, 2022)이 사용한 6 종을 그대로 쓰며, 파일럿에서는 그중 로지스틱 회귀와 LightGBM 2 종만 축소 적용했다. 6 종 전부에서 격차가 나타나야 원인이 알고리즘이 아니라 자료 정렬에 있음이 성립한다.

실험 설계 — 정렬 조건 하나만 바꾼다.

	실험 A (관행)	실험 B (시점 정합)
정렬 기준	결산일	접수일(rcept_dt)
T=2 월 1 일에 쓰는 자료	FY(Y-1) — 아직 미공개	T 이전에 실제 공개된 최신 보고서
표본·변수·모델·분할·지표	← 완전 동일 →	

표 2. 예측 시점별 PR-AUC 격차 (A-B, LightGBM)

예측 시점	파일럿 라벨	KIND 라벨
1 월	+0.206	+0.306
2 월	+0.245	+0.306
3 월	+0.086	+0.308

예측 시점	파일럿 라벨	KIND 라벨
4 월 (사업보고서 공개 후)	-0.004	-0.041
5 월 이후	~0.000	~0.000

로지스틱 회귀도 같은 방향이다(1~3 월 +0.188~0.222, 4 월 이후 0).




그림 2. 예측 시점별 A-B 격차(파일럿 라벨·표본, 로지스틱 vs LightGBM). 확정 지정 라벨 재측정치는 표 2 참조.

격차는 사업보고서가 공개되는 4 월을 기점으로 소멸한다. 4 월 이후에는 A 와 B 가 같은 자료를 보게 되므로 당연한 결과인데, 바로 그 당연함이 증거다. 표본·변수·모델이 원인이라면 4 월 이후에도 격차가 남아야 한다. 두 실험의 유일한 차이가 정렬 기준뿐임을 보이는 위약(placebo) 검사이기도 하다. 라벨을 교체한 뒤에는 격차가 커졌고 패턴도 깨끗해졌다. 파일럿에서는 3 월 격차가 0.086 으로 겨우 이상 신호로 기록했으나, KIND 라벨에서는 1~3 월이 모두 0.306 대로 평평하다. KIND 라벨은 사건이 3 월에 몰려 있어 3 월 1 일 기준으로도 앞에 사건이 남아 있기 때문이다.

조건 명시. 표 2 의 재무비율은 아직 파일럿 표본(416 개사)이며 평가 구간 사건은 50 건이다. 확대 표본(1,737 개사)으로 재측정할 예정이다. 또한 실험 B 는 현재 사업보고서만 사용하므로 이 격차는 상한값이다(3.2 절 ③).

고도화 방향. 파일럿에서 이미 복잡한 모델일수록 누출 정보를 더 흡수하는 현상이 관측됐다(LightGBM 격차가 로지스틱의 약 4 배). 본 학기에는 6 종 전체로 확대해 이 경향이 일관되는지 확인하고, 부트스트랩으로 신뢰구간을 산출한다.

2. 이론적 배경 및 심화 학습

2.1 시점 누출의 측정 방법론

Zhang, Zhu & Linnainmaa(2025)는 랜덤 포레스트로 애널리스트 예측오차를 추정 한 선행연구를 복제한 뒤, 75 개 입력변수 중 하나가 예측 시점에는 알 수 없는 미래 실현이익이었음을 밝혔다. 그 변수 하나만 예측일 기준 값으로 교체하자 월간 알파가 1.54%에서 0.41%로 줄어 유의성을 잃었다. Kapoor & Narayanan(2023)은 17 개 분야 294 편에서 누출을 확인하고 여덟 유형으로 분류했으며, 내전 발생 예측에서 누출을 바로잡자 머신러닝의 우위가 사라짐을 보였다. 국내에서는 노성호·이상호(2025, 자본시장연구원)가 거래정지 기간에 공시된 재무제표가 look-ahead bias 에 노출된다고 명시적으로 지목하고, K-fold 를 배제한 rolling-window 학습과 결산일 1 년 창 라벨 식별로 이를 차단했다.

우리가 가져온 것은 「복제 → 누출 제거 → 성능 변화 측정」 의 3 단 구조다. 다르게 한 것은 두 가지다. 단일 변수의 정의 오류가 아니라 자료 정렬 규칙 전체를 처치 변수로 삼는다. 그리고 노성호·이상호(2025)가 규칙을 지킨 것과 달리, 지키지 않았을 때의 격차를 쟀다. 정렬 기준도 결산일 1 년 창 근사가 아니라 기업별 접수일자를 쓴다.

2.2 선행연구 시점처리 감사

국내 실증연구 5 편(2020~2025)의 원문을 직접 확인해 자료 가용 시점 처리를 표로 정리했다. 5 편 중 3 편이 2025 년 발표작이다.

논문	쓴 재무제표	공개 시점 언급
엄하늘 외 (2020)	동일 연도	× (무작위 70/30 분할까지)
윤양현 외 (2022)	지정 당해 연도	×
권태연·전새봄 (2025)	?	구조 상이(라벨이 재무제표 이후)
노시현·한희준 (2025)	동일 연도	×
노성호·이상호 (2025)	결산일 재무제표만	◎ 명시 + 설계 반영

관행은 현재진행형이다. 2022 년과 2025 년 두 편이 사건 당해 연도 재무제표를 입력으로 쓰며, 각각 "해당 연도", "종속변수와 설명변수의 시점은 동일하다"고 본문에 적고 있다. **또한 실험 A 는 인위적 설정이 아니다.** 같은 대상(KOSDAQ 관리종목)을 두고 윤양현 외(2022)는 지정 당해, 신동인·곽기영(2018)은 지정 전연도를 썼다. 우리 실험은 현존하는 두 관행의 대조다.

2.3 평가지표 — 왜 정확도가 아닌가

사건 비율이 5% 내외인 불균형 문제다. 복제 대상 논문이 주 지표로 삼은 정확도 82.73%는 전부 음성으로 찍어도 94%가 나오는 구조에서 의미가 약하다. 노성호·이상호(2025)는 같은 모형에서 ACC 99%대와 Balanced Accuracy 0.5874, F1 0.1935 를 함께 보고해 이 문제를 국내 자료로 직접 보여준다. 파일럿에서도 AUC 는 격차를 절반 수준으로 과소평가했다(PR-AUC +0.245 대 AUC +0.124). **PR-AUC 를 주 지표로, AUC 와 소수 클래스 F1 을 보조로 삼는다.**

3. 수행 내용 상세

3.1 주요 활동 내역

단계	작업	산출물
수집	DART 클라이언트 구현(속도제한·디스크 캐시·페이지 순회), 거래소공시 전수 순회로 사건 명단 구축	src/dart.py, gate1_events.py
수집	KIND 확정 지정 수집기 — 공시유형 코드로 날짜 범위 조회, 종목코드 복원	src/kind.py
수집	정기보고서 인덱스 확장 (사업·반기·분기 접수일), 재무제표 수집 + 재무비율 10개 산출	gate3a/3b_*.py
전처리	라벨 확정, 사건 유형·사유 자동 분류(미상 2.2%)	kind.py
베이스라인	실험 A/B 통제 실험 + 예측 시점 스위치, 시각화	gate3c_experiment.py, 그림 1·2
검증	보조 실험 E1 (공통표본 탈락군 사건률 감소), 생존편향 진단 및 수정	e1_dropout.py, collect_firms()
측정	새 라벨·확대 표본으로 A-B 재측정	표 2

수집 순서 규칙. 현재 상장 종목 목록이 아니라 공시 스트림에서 출발했다. 상장 목록에서 시작하면 이미 퇴출된 기업, 즉 정답 표본이 통째로 빠진다.

3.2 방법론적 발견 세 가지

① **생존편향은 공시 스트림에서 출발해도 남을 수 있다.** DART list.json의 시장 구분(corp_cls) 필터는 현재 분류로 거른다. 상장폐지된 기업은 KOSDAQ 분류를 잃어 과거 공시까지 통째로 빠진다. 실제로 사건기업 413개 중 219개(53%)가 모집단 밖이었다. 사건기업을 기업코드로 직접 받아 메운 결과 411개(100%)가 모집단에 들어왔고, 인덱스는 52,584건에서 68,678건이 되었다. 파일럿에서 드러나지 않은 이유는 라벨도 같은 스트림에서 나와 빠진 기업이 라벨에서도 빠졌기 때문이다. **라벨 소스를 바꾼 것이 수집 버그를 드러냈다.**

② **A-B 격차는 결국 탈락에서 오지 않는다(E1).** "격차가 시점 누출이 아니라 부실기업의 결국 탈락을 재는 것 아닌가"라는 지적을 받아, 공통표본 규칙으로 탈락한 관측의 사건률을 세었다.

구분	관측	사건	사건률
잔존(실험에 사용)	1,194	67	5.61%
탈락	270	5	1.85%

탈락군의 사건률이 잔존군의 3분의 1이다. 격차가 탈락에서 왔다면 나와야 할 방향과 반대다. 다만 탈락의 다수(213건)는 수집 시작 이전이라 보고서 이력이 없는 구간이며, "상장 상태인데 재무제표가 없는" 34건의 사건률은 8.82%로 잔존군보다 높다(사건 3건). 두 사실을 함께 보고한다.

③ **실험 B는 현재 과소 설정되어 있다.** 실험 B는 사업보고서만 사용한다. 그런데 T=2월 1일 시점에는 직전 사업연도의 3분기보고서가 이미 공개되어 있고(11월 제출), 회사가 자진 공시한 「지정사유 발생」 알림도 공개되어 있다. 자진공시는 거래소 확정 지정보다 중앙값 34일 선행한다(77%가 선행). 즉 표 2의 격차는 상한값이며, 이 정보들을 B에 넣으면 줄어든다. 이를 위해 본 수집에서 분기·반기보고서를 함께 받아두었다. 한편 자진공시는 라벨(거래소 지정)과 지나치게 가까운 신호이기도 하다. 예측 시점 이전에 공개되었으므로 시점상 누출은 아니나, 사실상 정답을 읽는 구조가 될 수 있다. 따라서 이 변수를 넣은 조건과 넣지 않은 조건을 **함께 보고**하기로 한다.

3.3 팀원별 기여

이름	담당	산출물
배진형	수집 파이프라인 전반, KIND 수집기 구현, 파일럿 실험 설계·실행, 생존편향 진단·수정, 선행연구 감사	src/ 전체, 그림 1·2, 감사표 5편
박서진	DART 공시 실물 확인, 접수일 분산 검증	접수일 10건 표, 일괄 가정 오차율 90%·평균 15일
강지수	파일럿 재현 및 코드 검증	재현 확인(PR-AUC A 0.520 / B 0.275)
최서린	관리종목 지정 사유 분류, 자진공시의 라벨 근접성 지적	사유 10건 분류, 재무제표 유래 80% , 설계 원칙 제안

최서린이 제기한 "「사유 발생」 공시를 입력 변수로 쓰면 라벨에 매우 가까운 직접 신호가 섞인다"는 지적은 3.2절 ③의 설계 결정으로 반영했다.

4. 차후 본 학기 계획

4.1 현재 한계와 대응

한계	대응	상태
라벨의 자진공시 선택편향	KIND 확정 지정으로 교체	완료

한계	대응	상태
시장 단위 순회의 생존편향	사건기업 개별 수집으로 보충	완료
표본이 얇음(평가 구간 7 건)	2015~2024 전수로 확대	완료
격차가 점추정 하나뿐	부트스트랩 신뢰구간	예정
모델 2 종만 사용	복제 논문 6 종 전체로 확대	예정
실험 B 가 과소 설정	분기보고서 포함 조건(B') 병기	자료 확보 완료

4.2 실행 계획

1 순위 — 확정 수치 산출. 확대 표본으로 A-B 를 재측정하고 예측 시점 스위치를 재실행한다. 분기보고서를 포함한 B'를 추가해 A-B 를 상한, A-B'를 하한으로 병기한다.

2 순위 — 강건성. 복제 논문 명세(변수 21 개·모델 6 종)를 추출해 6 종으로 확대하고, 부트스트랩 신뢰구간과 E2(탈락 요건 완화 후 재측정), 연도별 반복을 수행한다.

3 순위 — 확장. 실험 C 는 제출 지연일수, 사업보고서 「II. 사업의 내용」 텍스트 임베딩, 유사기업 상대값을 투입하되 변수군을 블록으로 나눠 중분 기여를 개별 보고한다. 실험 D 는 유사도 그래프를 전 기간 문서로 구성한 경우와 예측 시점까지의 문서만으로 구성한 경우를 비교해, 입력변수가 아닌 그래프 구성 단계의 누출을 측정한다. KOSPI 반복 검증(라벨 확보 완료, 지정 97 건)은 시장을 섞지 않고 따로 돌린다.

4.3 보고 원칙

B 의 성능이 낮은 것은 실패가 아니라 측정 결과다. B-C 가 유의하지 않게 나와도 그대로 보고한다. C 가 A 를 상회하면 축하에 앞서 C 의 전 변수에 대한 시점 감사를 먼저 수행한다. 정직한 데이터가 반칙 데이터를 이기는 것은 대개 어딘가에서 또 시간이 섰다는 경보이기 때문이다.

참고문헌

윤양현·김태경·김수영 (2022). 「머신러닝 기반 KOSDAQ 시장의 관리종목 지정 예측 연구」. 『벤처창업연구』 17(1), 229-249. / 노성호·이상호 (2025). 「머신러닝을 활용한 재무제표 정보의 유용성 평가」. 자본시장연구원 연구보고서 25-04. / 노시현·한희준 (2025). 「머신러닝과 오버샘플링을 이용한 상장기업 부도예측 연구」. 『계량경제학보』 36(2), 59-82. / Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. Patterns, 4(9), 100804. / Zhang, Y., Zhu, Y., & Linnainmaa, J. T. (2025). Man versus machine learning revisited. The Review of Financial Studies, 38(12), 3768-3790.

전체 목록(9 편)은 2 주차 선행연구 조사보고서에 있다.



회의 사진