

논문 리뷰 발표

Explaining Machine Learning Classifiers through Diverse Counterfactual Explanations

다양한 반사실적 설명으로 분류기 설명하기 (DiCE)

Ramaravind K. Mothilal, Amit Sharma & Chenhao Tan (2020)

Proceedings of FAT* '20, pp. 607–617 · DOI 10.1145/3351095.3372850

리뷰 팀 00:7 | 대상 팀 닭고조이고기름치자

목차

index

1

문제와 핵심 아이디어

왜 반사실 “집합” 이 필요한가

2

수식과 두 가지 장치

식 (4), DPP · hinge, 제약과 인과

3

결과와 리뷰

유효성 · 다양성 · trade-off, 한계

4

핵심 정리와 시사점

대상 팀 프로젝트와의 연결

핵심 메시지

결정의 이유에만 머물지 않고,
결과를 바꾸려면 무엇을 바꿀 수 있는지 여러 현실적인 대안으로
보여준다

설명은 있는데, 처방이 없다

“신용 기록이 나빠서 거절됐습니다” — 그래서 무엇을 바꿔야 승인되나?

그 전 — 설명과 반사실 1개

- **LIME · SHAP** — 어떤 변수가 기여했는지는 알려주지만, 무엇을 바꿔야 하는지는 알려주지 않는다
- **Wachter (2017)** — 예측을 뒤집는 반사실을 1개만 준다. 고를 수 없다
- **Russell (2019)** — 서로 다른 여러 개를 주지만 선형 모델에만 쓸 수 있다




이 논문 — DiCE

- 서로 다른 반사실 **k**개를 한 번에 만든다
- 미분 가능한 모든 분류기에 적용된다
- 변경 가능 변수 · 허용 범위 같은 사용자 제약을 반영한다
- 다양성과 근접성 사이의 trade-off를 조정해야 한다

한 줄 요약 — 바꿀 수 없거나 · 하나로는 부족하거나 · 사람마다 다르기 때문에, **여러 경로**가 필요하다.

한 점에서, 서로 다른 방향으로 경계를 넘는다

DiCE는 이런 반사실 k개를 한 번에 만든다. 사용자는 자기 사정에 맞는 경로를 고른다.



1 소득만 ↑
3,000만 → 4,500만

2 근속만 ↑
1년 → 4년

3 소득 ↑ + 부채 ↓
소득 3,500만 · 부채 900만

예측을 뒤집는 조건은 하나가 아니다 — 다양한 경로가 **사용자의 선택지**가 된다

세 가지 요구를 한 식으로 묶는다

k개를 따로 찾지 않고 함께 최적화해야 서로 다른 방향으로 벌어진다.

$$\mathbf{C}(\mathbf{x}) = \text{argmin} \quad \textcircled{1} + \textcircled{2} - \textcircled{3}$$

1 예측 손실 $(1/k) \sum \text{yloss}(f(c_i), y)$

원하는 클래스로 바뀌게 압박한다. f : 학습된 모델 · y : 원하는 결과

2 근접성 $(\lambda_1/k) \sum \text{dist}(c_i, \mathbf{x})$

원래 입력 $\mathbf{x}$ 에서 멀어지지 않게 한다. λ_1 : 근접성 가중치

3 다양성 $-\lambda_2 \cdot \text{dpp_diversity}(c_1 \dots c_k)$

CF끼리 서로 다르면 보상한다. 손실에서 빠르게 다양할수록 유리하다. λ_2 : 다양성 가중치


실험 기본값 $\lambda_1 = 0.5$ · $\lambda_2 = 1$ · ADAM lr 0.05 · 최대 5,000 step

다양함을 숫자로 재고, 과한 이동은 막는다


DPP가 “다양함”의 정의이고, hinge loss가 “필요한 만큼만”의 정의다.

① DPP — 다양함을 숫자로

$$\det(K), K_{ij} = 1 / (1 + \text{dist}(c_i, c_j))$$



비슷함 → $\det(K)$ 작다




다름 → $\det(K)$ 크다

집합 전체의 “부피”를 재므로 중복 CF는 크게 벌점을 받는다

② hinge loss — 필요한 만큼만

$$\max(0, 1 - z \cdot \text{logit}(f(c)))$$




$\text{logit} \geq 1$ ($f \approx 0.73$)부터 벌점 0 → 더 밀지 않는다

거리 — 연속형: $L1 \div MAD$ · 범주형: 다르면 1, 같으면 0

가깝고 다양해도 실행 가능하다는 뜻은 아니다

생성 전에는 제약을 주고, 생성 후에는 불가능한 처방을 걸러낸다.

처리 흐름



- **사용자 제약** — 허용 범위 · 변경 가능 변수 · 변수별 가중치
- **인과 필터링** — “학위 ↑ ⇒ 나이 ↑”, “학위는 낮출 수 없다” 규칙을 어긴 CF를 제거

Adult-Income 실험 (그림 4)

교육 수준이 바뀐 CF 중 infeasible한 비율

1/3 이상

고학력자(Masters 등)에서 낮은 학위를 제안한 비율

최대 ~50%

저자들은 인과 제약을 **생성 단계**에 넣는 편이 더 효율적이라고 보고, 후속 과제로 남겼다.

거의 100% 유효하고 훨씬 다양하다. 대신 원본에서 멀어진다

4개 데이터셋 · 선형/비선형 모델 · 무작위 500개 입력으로 평가했다.

DiverseCF는 **거의 100% 유효**한 CF를 만들고 baseline보다 **훨씬 다양**하다. 대신 원본에서는 더 멀어진다.

유효성

~100%

고유한 유효 CF 비율. 모든 데이터셋, 모든 k

다양성

최대 11배

연속형 다양성. LendingClub, k=10, baseline 대비


근접성 (trade-off)

최대 ~30%

범주형 proximity 손실. baseline 대비

국소 결정 경계 근사 · F1

Adult-Income, k=4, 0.5 MAD



읽는 법

- Adult · COMPAS: precision과 recall 모두 LIME보다 높다
- 예외: LendingClub의 한 설정 (0.5 MAD, k=10)
- **LIME “만큼”** 근사한다 — 저자의 결론

기여와 증거의 한계

저자가 밝힌 한계와, 리뷰어가 덧붙이는 판단을 구분해 본다.

기여

- 다양성을 핵심 품질로 세우고 DPP로 구현
- 네 지표와 1-NN 경계 근사의 평가 틀
- 사용자 · 개발자 · 감사자에게 쓸모

저자가 밝힌 한계

- gradient가 필요해 블랙박스는 불가
- 이진 · 정적 모델만 가정
- 인과는 생성 후 필터링뿐
- 사용자 연구 없음

리뷰어의 관점

- 실제 데이터 분포 위라는 보장이 약함
- 다양성은 입력 공간 거리일 뿐
- 제도 문제를 개인 몫으로 돌릴 위험

저자들이 남긴 과제(인과 통합 · 사용자 연구)가 곧 **후속 연구의 출발점**이다.

DiCE · Diverse Counterfactual Explanations

Mothilal, Sharma & Tan (2020) · 문제 ① · 아이디어 ② · 결과 ③

1 문제

설명은 있는데
처방이 없다

기존 반사실 설명은 답이 하나이거나
(Wachter) 선형 모델에만 되었다
(Russell).

2 핵심 아이디어

k개를 동시에,
서로 다르게

예측 손실 + 근접성 - DPP 다양성 (식 4).
구현은 공개 코드(GitHub)로 제공된다.

3 결과

거의 100% 유효,
최대 11배 다양

대신 근접성은 낮아진다. 경계 근사는 LIME
만큼 좋다.

한 문장으로 — 결정의 이유만 설명하지 않고, 결과를 바꿀 수 있는 **여러 현실적인 대안**을 보여주는 논문이다.

제약형 DiCE는 여러분의 baseline이자 출발점

닭고조이고기름치자의 연구(인과구조 품질 ↔ Counterfactual 신뢰성)와의 접점

1 제약이 이미 있다

DiCE 논문

변경 가능 변수 · 범위 지정을 지원한다
(p. 609). Python 패키지 dice-ml도
지원한다

대상 팀 연결

RQ1의 “제약형 DiCE”가 baseline으로
성립한다

2 인과는 후속 과제

DiCE 논문

인과를 생성 후 필터링으로만 처리했고,
저자도 한계로 인정했다 (p. 616)

대상 팀 연결

SCM 기반 Causal CF가 그 빈칸을 채운다

3 다양성은 어떨까?

DiCE 논문

Proximity · Sparsity 지표를 그대로
정의했다 (pp. 611–612)

대상 팀 연결

대상 팀의 평가 지표에는 다양성이 없다. 공정
복구에도 필요할까?

질문 — 공정 복구에는 **서로 다른 여러 경로**가 필요한가, 하나의 정답 경로가 중요한가?

감사합니다

리뷰 팀 00:7 | 대상 팀 닭고조이고기름치자