

[3주차] 방학 스터디 최종 보고서

2026년 8월 23일


CREDIT | 이지은 김건우 박지원 오영광

1. 주요 결과물 요약

본 스터디는 AI허브 「금융상품·서비스 및 소비자 특성 데이터」를 활용해 고객 특성과 금융·보험상품 선택 패턴을 분석하고, 향후 추천모델을 위한 데이터 환경과 평가체계를 정비하였다. 초기 CoT 자연어 분석의 시행착오를 재검증한 뒤 전체 소비자 데이터를 확인하고, 최종적으로 보험-only 데이터 구축부터 Audit, 고객 단위 분할, Target 분석, RandomForest Baseline과 오류분석까지 연결하였다.

데이터	규모	핵심 내용
CoT 라벨링	보험 약 1,800건 / 증권 약 7,200건	질문·전문가 추천·답변·추천상품
상품 카탈로그	보험 약 1,990종 / 증권 약 7,989종	상품유형·가입조건·세제혜택
소비자 CSV	385,019행	고객 기본·금융 특성과 실제 보유상품
보험-only	77,305행 / 74,776명 / 62종	원본 22개 컬럼을 보존한 분석용 데이터


- 초기 CoT는 보험 1,800건에 상품 약 1,684종으로 Target이 지나치게 세분화되어 정확한 상품명 예측이 어려웠다.
- 긴 자연어에 LabelEncoder를 적용한 방식은 의미 표현이 아니라 고유번호 부여에 가까워 정형 Feature에서 제외하였다.
- 보험 핵심 8개 변수의 NaN은 없었고, 완전 동일 중복행 및 동일 고객-동일상품 중복도 0건이었다.
- 상위 1개 상품 33.54%, 상위 3개 62.30%, 상위 10개 83.97%로 강한 클래스 불균형이 확인되었다.




[그림 1] 보험상품 가입 건수 상위 15개. 관측치가 소수 인기상품에 집중되어 있다.

2. 이론적 배경 및 심화 학습


주제	학습 내용과 본 분석 적용
Target 정의	product_name은 최적상품이 아니라 관측된 보유·선택 상품이다. 세부상품 62종, 모상품, 2단계 추천 중 적절한 수준을 먼저 정해야 한다.
Encoding	자유서술 문장에 LabelEncoder를 적용하면 문장의 의미가 아닌 임의의 정수 ID로 변환되므로 적절한 텍스트 표현이 되지 않는다. 지역·직업 등 명확한 범주형 Feature는 One-Hot Encoding으로 처리하였다.
PCA	차원축소는 탐색 도구이다. 15~30개 점처럼 보인 것은 행 소실이 아니라 age×gender×query_type 조합 좌표의 중첩이었다.
데이터 누수	가입금액·거래시점 등 사후정보를 제외하고, customer_id 기준 분할과 Train-only 전처리 fit으로 누수를 방지했다.
평가 지표	Top-1뿐 아니라 Hit@K, MRR, Macro Recall/F1과 Popularity 기준선을 함께 봐야 다수 클래스 효과를 분리할 수 있다.
TF-IDF	고객 질문과 상품 설명을 TF-IDF 벡터로 표현하고 코사인 유사도를 이용해 상품을 Ranking하는 방식이다. 재분석에서는 한글 조사 등을 처리하는 간단한 토큰라이저를 구성하여 TF-IDF 추천을 실제 구현하였으며, 전체 유사도를 단어별 기여도로 분해할 수 있도록 설계하였다. 따라서 단순 추천점수뿐 아니라 어떤 단어가 해당 상품 추천에 기여했는지를 함께 제시할 수 있어 향후 설명가능한 추천 및 정형 고객정보와의 결합에 활용할 수 있다.




A. 1차 PCA (텍스트 포함)



B. 초기 RF 트리 (cot 포함)



C. 2차 PCA (텍스트 제거)



D. 재검증 RF 트리 (고객 스펙)

[그림 2] 초기 CoT 분석과 재검증. A: 텍스트 포함 PCA, B: cot 중심 트리, C: 텍스트 제거 PCA, D: 고객 스펙 중심 트리.

초기에는 텍스트 변수 중요도가 높아 이를 데이터 누수로 해석하였으나, 재검증 결과 핵심 문제는 긴 문장에 임의 번호를 부여한 잘못된 입력 방식이었다. 다만 cot_answer에 정답 상품명이 포함되어 예측 시점 Feature로 부적합하다는 판단은 유지하였다. 텍스트 제거 후 입력은 정리되었지만

age·gender·query_type 세 변수만으로 세부상품을 구분할 정보가 부족해 RF 정확도는 0.00이었다.

3. 수행 내용 상세

3.1 분석 흐름과 데이터 파이프라인

단계	수행 내용	검증 결과
① 원본 재확인	압축·인코딩 문제를 해결하고 JSON 29,003개, 소비자 CSV, 카탈로그 확인	CoT 외 정형 소비자 데이터 존재 확인
② 초기 분석 재검증	PCA·로지스틱·RF의 입력과 Target 구조 재검토	좌표 중첩, LabelEncoder 오류, 과세분 Target 확인
③ 보험 추출·Audit	customer_type='보험' 필터, 22개 컬럼 품질검사	77,305행, 중복 0, 결측 정의 보완
④ 모델링 준비	6개 Feature, product_name Target, 고객 단위 80:20 분할	Train/Test 중복 고객 0명, One-Hot 35개
⑤ Target 분석	62종 분포와 1,891쌍 유사명 전수 비교	36개 상품·10개 후보군, M-케어 68.64%
⑥ RF·오류분석	RF 1회, predict_proba 순위와 클래스별 오류 확인	파이프라인 작동 PASS, 다수 클래스 편향 확인

전체 데이터 재분석에는 CoT 데이터의 추천 단위를 변경해가며 모델의 적용 가능성을 다시 검토하였다. 정확한 상품명 1,684종을 Target으로 한 경우 인기도 Baseline Top-1 0.020 대비 TF-IDF Top-1 0.178로 개선되었다. 모상품 수준으로 세부 옵션을 통합한 432종 단위에서는 인기도 Baseline이 상대적으로 우세했으며, 상품유형 8종 단위에서는 다항 로지스틱 회귀 Top-1 0.722가 나타났다. 다만 상품유형 실험에서는 query_type이 상품유형을 강하게 암시하는 구조가 확인되어, 해당 0.722를 실제 추천모델의 성능으로 해석하지 않았다. 증권 CoT에서도 TF-IDF가 인기도 Baseline보다 높은 성능을 보여 자연어 정보를 활용한 Ranking 방식의 가능성을 확인하였다.

또한 새로 확보한 소비자 CSV 385,019건을 이용해 가입금액·거래일자 등 상품 선택 이후의 정보를 제외하고 고객 특성 11개를 활용한 RandomForest를 적용하였다. 그 결과 Top-1 Accuracy 0.531, MRR 0.690이 나타났다. 주요 변수 중요도는 income_bracket 22.5%, investment_propensity 13.1%, customer_type 12.6%, age 10.9%, gender 2.8% 순으로 확인되었다. 단, 해당 실험은 보험·증권 전체 데이터와 11개 Feature를 사용한 조건으로 이후 보험-only 6개 Feature Baseline과 데이터 및 문제 정의가 다르므로 두 결과를 직접적인 성능 우열로 비교하지 않았다.

3.2 전처리 및 Baseline 결과

보험 데이터 Audit에서는 단순 NaN뿐 아니라 문자열 형태의 의미상 결측도 별도로 점검하였다. 초기에는 '없음'을 결측으로 처리하였으나, disease_history='없음'은 데이터 미수집이 아니라 '기왕력 없음'을 의미하는 정상 응답으로 판단하여 최종적으로 유효 범주로 처리하였다. 반면 investment_propensity는 보험 데이터 77,305건 전체가 -로 기록되어 있어 현 단계 모델링 Feature에서는 제외하였다. 또한 완전 동일 중복행과 동일 고객·동일상품 중복은 모두 0건이었으나, 74,776명의 보험 고객 중 2,339명(3.13%)은 서로 다른 보험상품을 2개 이상 보유하고 있었으며 고객당 최대 고유상품 수는 5개였다. 이에 따라 향후에는 하나의 정답상품을 예측하는 Single-label 방식뿐 아니라 Top-K 또는 Multi-label 추천 구조도 함께 검토할 필요가 있다고 판단하였다.


원본 데이터 점검 과정에서는 소비자 CSV의 Training 버전과 Validation 버전이 내용상 동일한 파일임을 확인하였다. 따라서 AI Hub에서 제공한 Train/Validation 구분을 그대로 사용할 경우 독립적인 평가가 어렵다고 판단하였으며, 보험-only 모델링에서는 customer_id를 기준으로 Train/Test를 직접 재분할하

였다. 이를 통해 동일 고객이 학습 데이터와 평가 데이터에 동시에 포함되는 것을 방지하였다.

Baseline 입력변수 X는 age, gender, region, income_bracket, occupation_group, credit_rating의 6개 변수로 구성하였으며, customer_id는 모델 입력에 포함하지 않고 그룹 분할에만 사용하였다. 또한 product_amt, transaction_amt, 거래연도 등 상품 선택 이후에 생성될 가능성이 있는 사후정보는 Target leakage를 방지하기 위해 제외하였다. GroupShuffleSplit(random_state=42)을 적용한 결과 Train은 61,840행·59,820명, Test는 15,465행·14,956명으로 분할되었으며, Train/Test 간 중복 고객은 0명이었다.

지표	결과	해석
Top-1 Accuracy	31.79%	최빈상품 기준선 33.88%보다 낮음
Hit@3	59.71%	Popularity Top-3 기준선 추가 필요
MRR	0.4841	정답 상품의 추천 순위를 함께 반영
목적	Sanity check	튜닝이 아니라 학습·확률·순위 산출 정상 여부 확인


보험상품 RandomForest Baseline 성능 비교



[그림 3] 보험-only RandomForest Baseline 성능. Top-1은 최빈상품 기준선을 넘지 못했다.

3.3 오류분석과 종합 해석

오류분석 항목	결과	의미
Top-1 오류	10,549건(68.21%)	Test 15,465건 기준
Recall 0 상품	49종 / 62종	대부분의 세부상품을 한 번도 맞히지 못함
Macro Recall	2.25%	전체 상품을 동일하게 보면 성능이 매우 낮음
M-케어 정확 세부상품	4,689건(43.91%)	정확한 세부옵션까지 일치
다른 M-케어로 오분류	5,265건(49.30%)	동일 계열 세부옵션 구분이 주요 난점
M-케어 밖으로 오분류	725건(6.79%)	단, 계열 내 비율을 인식 성능으로 과대해석 금지



[그림 4] Top-1 오분류 조합 상위 15개. M-케어 내부 혼동과 최빈상품 방향의 예측 편향이 함께 나타난다.

3.4 종합 판단

- 현재 6개 기본 특성만으로 세부상품 62종을 고르게 예측하기는 어렵다.
- M-케어 내부 오분류가 많지만, M-케어 데이터 비중 68.64%와 예측 편향 때문에 '계열을 잘 학습했다'고 단정할 수 없다.
- Hit@3 59.71%도 상위 3개 상품 비중 62.30%와 비교하면 개인화 성과로 해석하기 이르다.
- 이번 성과는 최고 성능 모델이 아니라 보험 추출→Audit→누수 방지 분할→Target 분석→학습→오류 분석의 재현 가능한 파이프라인 구축이다.

4. 차후 본 학기 계획

본 학기에는 모델을 먼저 복잡하게 만들기보다 Target과 추천 문제를 확정한 뒤 동일 데이터·동일 고객 split·동일 지표에서 단계적으로 비교한다.

우선순위	논의·실행 내용	판단 기준
1. Target 단위	세부상품 62종 유지 / 검증된 모상품 통합 / 모상품→옵션 2단계	약관·보장내용·판매시기·가입조건 확인
2. 추천 형식	Single-label / Multi-label / Top-K-Ranking	다상품 고객 3.13%와 실제 서비스 UX
3. 평가체계	Random 및 Popularity Top-1-3-5, Hit@K, MRR, Macro-Weighted F1	개인화 효과와 인기효과 분리

우선순위	논의·실행 내용	판단 기준
4. Feature 확장	risk_grade, marital_status, cross_coverage 등 후보 검토	기존 split 고정, 민감정보·누수 점검
5. 불균형 대응	class weight, sampling, 계층형 Target, Ranking 방식 후보	소수상품 Recall과 Macro 지표 개선
6. 모델·텍스트 결합	정의 확정 후 부스팅·선형모델 및 TF-IDF 하이브리드 비교	모델 수가 아니라 동일 조건의 안정성 비교

4.1 논의가 필요한 핵심 질문

- 62개 세부상품을 그대로 예측할 것인가, 모상품 단위로 통합할 것인가, 또는 모상품→세부옵션의 2단계 추천으로 구성할 것인가?
- 복수상품 보유 고객을 고려해 Single-label 방식으로 유지할 것인가, Top-K 또는 Multi-label 추천으로 정의할 것인가?
- 기타 상품 1,492건(1.93%)과 현재 판매 여부·가입조건 등을 고려해 실제 추천 후보군을 어떻게 정제할 것인가?
- 현재 모델이 단순 Popularity Top-K보다 실제로 나은 개인화 추천 성능을 보이는가? 또한 클래스 불균형을 어떤 방식으로 보완할 것인가?
- 현재 6개 고객특성을 확장할 것인가, 그리고 정형 고객정보와 TF-IDF 기반 텍스트 정보를 어떤 방식으로 결합할 것인가?

4.2 해석상 한계

현재 product_name은 고객에게 객관적으로 가장 적합한 상품을 의미하는 정답 라벨이 아니라, 데이터상 실제로 관측된 보유·선택 상품이다. 따라서 모델 성능은 '최적 상품 추천 정확도'라기보다 고객 특성에 따른 관측 상품 선택 패턴을 예측한 결과로 해석하는 것이 적절하다.

이러한 한계는 모상품 후보 분석에도 적용된다. 유사상품군은 상품명 문자열을 기준으로 탐색한 결과이므로 실제 보장내용이나 약관이 동일하다고 볼 수 없다. 따라서 향후 상품 통합 여부는 약관·보장내용·가입조건·판매시기 등을 추가 검토한 뒤 결정할 필요가 있다.

보험-only Baseline 역시 현재 데이터 구조를 점검하기 위한 기준 실험이다. 6개 기본 Feature만 사용하였고 클래스 불균형 보정이나 하이퍼파라미터 튜닝은 수행하지 않았다. 또한 앞서 수행한 소비자 CSV 11개 Feature 모델과는 데이터 범위와 조건이 달라 성능 수치를 직접 비교하기 어렵다.

평가지표도 같은 맥락에서 신중하게 해석해야 한다. Hit@3는 59.71%였지만 상위 3개 상품이 전체의 62.30%를 차지하므로, 해당 수치만으로 개인화 추천 효과가 있다고 보기는 어렵다. 향후 Popularity Top-3 Baseline과 동일 조건에서 비교할 필요가 있다.

따라서 이번 분석은 완성된 추천모델의 성능을 제시하기보다 Target 정의·클래스 불균형·추천 형식 등 데이터와 문제 구조를 점검하고 이후 모델링을 위한 기준선을 마련한 단계로 해석한다. 본 학기에는 Target 단위 확정 → 추천 형식 확정 → Popularity Top-K 기준선 구축 → 추가 Feature 검토 → 불균형 대응 순으로 문제 정의와 평가체계를 정비한 뒤 모델을 단계적으로 비교할 예정이다.