


방학 사전스터디 결과

소비자 행동 및 금융 특성 데이터 기반 맞춤형 금융상품 추천 모델 개발

CREDIT | 이지은 · 김건우 · 오영광



고객



데이터



금융상품

01. 프로젝트 목표와 활용 데이터

“고객의 특성을 바탕으로 실제 금융상품 선택 패턴을 예측할 수 있을까?”



① CoT 데이터

보험 약 1,800건

증권 약 7,200건

질문 · 전문가 추론 · 답변 · 추천상품



② 상품 카탈로그

보험 약 1,990종

증권 약 7,989종

상품유형 · 가입조건 · 세제혜택



③ 소비자 CSV

385,019행

고객 기본 · 금융 특성과 실제 보유상품



보험-only 데이터 구축



77,305건

보험 데이터



74,776명

보험 고객



62종

보험상품

성능 경쟁보다 추천 문제의 구조와 데이터 활용 가능성을 먼저 검증

※ product_name은 ‘최적상품’이 아닌, 데이터상 실제 보유·선택 상품을 의미함

02. 초기 접근 재검토 및 문제 재정의

초기 접근

보험 CoT 1,800건 → 상품 1,684종 → 정확 상품명 예측

3개 Feature (age · gender · query_type) RF Accuracy **0.00**

문제 발견

- 1 cot-answer에 정답 상품명 포함 → 예측 시점 Feature로 부적합
- 2 자연어 LabelEncoder 처리 → 임의의 정수 ID
- 3 Target 과도 세분화 보험 1,800건 ↔ 상품 1,684종

재분석 방향

- CoT 데이터 → Target 재검토 · TF-IDF Ranking
- 소비자 CSV 385,0019건 → 11 Feature RF 재분석

재분석 결과

[CoT 텍스트 분석]

TF-IDF Top-1

0.178

>


Popularity Top-1

0.020


소비자 CSV 11 Feature RF **Top-1 0.531 / MRR 0.690**

※ 이후 보험-only 6 Feature Baseline과 직접 비교하지 않음


재검증 과정 시각화




A. 1차 PCA (텍스트 포함)



B. 초기 RF 트리 (cot 포함)



C. 2차 PCA (텍스트 제거)



D. 재검증 RF 트리 (고객 스펙)

Target과 Feature 구성을 재검토해 본격적인 모델링을 위한 문제 구조를 정립

02. 초기 접근 재검토 및 문제 재정의

초기 접근

보험 CoT 1,800건 → 상품 1,684종 → 정확 상품명 예측

3개 Feature (age · gender · query_type) RF Accuracy 0.00

문제 발견

- 1 cot-answer에 정답 상품명 포함 → 예측 시점 Feature로 부적합
- 2 자연어 LabelEncoder 처리 → 임의의 정수 ID
- 3 Target 과도 세분화 보험 1,800건 ↔ 상품 1,684종

재분석 방향

- CoT 데이터: Target 재검토 · TF-IDF Ranking
- 소비자 CSV 385,0019건: 11 Feature RF 재분석

재분석 결과

CoT


TF-IDF Top-1 0.178 > Popularity 0.020

소비자 CSV


11 Feature RF Top-1 0.531 / MRR 0.690

※ 이후 보험-only 6 Feature Baseline과 직접 비교하지 않음


재검증 과정 시각화




A. 1차 PCA (텍스트 포함)



B. 초기 RF 트리 (cot 포함)



C. 2차 PCA (텍스트 제거)



D. 재검증 RF 트리 (고객 스펙)

Target과 Feature 구성을 재검토해 본격적인 모델링을 위한 문제 구조를 정립

02. 초기 접근 재검토 및 문제 재정의

초기 접근

보험 CoT 1,800건 → 상품 1,684종 → 정확 상품명 예측

3개 Feature (age · gender · query_type) RF Accuracy 0.00

문제 발견

- 1 cot-answer에 정답 상품명 포함 → 예측 시점 Feature로 부적합
- 2 자연어 LabelEncoder 처리 → 임의의 정수 ID
- 3 Target 과도 세분화 보험 1,800건 ↔ 상품 1,684종

재분석 방향


- CoT 데이터 → Target 재검토 · TF-IDF Ranking
- 소비자 CSV 385,0019건 → 11 Feature RF 재분석

재분석 결과


CoT TF-IDF Top-1 0.178 > Popularity 0.020

소비자 CSV 11 Feature RF Top-1 0.531 / MRR 0.690


재검증 과정 시각화




A. 1차 PCA (텍스트 포함)



B. 초기 RF 트리 (cot 포함)



C. 2차 PCA (텍스트 제거)



D. 재검증 RF 트리 (고객 스펙)

Target과 Feature 구성을 재검토해 본격적인 모델링을 위한 문제 구조를 정립

03. 보험-only 데이터 분석 파이프라인

보험 데이터 추출부터 오류분석까지의 6단계 분석 과정

01



원본 데이터 재확보

압축 · 인코딩 문제 해결
JSON 29,003개
소비자 CSV · 카탈로그 확인

02



초기 분석 재검증

PCA · 로지스틱 · RF
Feature와 Target 구조 재검토

03



보험 추출 & Audit

customer_type='보험'
77,305행, 중복 0
결측치 기준 보완

04



모델링 준비

기본 고객 Feature 6개
Target: product_name
customer_id 기준 분할

05



Target 분석

62종 상품 분포 확인
유사 상품명 구조 검토
강한 클래스 불균형 확인

06



Baseline & 오류분석

RandomForest
predict_proba 기반
추천 순위와 클래스별 오류 분석

- ☑ AI Hub 제공 Training/Validation이 내용상 동일함을 확인 → customer_id 기준 직접 재분할
- ☑ 가입금액 · 거래시점 등 사후정보 제외 → Target leakage 방지

☑ Train/Test 중복 고객 0명 ✓

04. Baseline 결과

기본 고객정보 기반 개인화 효과의 한계

RF Top-1 Accuracy

31.79%

vs.

Majority Baseline

33.88%


Hit@3 59.71%

MRR 0.4841

Baseline 목적

모델 학습·확률 산출·추천 순위 생성이
정상적으로 작동하는지 확인하는 Sanity Check


보험상품 RandomForest Baseline 성능 비교



6개 기본 고객 특성만으로 62개 세부상품을 구분하기에는 한계가 있음

05. 오류분석: 불균형과 세부상품 혼동

보험상품 가입 건수 상위 15개



33.54%

Top 1

62.30%

Top 3

83.97%

Top 10

→ 관측치가 소수 인기상품에 집중

Recall 0 상품

⚠️ 49 / 62

Macro Recall

2.25%

49개 상품에서 정답 예측 0건

M-케어 내부 혼동

정확 세부상품

43.91%

다른 M-케어로 오분류

49.30%

M-케어 밖으로 오분류

6.79%

※ M-케어 비중이 68.64%로 높고 예측 편향도 존재하므로, 내부 오분류가 많다는 사실만으로 M-케어 계열을 잘 학습했다고 보기는 어려움


모델 Hit@3

59.71% vs. 상위 3개 상품 비중 62.30%

개인화 효과 확인 어려움

오류분석의 핵심 이슈: Target 구조와 데이터 불균형

06. 본 학기 방향



▶ 진단 결과에 따라 Target 및 후속 모델링 방향 결정