

최종 [3 주차] 코스모스 보고서

KOSMOS | 김태우 · 정주희 · 허다교

2026년 8월 23일

1. 주요 결과물 요약

1.1 데이터 개요 및 인사이트

한국종합사회조사(KGSS) 2003-2025 누적자료를 성균관대학교 서베이리서치센터를 통해 확보했다. 전국 만 18세 이상 성인 대상 대면면접 조사로 23,282명, 3,491개 변수, 17개 회차 구성이다. 회차마다 문항이 달라 2023년을 주 회차로, 선택지 배열 효과 검증을 위해 2021년을 보조 회차로 정했다. 응답자 식별자가 회차마다 재부여돼 개인 수준 분석은 단일 회차 내로 제한된다.

코드북에서 설문 원문을 추출해 프롬프트 코퍼스를 만들었다. 2023년 526개 변수 중 대리응답 문항을 빼고 조건을 적용해 주 문항 303개, 조건부 문항 69개를 확보했다. 결측은 -1(비해당, 89.6%)과 -8(무응답) 두 코드인데, 건너뛰기 규칙에 의한 비해당은 선행 문항으로 이미 확정된 값이라 결측이 아니다.

성별·연령만으로 도달 가능한 개인 예측 정확도 상한(셀 최빈응답 정확도)은 0.5385, 인구통계 미사용 대비 순이익 중앙값은 0이었다. 303개 문항 중 152개는 개선이 없었고 나머지도 평균 1.4%p에 그쳤다. 성별×연령의 응답 분산 설명력(η^2) 중앙값도 0.018로 낮아, 개인 수준 예측에는 인구통계 밖의 추가 정보가 필요함을 시사한다.

이와 별도로 KGSS 2021·2023 자료로 실제 모델 응답을 먼저 돌려봤다. 2021년 profile 1,203명을 전량 사용해 Direct(실제 profile)와 RSS(성별·연령·교육·지역·도시성 주변분포 조합)를 비교했다. 총 18,045건을 독립 zero-shot으로 완료했고 오류·중복은 0건이었다.

조건	요청 수	W1	JS	핵심 해석
Direct	6,015	0.641	0.186	RSS와 평균 분포 차이가 거의 같음
RSS-marginal	12,030	0.640	0.190	일관된 우위는 확인되지 않음

모델이 인간보다 특정 선택지에 훨씬 더 몰린다는 점이 두드러졌다. 인간 최빈 선택지 비율 0.605

대비 Direct 0.777, RSS 0.813이었다. 신뢰 문항은 방향을 어느 정도 따라갔지만 가치판단 문항 (HELPFUL·FAIR)은 차이가 컸다.

표본설계를 더 들여다보면 구조적 제약이 있다. 기숙사·군부대·요양원 거주자와 한국어가 서툰 응답자는 KGSS 모집단에서 애초에 빠져 있어 일부 페르소나는 정의상 구현할 수 없다. 사후층화도 성별·연령·지역·도시성 4개 변수만 써서, 우리 페르소나 변수와는 또 다른 불일치가 있다.

2023년 자료가 이미 LLM 사전학습 데이터에 포함됐을 가능성이 있는데 아직 확인되지 않았다. 확인되면 실험 타당성 자체가 흔들리는 문제라 우선 점검이 필요하다. 2021년 A/B 분할표본으로는 인간의 실제 순서효과를 처음 실측했다. 16개 문항쌍 중 13쌍이 순서 반전 조작이었고, TV거리 0.02~0.06, 국가자긍심 문항은 10개 중 9개에서 방향이 일치했다.

결측치는 -1/-8 코드가 회차 통합 과정에서 섞였을 가능성과 다단 게이트 문항의 역추적 문제가 남아 있고, 필터링 로직은 LLM 입력뿐 아니라 실제 KGSS 분포 계산에도 동일하게 적용해야 한다. 평가지표 쪽에서는 '재검사 신뢰도 대비 정규화 정확도'를 '셀 최빈응답 정확도'로 바꾼 게 단순 우회 아니라 측정 대상 자체를 바꾼 결정이라는 점, η^2 와 LLM 모드 붕괴를 곧바로 인과관계로 읽는 건 아직 검증되지 않은 가설이라는 점을 짚었다.

1.2 활용 모델 및 고도화 계획

본실험 모델로는 오픈웨이트 한국어 모델 EXAONE 3.5(2.4B·7.8B)와 Kanana 1.5(2.1B·8B)를 검토 중이다. 로짓에 직접 접근해 조건부 분포를 얻을 수 있고, 가중치가 고정돼 재현 가능하며, 호출 비용도 없다는 게 이유다. 다항 로지스틱 회귀·랜덤포레스트를 베이스라인으로 두고, 페르소나 조건·인칭·화제·선택지 순서 요인을 스크리닝한 뒤 교차해 본실험으로 넘어갈 계획이다.

이번 주 파일럿에는 고빈도·단문 응답에 맞는 GPT-5.6 Luna를 썼다. 결론이라기보다 실행 가능성과 응답 쓸림을 확인한 1차 베이스라인이며, 학기 중에는 질문 유형·profile 조합의 영향을 비교하고 쓸림을 줄이는 prompt·표본설계·row bootstrap을 검토할 예정이다.

2. 이론적 배경 및 심화 학습

2.1 실리콘 샘플링과 알고리즘적 충실도

실리콘 샘플링은 LLM에 인구통계 특성을 주입해 응답을 생성시키는 방법이다. Argyle et al.(2022)은 LLM을 조건부 확률 계산기로 보고 이 방식이 미국 표본에서 잘 작동한다는 걸 보였고(알고리즘적 충실도 개념 제시), Aher et al.(2023)은 모델이 정교해질수록 인간 패턴을 잘 재현하지만 일부 결과는 오히려 왜곡되며 정렬 학습 고도화가 그 괴리를 키울 수 있다고 지적했다. 각 선택지에 부여된 확률을 직접 볼 수 있어야 이 관점을 제대로 구현할 수 있어 오픈웨이트 모델을 쓰기로 했다.

이번 파일럿의 지표도 같은 맥락이다. W1(Wasserstein distance)은 선택지 비율의 순서상 거리, JS-KL divergence는 분포 차이를 본다. Cramer's V로 인구통계-응답 관계구조 유지 여부를, 최빈 선택지 비율로 쓸림을 봤다. 알고리즘적 충실도 네 기준 중 Pattern Correspondence(Cramer's V)와 Forward Continuity(간접 확인)만 다뤘고, 사람 평가가 필요한 Turing Test·Backward Continuity는 이번엔 하지 않았다.

2.2 모드 붕괴

모드 붕괴는 응답이 최빈값에 몰려 분산이 비현실적으로 작아지는 현상이다. Li & Conrad(2026)는 인구통계만으로 페르소나를 만들면 비슷한 프로필끼리 응답이 수렴한다고 봤고, Heath & Alexander(2026)는 원인을 모델이 분포를 몰라서가 아니라 표집을 못해서라고 진단해 텍스트 응답을 임베딩으로 사후 매핑하는 SSR을 제안했다(KL divergence 최대 1.97→0.07 감소, 단 평균 편향은 남음). 로짓을 직접 보면 표상 문제인지 표집 문제인지 구분할 수 있을 것으로 본다.

2.3 사회적 바람직성 편향과 프롬프트 수준 개입

Sun et al.(2024)은 사회적으로 민감한 주제에서 생성 분포가 가장 저조하다는 걸 harmlessness bias로 이름 붙였고, Chapala et al.(2025)은 다섯 조건 중 삼인칭 재구성만 정렬을 일관되게 개선한다는 걸 확인했다(정직 지시는 오히려 역효과). 다만 영어는 인칭 전환과 평가 프레임 제거가 같이 일어나 두 효과를 분리하기 어렵다. 한국어는 인칭과 화계(상대높임법)가 독립된 문법 범주라, 이를 교차 설계해 어느 요인이 완화를 이끄는지 나눠 볼 계획이다.

2.4 구조적 결측과 스킵 로직

결측치의 구조적 처리 문헌도 찾아봤다. Fagan & Greenberg(1988)는 스킵 패턴을 방향 그래프로 분석해, 게이트 문항에 의한 결측이 무작위(MCAR/MAR)와 다른 구조적 결측(structural missingness)이라고 봤다. Zhang et al.(2024)은 스킵 패턴 변수의 다중대체 방식(IAAC vs IWRNC)이 서로 다른 편향-효율성 특성을 갖는다고 보였다. KGSS의 -1(89.6%)은 이 구조적 결측의 전형적 사례이며, 다만 이 문헌들은 사후 통계처리를, 우리는 LLM 입력 전 필터링을 다룬다는 점에서 다르다.

2.5 LLM의 선택지 순서 민감도와 인간 편향과의 정합성

LLM의 selection bias(positional bias)도 살펴봤다. Zheng et al.(2024)은 이 편향이 주로 선택지 ID 토큰 자체의 확률 편향에서 온다고 보고 PriDe라는 디바이어싱 기법을 제안했고, Pezeshkpour & Hruschka(2024)는 순서만 바뀌도 정확도가 13~85%까지 흔들린다고 보고했다. Tjua et al.(2024)은 인간의 알려진 응답 편향을 LLM이 똑같이 보이진 않는다는 걸 확인했고, Rupprecht et al.(2026)은 모델들이 대체로 마지막 선택지를 선호하는 최신성 편향을 보인다고 밝혔다. 이 연구들은 대부분 인위적 순서 교란(perturbation)에 기반하는데, 우리는 KGSS에 실제로 있는 A/B 분할표본으로 인간의 순서효과를 먼저 실측하고 LLM과 비교한다는 점에서 다르다.

3. 수행 내용 상세

3.1 주요 활동 내역

서베이리서치센터를 통해 자료를 확보하고 python 진단 파이프라인을 구축했다. 코드북 PDF를 파싱해 설문 원문을 추출하고 코드북-원자료 변수명 불일치를 자동 매칭하는 규칙을 만들었으며, KGSS의 2016년 이후 분할표본 설계를 찾아내 A/B 문항쌍 16개 중 13쌍의 반전 조작과 배열효과 크기(TV거리 0.02~0.05)를 산출했다. 진단·추출·선정 단계를 스크립트로 나눠 Git으로 관리했고, 문항 후보 303개·조건부 문항 69개를 분리했으며, 페르소나 변수 3개 이상 교차 시 셀당 표본이 부족해져 프롬프트엔 6개 변수를 쓰되 분포 비교는 성별·연령으로 한정하기로 했다.

KGSS 2021-2023 자료를 codebook과 맞춰 성별·연령대·교육·지역·도시성으로 profile을 구성하고, FINALWT 가중치로 인간 기준분포를 계산했다. 질문마다 독립 zero-shot 요청을 쓰고 request ID=idempotency key로 중복을 막았으며, W1·JS·KL·Cramer's V·bootstrap으로 평가했다. logprob 조

건은 선택지 토큰 누락이 확인돼 민감도 분석 과제로 미뤄졌다.

프로젝트 일정과 결정 이력을 관리하며 매 세션 초반 이전 합의를 재확인하는 역할을 맡았다. 1주차부터 3주차까지 선행연구 검토를 총괄해 이번 주엔 구조적 결측·순서 민감도 문헌을 추가로 조사했고, 매 주차 보고서 간 논리적 정합성을 점검했다. KGSS 데이터를 Jamovi로 따로 불러와 구조·결측 코드 분포를 교차검증했다.

3.2 팀원별 기여

이름	주요 담당 역할
정주희	KGSS 자료 확보·전처리, 코드북 기반 프롬프트 코퍼스 구축, 분할표본·결측 구조 진단, 문항 선정 기준 수립
김태우	선행연구·fidelity 평가를 정리, 프롬프트 설계 및 오염 방지, logprob 설계, GPT-5.6 Luna 파일럿 실행과 결과 기록
허다교	프로젝트 일정 및 의사결정 이력 관리, 선행연구조사 총괄, 보고서 간 정합성 검토, 데이터 교차검증

4. 차후 본 학기 계획

4.1 데이터 및 전처리 보완

-1/-8 결측 코드 혼입 지점을 재점검하고, 다단 게이트를 포함한 필터링 로직을 코드북 기준으로 구현해 LLM 입력과 실제 분포 계산 양쪽에 동일하게 적용한다.

2023년 자료의 사전학습 데이터 오염 여부를 예비 프로빙으로 점검한다.

문항을 무작위로 고르지 않도록 구체적인 선정 기준안을 마련한다.

4.2 모델링 및 실험 설계 확장

페르소나·인칭·화제·선택지 순서 요인 스크리닝을 마치고 교차 본실험으로 넘어가며, 회귀·랜덤포레스트 베이스라인과 EXAONE·Kanana의 예측 정확도를 비교한다.

GPT-5.6 Luna 파일럿에서 드러난 응답 쓸림을 줄이는 prompt·표본설계·row bootstrap을 검토하고,

질문 유형·profile 조합의 영향을 비교하며, logprob 토큰 누락 문제를 해결해 민감도 분석으로 확장한다.

KGSS AB 분할 기반 순서효과 분석(RQ4)을 본실험에 포함할지 팀 합의를 거친다.

4.3 평가체계 정교화

전 회차 공통 문항(약 80개) 중 사회적 바람직성 편향 검증이 가능한 문항을 파악하고, η^2 와 LLM 알고리즘적 충실도의 관계를 문항별 η^2 -JS(또는 KL) divergence 교차분석으로 검증한다.

사람 평가가 필요한 Social Science Turing Test·Backward Continuity 기준을 어떻게 확인할지 설계한다.

참고문헌

- Aher, G., Arriaga, R. I., & Kalai, A. T. (2023). Using Large Language Models to Simulate Multiple Humans and Replicate Human Subject Studies. arXiv:2208.10264.
- Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J., Rytting, C., & Wingate, D. (2022). Out of one, many: Using language models to simulate human samples. arXiv.
- Chapala, S. et al. (2025). Mitigating Social Desirability Bias in Random Silicon Sampling.
- Fagan, J., & Greenberg, B. V. (1988). Using Graph Theory to Analyze Skip Patterns in Questionnaires. U.S. Census Bureau, Statistical Research Division Report Series, RR-88/06.
- Heath, & Alexander (2026). Correcting Mode Collapse in Silicon Sampling with Semantic Similarity Rating.
- Li, & Conrad (2026). Persona-Based Simulation of Human Opinion at Population Scale.
- Pezeshkpour, P., & Hruschka, E. (2024). Large Language Models Sensitivity to The Order of Options in Multiple-Choice Questions. Findings of the Association for Computational Linguistics: NAACL 2024, 2006–2017.
- Rupprecht, J., Ahnert, G., & Strohmaier, M. (2026). Prompt Perturbations Reveal Human-Like Biases in Large Language Model Survey Responses. arXiv preprint.
- Sun, et al. (2024). (harmlessness bias 관련 문헌, 2주차 선행연구조사 보고서 참고)
- Tjuatja, L., Chen, V., Wu, S. T., Talwalkar, A., & Neubig, G. (2024). Do LLMs Exhibit Human-like Response Biases? A Case Study in Survey Design. Transactions of the Association for Computational Linguistics, 12, 1011–1026.

Zhang, G., He, Y., Cai, B., Moriarity, C., Shin, H.-C., Parsons, V., & Irimata, K. E. (2024). Multiple imputation of missing data with skip-pattern covariates: a comparison of alternative strategies. *Journal of Statistical Computation and Simulation*, 94(7), 1543–1570.

Zheng, C., Zhou, H., Meng, F., Zhou, J., & Huang, M. (2024). Large Language Models Are Not Robust Multiple Choice Selectors. *Proceedings of ICLR 2024* (arXiv:2309.03882).

회의사진(부록)

