


KOSMOS 2026 정기세션 · 1주차 발표

한국형 실리콘 샘플링 검증

KGSS 기반 집단 응답분포 재현도 분석

김태우 · 정주희 · 허다교

2026



목차

오늘 다룰 내용

01 이번 주 업데이트

오염 프로빙 재실행, 인칭×화계 파일럿

02 새로 찾은 선행연구

Silicon Sampling in Seoul

03 다음 단계

팀 논의와 남은 과제

01 · 이번 주

확인하고 정리에 집중한 한 주였습니다

지난 3주간 데이터 정비와 첫 파일럿을 마쳤고, 이번 주는 그 위에서 세 갈래로 점검을 더했습니다.

~20문항

오염 프로빙 (R/B/C) 재실행

4문항

인칭×화계 파일럿

1편

신규 선행연구 검토



아직 **확정 결론은 아니며**, 규모 확대와 설계 보완이 필요한 중간 점검입니다.

세 가지 각도에서 찢어봤습니다

만약 KGSS 2023 자료가 모델의 사전학습 데이터에 이미 포함돼 있다면, 우리가 보는 건 ‘추론’이 아니라 ‘암기’의 재현일 수 있습니다.



A. 로짓 기반 분포 재현

번호만 답하게 강제한 뒤 선택지 숫자 토큰의 확률을 정규화해 실제 응답 분포와 비교합니다.



B. 원문 완성

설문 문장 앞부분만 주고 뒷부분을 잇게 한 뒤, 실제 원문과 문자열 유사도를 비교합니다.



C. 선택지 배열 재현

섞어놓은 선택지를 원래 순서로 재배열시켜, 우연히 맞을 확률과 비교합니다.

세 방법 모두 유의한 오염 신호는 없었습니다

출처를 밝힌 프롬프트와 밝히지 않은 프롬프트를 비교해, 밝혔을 때만 결과가 좋아지면 오염 의심입니다. 세 방법 모두 그런 신호는 없었습니다.

$p=.33 / .43$

A. 로짓기반 (EXRONE / Kanana)

$p=.059 / .13$

B. 원문완성 (EXRONE / Kanana)

20% / 10%

C. 선택지배열 (우연 12.4%)



가장 근접한 값(B, EXRONE)도 $p=.059$ 로 다중비교 미보정 상태 — **규모 확대와 보정이 다음 과제입니다.**

사회적으로 민감한 문항 4개로 조합을 시범 실행했습니다

인칭은 응답자를 1인칭(‘저는’)으로 답하게 할지 3인칭(‘그는’)으로 답하게 할지, 화계는 하십시오체(높임)와 해라체(반말) 중 무엇을 쓸지의 문제입니다.

1인칭

하십시오체 (기준 조건)

1인칭

해라체

3인칭

하십시오체

3인칭

해라체 (자연스러움 미확인)



문항 4개로는 **방향성조차 판단하기 어려움** — 민감 문항 선정 기준부터 정해야 합니다.

Silicon Sampling in Seoul (Kim, Park & Suh, 2026)

한국인 연구자가 2024 서울서베이(확률표본 5,000명)를 기준으로, LLM에 페르소나를 얼마나 자세히 줘야 하는지 검증한 논문입니다.

5,000명

2024 서울서베이 확률표본

24개

태도·행동 문항

C0/C1/C2

페르소나 조건 3단계 ablation




한국인 연구자가 확률표본으로 검증한 최근접 사례 — 우리 프로젝트와 방법론이 가장 가까운 선행연구입니다.


조건은 순서를 사고, 서사는 둘 다 해칩니다

인구통계 조건(C1)이 순서는 잡지만, 수준 적합도는 **무조건(C0)**이 가장 좋았습니다 — 서사(C2)는 둘 다 악화시켰습니다.

population TVD (낮을수록 좋음)



subgroup 추적력 r (높을수록 좋음)



다섯 가지 발견 — 조건부여의 트레이드오프 (1/2)

다섯 가지 발견 중 앞의 세 가지입니다 — 조건을 줄수록 무엇을 얻고 무엇을 잃는지에 관한 내용입니다.



① 조건은 순서를 사고 보정을 판다

인구통계 조건(C1)이 셀 추적력을 $r \approx 0 \rightarrow 0.42$ 로 올리지만, 모집단 수준 적합도는 오히려 무조건(C0)이 더 좋았습니다.



② 합성 서사는 순손해

서사를 더할수록(C2) 두 지표 모두 나빠지고, 교육차별 같은 민감 문항은 방향이 반전($r\ 0.81 \rightarrow -0.57$)되기도 했습니다.



③ 하이브리드 추정량이 둘 다 잡는다

C0로 수준을 앵커링하고 C1의 상대적 편차를 없으면, 추가 비용 없이 수준적합과 순서추적을 동시에 얻습니다.

다섯 가지 발견 — 어디까지 적용되는가 (2/2)

나머지 두 가지입니다 — 이 결과가 어떤 문항, 어떤 모델까지 적용되는지에 관한 스코프입니다.



④ 재현성은 문항 유형의 속성

연령그라디언트 행동문항(모바일결제 $r=.98$)은 신뢰할 수 있지만, 가격인식 같은 경험적 문항은 모든 조건에서 실패했습니다.



⑤ 발견은 능력 있는 모델에 한정

오픈웨이트 2종(EXAONE 3.5, Qwen3)은 셀 추적력이 상용모델의 1/3~1/8 수준으로, 모델 크기로는 설명되지 않았습니다.



즉 이번 검증은 상용급 능력을 가진 모델에서만 성립합니다
우리 본실험 모델(EXAONE)의 사전검증이 필요한 이유입니다.

우리 실험 설계에 바로 반영할 수 있는 세 가지

이 논문의 발견을 KGSS 실험 설계에 그대로 적용할 수 있는 지점 세 가지를 정리했습니다.



CO(페르소나 없음) 대조군 도입

운영진 지적 Q1·Q2에 대응하고, 셀 수준 Pearson r 지표의 타당성을 검증하는 기준값으로도 필요합니다.



verbalized probability vector 검토

로짓 없이 확률벡터를 직접 요청하는 방식 — top_logprobs 상한으로 선택지 토큰이 누락되는 문제의 대안입니다.



EXPLONE 3.5 7.8B 능력 사전검증

Seoul 논문에서 셀 추적력이 상용모델의 1/8($r=0.05$)이었습니다 — 본실험 투입 전 확인이 필요합니다.

다음 세션까지 할 일



오염 프로빙 규모 확대 + 다중비교 보정 적용



CO(페르소나 없음) 대조군을 실험 설계에 추가



인칭 × 화계 민감 문항 선정 기준 문서화



3인칭 × 해라체 표현의 자연스러움 확인



셀 수준(성별 × 연령) Pearson r 검증 설계 착수

마무리

이번 주는 확인과 정리, 다음 주는 설계와 실행입니다

감사합니다