


KOSMOS 2026 정기세션 · 2주차 발표

한국형 실리콘 샘플링 검증

KGSS 기반 집단 응답분포 재현도 분석

김태우 · 정주희 · 허다교 · 이지은

2026



목차

오늘 다룰 내용

01 오염 프로빙 재검증

버그 발견과 결론 수정

02 문항 선정

3인 태깅과 일치도

03 대조군 4수준 첫 결과

C0 → adult → demo → full

04 다음 단계

모델 규모와 남은 과제

01 · 지난 2주

결론 하나가 뒤집혔고, 첫 본실험급 결과가 나왔습니다

지난 세션에서 ‘오염 신호 없음’으로 보고드렸는데, 그 프로브 자체에 버그가 있었습니다. 동시에 대조군 4수준을 전부 돌려 첫 정량 결과를 얻었습니다.



오염 프로빙 재검증

선택지에 ‘모르겠다’·비해당 코드가 섞여 있던 버그를 발견해 수정하고, $n=118$ 로 재실행했습니다.



문항 선정 기준 확정

후보 220문항을 3인이 독립 태깅했고, 일치도가 낮아 과반 기준으로 규칙을 바꿨습니다.



대조군 4수준 실행

C0 · adult · demo · full 네 조건을 두 모델로 모두 돌려 재현도를 처음으로 수치화했습니다.

지난 세션에서 보고한 프로브에 버그가 있었습니다

모델에게 보여준 선택지 목록에 실제 응답 선택지가 아닌 코드가 섞여 들어가 있었습니다. 확률을 정규화하는 분모가 오염된 상태로 140문항이 돌아갔습니다.



무엇이 잘못됐나

‘모르겠다’·비해당 등 결측 코드가 선택지로 제시됐습니다 — 실제 응답 분포에는 없는 항목입니다.



어떻게 고쳤나

선택지 코드 1~9만 남기도록 수정하고, 그 조건을 만족하는 118문항으로 R·C·E를 재실행했습니다.



지난 세션에서 보고드린 **로짓 기반·원문 완성 결과는 이 버그의 영향을 받았습니다.**

재실행하니 오염 증거는 오히려 더 약해졌습니다

진짜 출처(KGSS)를 밝힌 프롬프트와 가짜 출처를 낸 프롬프트를 비교해, 진짜일 때만 결과가 좋아지면 오염 의심입니다.

$p = .104$

A. 로짓기반 EXRONE
이전 $p = .039$

$p = .801$

A. 로짓기반 Kanana
TOST 동등성 확인

차이 없음

E. 직접회상
 $p = .747 / .197$

2.0배

C. 선택지순서 EXRONE
보조지표



Kanana는 **오염 없음**을 적극적으로 주장 가능, EXRONE은 **증거 없음** 수준까지입니다.

EXAONE만 동등성 검정을 못 했습니다

‘차이가 없다’를 적극적으로 보이려면 동등성 검정(TOST)이 필요한데, 지금 문항 수로는 검정력이 부족합니다.

216

$dz = 0.2$, 검정력 80% 확보에 필요한 최소 문항 수 (현재 118문항)



본실험 문항 세트가 커지면 **같은 프로브를 그대로 재활용해 자동으로 해결됩니다.**

02 · 문항 선정

문항 선정을 3인 독립 태깅으로 문서화했습니다

‘무작위 지양’이라는 말 대신, 누가 무엇을 기준으로 골랐는지 재현 가능한 절차로 바꿨습니다.

303개



2023년 회차 후보

결측·공통문항 정리 후 남은 전체 후보 문항

220개



배터리 중복 제거

사실 66 · 차별 11 · 가치관 143로 자동 분류

3인 태깅



독립 라벨링 후 병합

각자 민감 여부를 표기하고 다수결로 통합

민감 여부는 사람마다 같았습니다

문항 유형(사실·차별·가치관) 분류는 일치도가 쓸 만했지만, ‘이 문항이 민감한가’는 그렇지 않았습니다.

0.38–0.55

민감 여부 태깅 일치도 — Cohen’s κ

양호

문항 유형 분류 일치도

38개

민감 다수결 Y — 220문항 중



단일 판정을 포기하고 **3인 중 2인 이상(과반) 기준**으로 확정 — 기준 자체를 결과로 보고합니다.

페르소나 정보량을 네 단계로 쌓아 올렸습니다

같은 응답자 표본을 네 조건에 전부 재사용해, 조건 간 대응비교가 가능하게 설계했습니다.

C0

페르소나 없음

adult

“당신은 한국 성인입니다”

demo

성별 + 나이
(24/35/45/55/70세)

full

6변수 서사형 문장




full 예시 — “당신은 63세 여자입니다. 초등(국민)학교를 졸업했고 충청에 거주하며 기혼입니다.”

03 · 첫 결과


정보를 늘릴수록 개선되는 건 통계적으로 실재합니다

네 조건의 Wasserstein 거리입니다. C0에서 full로 갈수록 값이 내려가고(개선), 두 모델 모두 같은 방향으로 움직입니다.

Wasserstein — EXAONE 2.4B (낮을수록 좋음)



Wasserstein — Kanana 2.1B (낮을수록 좋음)



대응표본 t-test (C0 vs full) — Wasserstein **EXAONE** $p=1.4e-09$ · **Kanana** $p=4.0e-05$, subgroup r $p=.050$ · $p=.006$

03 · 첫 결과

그런데 그 개선은 ‘찍기’보다도 못한 지점에 도달했습니다

같은 255문항에 대해 아무 정보 없이 균등하게 찍는 기준선과, 실제 최빈범주를 100% 확신하고 찍는 오라클급 상한을 계산해 나란히 놓았습니다. 모두 Wasserstein 거리라, 막대가 짧을수록 좋습니다.



‘많이 좋아졌다’가 아니라 ‘훨씬 나빴던 게 조금 덜 나빠졌는데 여전히 아무 생각 없이 찍는 것보다 못하다’가 정확한 서술입니다.

원인은 모두 붕괴였고, 출력 엔트로피로 직접 확인했습니다

모델은 문항마다 1.4~2개 선택지로 좁게 쏠려 자신 있게 답합니다 — 그 확신이 자주 틀린 곳을 가리키니 균등하게 찍는 것보다 거리 비용이 더 듭니다.

1.53 bit

인간 응답 (유효 선택지 2.89개)

0.63–0.68배

EXAONE 2.4B — 인간 대비

0.30–0.33배

Kanana 2.1B — 인간 대비



붕괴 정도가 네 조건 내내 거의 움직이지 않습니다 — 페르소나 정보량과 무관한 성질(성분②)입니다.

서울 논문도 EXAONE 7.8B · Qwen3-30B에서 subgroup r 0.05–0.12로 보고 — 모델 크기만의 문제는 아닐 가능성

온도를 올리면 기준선은 넘지만, 정작 중요한 지표는 나빠집니다

이미 받아둔 로짓을 재정규화하는 것만으로, 재실행 없이 디코딩 온도의 효과를 탐색해봤습니다.



되는 것 — population 지표

EXRONE $T \approx 3.0$ 에서 0.660, Kanana $T \approx 4.0$ 에서 0.646으로 균등분포 기준선(0.677)을 실제로 역전합니다.



안 되는 것 — subgroup 지표

같은 구간에서 subgroup r은 오히려 더 나빠집니다. 하위집단 구분력은 온도로 사지 못합니다.



두 지표가 서로 다른 방향으로 움직입니다 — 다음 실험의 1순위 질문입니다.

04 · 다음 단계

모델 크기 때문인지는 이 데이터만으로 답할 수 없습니다

크기가 거의 같은 EXAONE 2.4B와 Kanana 2.1B의 붕괴 정도가 2배 넘게 차이 납니다 — 크기 말고 정렬 같은 다른 요인이 작동할 가능성이 있습니다.



규모 축을 2B / 8B / 30B급으로 확장

같은 파이프라인을 EXAONE 7.8B · Kanana 8B · Qwen 30B급으로 올려 크기 효과를 분리합니다.



한국어 선택지 다중토큰 문제는 번호 응답으로 해결

선택지 앞에 1~k 번호를 붙여 번호만 답하게 하면, top-k 로그확률에서 누락되지 않습니다.



실행 환경이 T4에서 확장됐습니다

A5000 · RTX 4000 Ada 서버를 확보해, 그동안 메모리 때문에 미뤄둔 8B급 실행이 가능해졌습니다.

다음 세션까지 할 일



최종 30문항 확정 (유형별 10개, 배터리당 1개)



EXRONE 동등성 재검정 — 216문항 이상 확보



온도 × subgroup r 동시 탐색



8B급 모델에 동일 파이프라인 적용



본실험 프롬프트 생성 → 로짓 추출

개선은 실재하지만, 아직 기준선 아래입니다

질문과 피드백 환영합니다 — KOSMOS