

KOSMOS 2026 정기세션 · 중간 발표

한국형 실리콘 샘플링 검증

KGSS 기반 집단 응답분포 재현도 분석

김태우 · 이지은 · 정주희 · 허다교

2026



중간 검증 결과와 남은 과제

01	연구 배경과 질문	실리콘 샘플링, 선행연구, 세 가지 연구 질문
02	데이터와 실험 설계	KGSS, 문항 선정, 페르소나 4수준
03	중간 분석 결과	분포 재현, 모드 붕괴, 개인 예측, 순서 효과
04	추가 점검	사전학습 오염 재검증, 인칭x화계 파일럿
05	향후 계획	남은 과제와 추진 일정

세 가지 질문으로 검증했습니다

비용·속도는 매력적이지만, 분산 붕괴·형식 민감도와 한국어 검증 공백이 남아 있습니다.

RQ1 · 타당성

KGSS 모집단 응답분포를 재현하는가?

RQ1은 RQ2·RQ3의 전제조건입니다.

RQ2 · 조건화

정보를 더 주면 분포·개인예측이 좋아지는가?

RQ3 · 화계

인칭·화계를 바꾸면 민감 문항 응답이 이동하는가?



KGSS 확률표본을 기준으로 설문 재현 능력과 실패 원인을 분해해 검증합니다.
정보 부족, 척도 표현, 내용 편향, 형식 민감도를 나눠서 봅니다.

상세한 정보가 항상 좋은 건 아니었습니다

측정된 상세정보와 생성된 상세정보는 다른 결과를 보였습니다.

Park et al. (2024)

실제 개인

1,052명

2시간 심층면접

→ 측정된 상세정보는 도움

Kim, Park & Suh (2026)

TVD

+0.031

subgroup Δr

-0.067

합성 서사 추가 2024 서울서베이 n = 5,000

→ 생성된 상세정보는 악화

차별점 전국 KGSS 17회차 · 정보량 4수준 · 한국어 인칭×화계



중요한 건 상세도보다 “어디서 온 정보인가”일 수 있습니다.

full = 합성서사가 아니라 실제 KGSS에서 측정된 6변수

세 가지 분석세트로 검증했습니다

KGSS 17회차 · 누적 23,282개 관측치 · 2023년 표본 1,230명



303개

후보 문항

응답률 $\geq 90\%$ · 비해당 $\leq 5\%$ · 선택지 2-7개



255문항

타당성 검증

4수준별 모집단 분포 재현



29문항

본실험

3인 독립 태깅·다수결 · 개인예측 · 인칭×화계




서로 다른 분석세트입니다. 실제 기준분포는 FINALWT 가중치를 적용했습니다.

정보량과 말하는 방식을 따로 조작했습니다

EXAONE 3.5 2.4B · Kanana 1.5 2.1B

정보량 · 페르소나 4수준



실제 KGSS 행 · FINALWT 비례 복원추출
n = 200 · seed = 42 · 동일한 200명을 모든 조건에 재사용

인칭×화제 4조건

	하십시오체	해라체
당신	A 기준	B 격식↓
이 사람	C 대상화	D 거리 최대

- D 조건 · 자연스러움 확인 필요

텍스트 대신 로짓으로 응답분포를 읽었습니다



실제 척도 선택지 20개 → 모든 선택지가 2 token 이상

4.1 token **5.8 token**

EXAONE 평균 Kanana 평균

숫자는 두 모델 모두 단일 token

1-9 **0.983-1.0** **0.9998-1.0**

숫자 EXAONE 첫 토큰 확률질량 Kanana 첫 토큰 확률질량



숫자 로짓을 softmax해 예측 응답분포를 얻습니다.

사람을 기준으로 보면, 특정 문항이 크게 흔들렸습니다


선택지 순서효과: 인간 TV 중앙값 0.036 · 실제 역전 13쌍 · 13쌍 기반 탐색적 관측

성별×연령 셀 최빈 정확도

0.5385

전체 최빈 정확도	0.5293
인구통계 순이익 중앙값	0

인간 배율




인간보다 큰 문항 EXAONE 4 / 13 · Kanana 5 / 13



중앙값은 인간보다 작았지만, 특정 문항에서는 수십 배였습니다.
1x = 인간과 동일한 효과 · 최대값 문항: 두 모델 모두 PROUDPOL16

정보를 주면 좋아졌지만, 기준선은 못 넘었습니다

Wasserstein distance · 낮을수록 좋음 · 255문항



C0 vs full

EXAONE $t = 6.28 \cdot p = 1.4 \times 10^{-9}$

Kanana $t = 4.18 \cdot p = 4.0 \times 10^{-5}$

Uniform < EXAONE full < Kanana full

Oracle 0.590

full subgroup r

EXAONE 0.001 · Kanana 0.026

하위집단 차이도 거의 재현하지 못했습니다.



통계적으로 좋아졌지만, 가장 좋은 조건도 무정보 기준선보다 못했습니다.

문제는 너무 확신하는 쪽에 가까웠습니다

정보량을 늘려도 붕괴 정도는 거의 변하지 않았습니다.



분포 형태 개념도 · 실제 문항별 확률 아님

C0 logits · Temperature rescaling

EXAONE $T \approx 3.0 \rightarrow W = 0.660$

Kanana $T \approx 4.0 \rightarrow W = 0.646$



Uniform 0.677보다 낮아짐 → 모집단 Wasserstein에서는 기준선 역전
단순 정보 부족만으로 설명되지 않습니다.

실제 6변수를 주자, EXAONE 개인예측이 좋아졌습니다

29문항 · 정규화 정확도 · persona bootstrap 2,000회 · 탐색적 결과

full – demo


+0.059

95% CI [+0.013, +0.114]

full – C0 **+0.052** [+0.001, +0.111]

demo – C0 -0.007 [-0.079, +0.058]

EXAONE 정규화 정확도



Kanana: 세 대비 모두 CI에 0 포함 → 조건 간 차이 확인되지 않음



성별·연령만 준 demo는 이득이 없었습니다. 실제 측정된 6변수를 함께 제공했을 때 효과가 관측됐습니다.

응답은 움직였지만, 화계 가설은 안 맞았습니다

외국인 이민자 관련 민감문항 4개

 A 당신 × 하십시오체 →  D 이 사람 × 해라체

‘반대’ 방향 이동

4 / 4

EXAONE

3 / 4

Kanana

그러나

EXAONE D: 4문항 중 3문항에서
인간분포와 더 멀어짐

→ 사회적 거리 가설 미지지

H5 · 민감 문항 9개

0.208 → 0.149

Kanana full 승인편차 · 당신 → 이 사람

검정 미실시 · 해라체 효과는 작음



파일럿·H5 모두 탐색적 관측입니다. 인칭·화계 수용성 평정 후 본검증이 필요합니다.

뚜렷한 증거는 없지만, 완전히 배제하진 못했습니다

버그 발견

A probe 351행 중 216행에 결측코드 버그



수정



재실행

A·C·E 재실행 n = 140

A · 로짓 기반 분포 재현

뚜렷한 증거 없음

EXAONE p = .104 · Kanana p = .801 · TOST p = .029

C · EXAONE 선택지 순서 정확일치

29.3% 우연 기대 12.7%

통계검정 없는 보조신호



사전학습 오염을 완전히 배제할 수 없습니다.

"증거 없음"을 "오염 없음"으로 해석하지 않습니다.

이제 탐색적 신호를 본검증으로 넘깁니다

핵심 재검증 대상: EXAONE full-demo +0.059

	설계 확정	수용성 평정 민감 기준 재태깅
	사전등록 · 본검증	가설·지표·검정 방법 고정 문항·페르소나 확대 +0.059 재검증
	모델 확장	EXAONE 7.8B Kanana 8B Qwen2.5-3B
	보정 · 형식 민감도	temperature 형식 민감도 본검증

 **한계** 검정력 제한, 정밀도 점검 200건 한정, 6변수 목록 확정 전, 인칭·화계/민감 기준 확정 전, 오염 완전 배제 불가

**분포 재현은 무정보 기준선보다 못했지만,
실제 6변수에선 조건화 신호가 보였습니다**

탐색적 결과 · 사전등록 후 재검증 필요

질문과 피드백 환영합니다 — KOSMOS