KOSMOS 2026 정기세션 · 3주차 발표

한국형 실리콘 샘플링 검증

KGSS 기반 집단 응답분포 재현도 분석

김태우 · 이지은 · 정주희 · 허다교

2026

목차

중간발표 이후 진행 상황과 남은 과제

01	지난 발표 요약	실리콘 샘플링, 균등 기준선, 응답 쏠림
02	평가 방식 재점검	비교 집단과 평균 순서, 온도 보정 교차검증
03	후속 탐색 분석	개인 응답 평가와 민감 문항의 바람직성 편향
04	250문항 확장 실험	모델 4개 실행과 숫자 선택지 확률(mass) 점검
05	분석 계획과 다음 세션 목표	화계·인칭 검정, mass 기준별 비교, 민감 문항 검토

01 · 지난 발표 요약

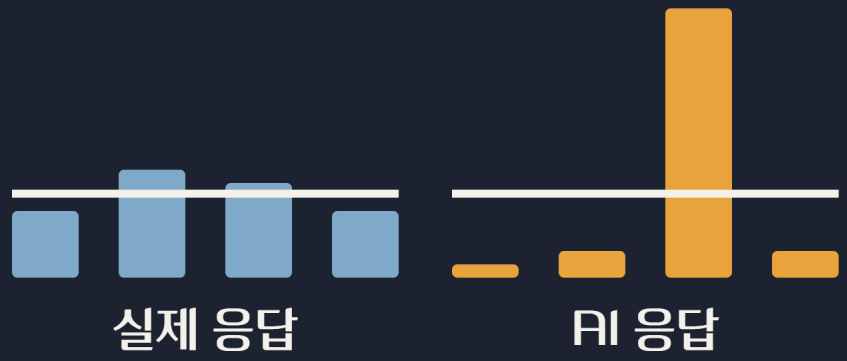
지난 발표에서는 응답 쏠림이 남았습니다

응답 분포를 AI로 얻는 방법과, 지난 발표 결과를 정리합니다.

실리콘 샘플링
역할을 준 AI의 답으로 설문 분포를 얻는 방법

비교 기준
KGSS 2023 실제 응답 분포

균등 기준선
선택지가 4개라면 각각 25%를 주는 기준



개념도(실제 수치 아님) · 가로선은 균등 기준선 25%

비교 집단과 평균 순서를 따로 점검했습니다

비교 대상과 평균을 내는 순서를 나눠서 다시 살펴봤습니다.

문제 제기

비교 대상이 전체 분포 또는 성별·연령 집단이었습니다

예: 학력까지 준 AI를 성별·연령만 같은 집단과 비교한 경우입니다.
재실험은 이 어긋남이 점수를 왜곡했다고 봅니다.

후속 분석

비교 집단을 맞춘 효과는 거의 0이었습니다

기존 지표 차이는 주로 응답을 먼저 평균 낸 효과였습니다.
확장 실험 이전, Wasserstein 거리 기준입니다.

이 분석은 Wasserstein 거리, 다음 장의 재실험은 TVD로 평가했습니다

02 · 온도 보정

온도 보정 후 TVD가 교차검증에서도 개선됐습니다

재실험(10.10)의 5-fold 교차검증(OOF) 결과입니다.

모델	조건	보정 전	보정 후 (5-fold OOF)
EXAONE 2.4B	역할 없음	0.4373	**0.3335**
EXAONE 2.4B	성별+연령+학력+혼인	0.3816	**0.3066**
Kanana 2.1B	역할 없음	0.5705	**0.3441**
Kanana 2.1B	성별+연령+학력+혼인	0.5223	**0.3099**

TVD는 낮을수록 좋습니다. 표의 네 조건 모두 보정 후 TVD가 균등 기준선 0.3740보다 낮았습니다.
TVD · 소형 2개 모델 · 비교 집단은 성별+연령 고정 · 온도를 고를 때 쓰지 않은 데이터에서 평가

개인 응답엔 한계가, 민감 문항엔 편향이 보였습니다

확장 실험 이전의 탐색 분석이며, 확장 결과가 아닙니다.

개인 응답 평가

과한 확신은 줄었지만 위치 오차는 남았습니다

응답자 한 명 한 명의 실제 답으로 평가했을 때, 온도는 과신만 줄이고
고르는 답 자체의 오차(위치 오차)는 고치지 못했습니다.

민감 문항 탐색

바람직성 편향이 4개 모델에서 공통으로 나타났습니다

역할을 주지 않은 조건(C0)에서도 같은 방향이었습니다.
'바람직한' 방향은 연구자가 정한 가정입니다.

04 · 250문항 확장 실험

250문항을 모델 4개에서 실행했습니다

한국 성인·성별×연령에만 인칭·화계 4조합을 적용했고, 6변수 조건은 이번 실행 범위에 포함되지 않았습니다.

250	4	15,250
문항	모델	모델당 프롬프트

구성	역할 없음 250 + 한국 성인 1,000 + 성별×연령 14,000
모델	EXAONE 2.4B · 7.8B, Kanana 2.1B · 8B
조건	인칭(2인칭·3인칭) × 화계(해라체·하십시오체)

3인칭에서 숫자 선택지 확률이 더 자주 낮았습니다

EXAONE 7.8B 기준이며, mass는 숫자 선택지에 배정된 확률의 합입니다.

mass: 숫자 선택지 전체 확률

낮을수록 확률의 일부가
숫자 선택지 밖에 놓였다는 뜻입니다.

선택지 안의 분포

숫자 선택지 안에서
어느 답에 무게를 뒀는지 보여 줍니다.

9.4%

mass 0.9 미만 프롬프트 비율

69문항

250문항 중 한 번이라도 발생

3인칭

2인칭보다 더 잦았습니다

화계·인칭 효과와 mass 기준별 결론을 봅니다

완료	250문항 · 4개 모델 실행
검정 계획	주 분석: 화계·인칭 이중차분 보조 분석: 연령별 화계 효과, 동등성 검정
mass 기준	0.5를 주 기준, 0.7 · 0.9를 민감도 분석으로 봅니다 기준 미만이 한 번이라도 나온 문항 제외 시 28 · 40 · 69개 (민감 문항 1 · 1 · 3개)
응답 방향	민감 문항마다 각자 먼저 검토한 뒤 합쳐서 정합니다

검정은 예정이며, 주·보조 분석 구분과 mass 기준은 결과를 보기 전에 정하자는 제안입니다

05 · 다음 세션

다음 세션까지의 목표

일정은 아직 정해지지 않았으며, 아래 세 가지를 공유하는 것이 목표입니다.

화계·인칭	**모델별 효과 결과표** 4개 모델 각각의 화계 효과와 인칭 효과를 나란히 보여줍니다
mass 기준	**기준별 비교표** 0.5 · 0.7 · 0.9 기준별 결론을 비교합니다
응답 방향	**민감 문항별 검토표** 문항마다 바람직한 방향을 팀원이 각자 검토한 결과입니다

주 분석과 보조 분석의 구분은 **팀에서 합의**할 사항입니다

집단 분포는 개선됐지만, 개인 응답 오차는 남았습니다

질문과 피드백 환영합니다 — KOSMOS