KOSMOS 2026 정기세션 · 4주차 발표

한국형 실리콘 샘플링 검증

KGSS 기반 집단 응답분포 재현도 분석

정주희 · 김태우 · 이지은 · 허다교

2026

목차

분석 구조 재설계와 이번 주 분석 결과

01 분석 구조 재설계 — 기존 분석의 문제점과 새로운 분석 체계

02 사전등록 분석과 선택지 순서 — 사전등록·mass 점검, C1 선택지 순서

03 인칭·화계 효과 검증 — C2 출력 변화와 KGSS 분포와의 거리

04 종합 결론 — 주요 발견과 해석상 한계

원인 분리가 어려워 분석 구조를 재설계했습니다

정보 부족, 모드 붕괴, 사회적 바람직성 편향, 형식 민감도 네 가지 가능한 원인을 검토했습니다.

비독립성	**temperature를 바꾸면 평균도 함께 바뀌었습니다** 위치 항 비중이 낮게 잡히고, 평균과 분산이 함께 움직였습니다.
인간 기준선	**13쌍 모두 표본 잡음과 구별되지 않았습니다** 계산 기준이 달라 배율이 의미 없었고, 우연 확률 계산도 재검토 대상입니다.
형식 효과	**화계 효과는 거의 0, 인칭 효과는 작았습니다** 화계는 방향도 반대였고, 인칭은 방향은 맞았지만 크기가 작았습니다.
가설 형태	**동등성 검정 없이는 지지할 수 없었습니다** 다른 효과와 섞여 확인하기 어려운 가설도 있었습니다.

분석 목적에 따라 A·B·C1·C2로 나눴습니다

원인별 분해 대신 연구 질문과 평가 지표를 구분했습니다.

A	**기술 분석** 분포는 어떻게 다른가?	$WJ1$·$WJ2^2$ 항, 최빈 일치율, NLL을 온도 보정 전후로 비교
B	**인구통계 조건화** 페르소나는 얼마나 유용한가?	페르소나 이득(G_m)을 셀분포 이득(G_c)과 비교 5-fold CV, $G_m - 0.25 \times G_c$ 상한이 0보다 작은지
C1	**선택지 순서** 인간과 모델은 어떻게 반응하는가?	12쌍 평균차를 주 검정으로 사용 인간 쪽 불확실성은 응답자 부트스트랩으로 반영
C2	**인칭·화계** 표현을 바꾸면 KGSS와의 거리가 달라지는가?	당신·하십시오체 기준, 인칭·화계를 하나씩 변경 KGSS와의 $WJ1$ 변화량, TOST 동등성 검정

지난주 분석에서는 가설 지지 근거를 얻지 못했습니다

사전등록한 검정의 결과를 정리합니다.

이중차분

4개 모델 × 2개 검정 모두 본페로니를 통과하지 못했습니다

인칭은 4개 모델 모두 음수, 민감 문항에서 실제 분포에 가까워지는 방향
다만 독립적으로 보기는 어렵습니다.

연령 계수

연령 계수는 거의 0이었습니다

연령 관련 가설은 지지되지 않았습니다.

화계 점검

화계 TV 〈 0.02 동등성은 4개 모델 모두 통과하지 못했습니다

화계 TV 평균은 0.020–0.028로, 출력을 무시할 만큼만 바꾼다고 말할 수 없습니다.

mass 기준을 바꿔도 이중차분 결론은 같았습니다

mass는 숫자 선택지에 배정된 확률의 합입니다.

EXAONE 7.8B · mass 0.9 미만 프롬프트 비율

3인칭 조건	2인칭 조건
15%	3.5%

대부분 비민감·사실 문항이었습니다.

mass 기준	0.5 · 0.7 · 0.9에서 결론이 모두 같았습니다
경계 수준	Kanana 2.1B 화계 p=.016 · Kanana 8B 인칭 p=.014 본페로니 기준은 통과하지 못했습니다.

순서효과는 EXAONE 7.8B에서 인간보다 컸습니다

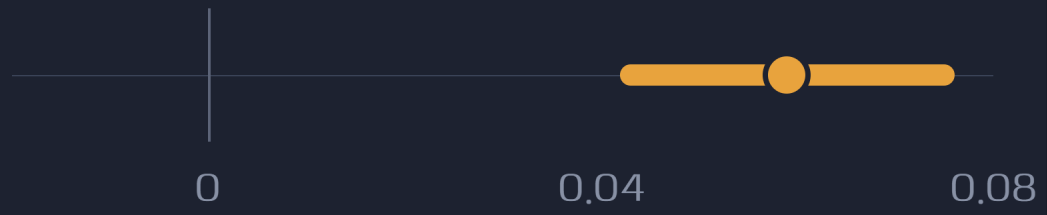
Δ̄는 12쌍 평균차이며, 양수는 모델의 순서효과가 더 크다는 뜻입니다.

EXAONE 7.8B

Holm 기각

+0.059

95% 구간 [0.042, 0.076]

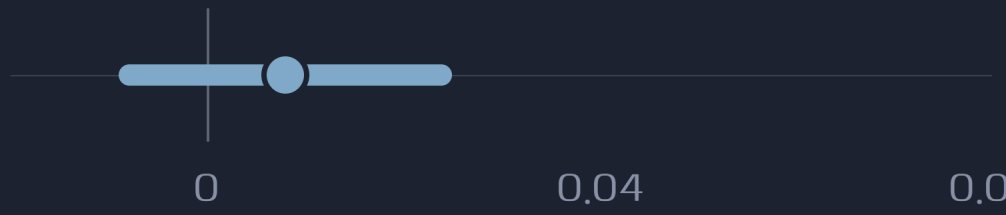


Kanana 8B

기각 못함

+0.008

95% 구간 [−0.009, 0.025]



0은 모델과 인간의 순서효과가 같은 지점이며, 막대는 95% 구간입니다.

문항쌍별로 보면 모델마다 양상이 달랐습니다

12개 문항쌍을 모델별로 나눠 확인했습니다.

EXAONE 7.8B

0.94

NUKPLT10의 모델 TV
(나머지 10쌍은 거의 0)

NUKPLT10과 PROUDMIL16이
대부분을 차지했습니다

Kanana 8B

5/12

부호 일치 · 평균 |차이| 0.030

NUKPLT10만 크게 흔들려
평균이 상쇄됐습니다

인간 기준

1/12

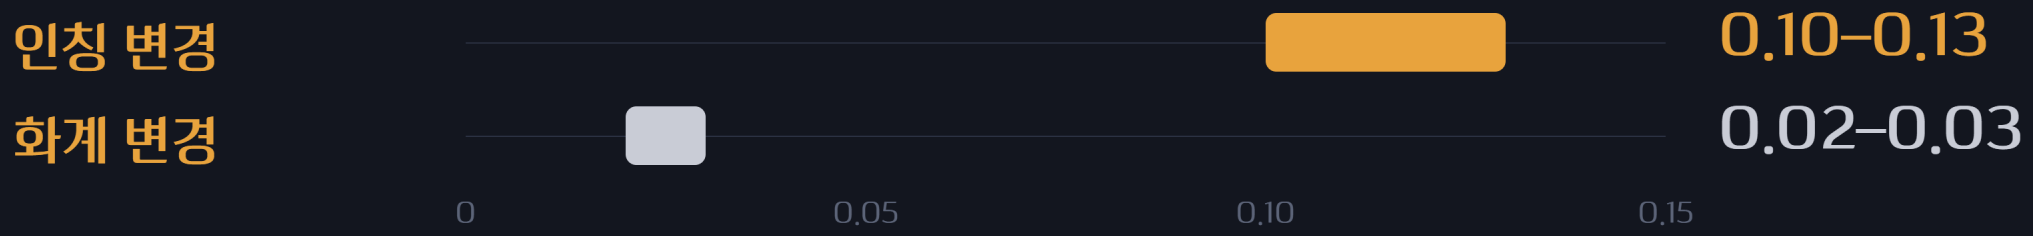
인간 δ_h의 95% 구간이
0을 포함하지 않는 쌍

12쌍 중 PROUDMIL16
하나뿐이었습니다

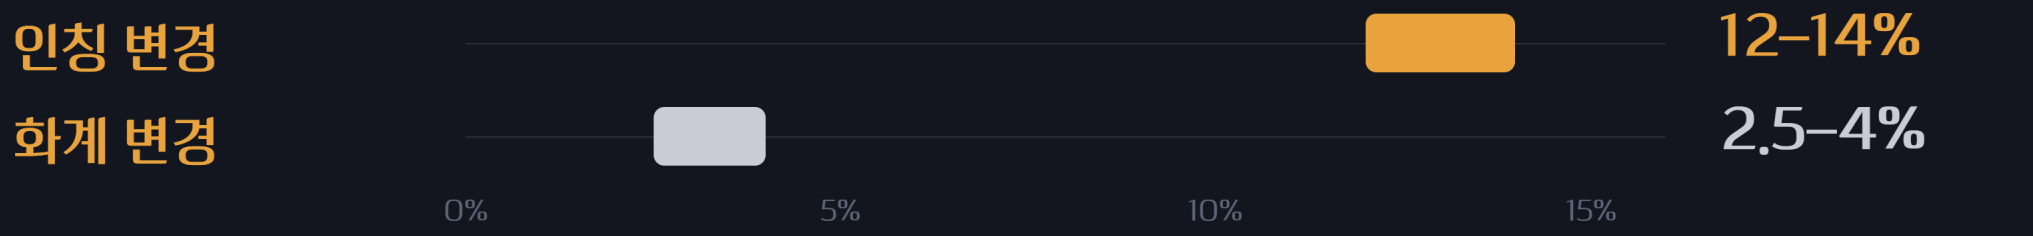
인칭 변경에서 모델 출력이 더 크게 달라졌습니다

당신·하십시오체를 기준으로 인칭과 화계를 하나씩 바꾼 조작 점검 결과입니다.

TV



최빈 선택 뒤집힘



출력이 바뀐 정도와 실제 분포에 가까워졌는지는 별개, 다음 장에서 KGSS와의 거리를 봅니다

화계는 ±10% 동등, 인칭은 모델별로 달랐습니다

R은 KGSS와의 W1 거리 변화율이고, 동등성 한계는 ±10%입니다.

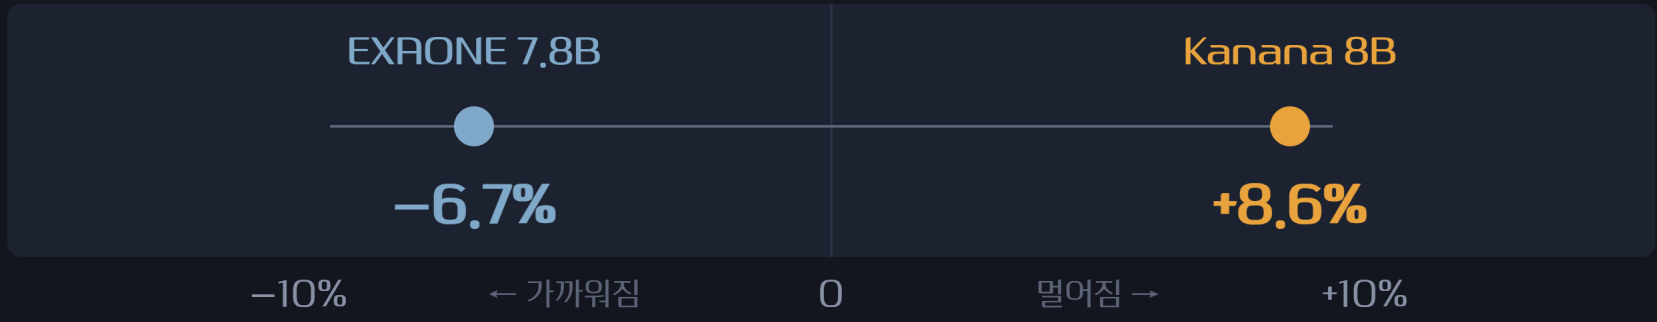
화계

4개 모델 모두 TOST를 통과했습니다

±10% 이내 동등성 근거를 얻었고, 실제 변화는 ±2% 정도였습니다.

인칭

Kanana 2.1B만
동등성 확인



문항별 |ΔW1| 평균이 부호 있는 평균보다 몇 배 컸고,
개선된 문항과 악화된 문항이 상쇄된 것이라 정확도와 무관하다고는 말할 수 없습니다

H5는 이번 분석에서 지지되지 않았습니다

A·B 분석 결과는 이번 발표에 포함하지 않았습니다.

C1	EXAONE 7.8B는 인간보다 컸고, Kanana 8B는 유의하지 않았습니다
C2 · 화계	출력 변화는 작았고, 평균 WJ1 변화율은 ±10% 동등성이 확인됐습니다
C2 · 인칭	출력은 크게 바뀌었고, 거리 변화 방향은 모델마다 달랐습니다
H5	'3인칭 + 해라체가 바람직성 편향을 줄인다'는 지지되지 않았습니다
해석 주의	WJ1 감소를 곧 사회적 바람직성 편향 감소로 해석하지는 않습니다

인칭은 출력을 크게 바꿨지만,
실제 분포에 일관되게 가까워지지는 않았습니다

질문과 피드백 환영합니다 — KOSMOS