NEXUS · DAT 8기

피드백 반영 결과와 초과 혼잡 전파 모델 진행

행사 기반 대중교통 혼잡 전파 예측 및 쾌적 경로 추천 시스템 — 올림픽공원역(5·9호선)

① 피드백 1 · 데이터 독립성 ② 피드백 2 · 미래 정보 참조 ③ 초과 혼잡 전파 모델

한지원(팀장) · 정종원 · 박우찬 · 신예주

발표 범위

이번 발표에서 다루는 세 가지

① 피드백 1

행사 422건은 모두 독립된 표본인가?

데이터 단위를 다시 세고, 같은 아티스트가 학습·검증에 동시에 들어가지 않도록 묶는 기준을 수정

반영 완료 · 일부 과제 남음

② 피드백 2

예측 시점에 알 수 있는 정보만 썼는가?

'오후 하차 초과량'이 미래 시간대 값까지 쓰던 문제를 수정하고, 성능보다 타당성 점검을 우선

반영 완료 · 일부 과제 남음

③ 3단계 진행

늘어난 승객은 어디까지 번지는가?

평소 승객과 행사로 늘어난 승객을 나눠, 늘어난 인원만 하류 역으로 따라가는 모델 설계

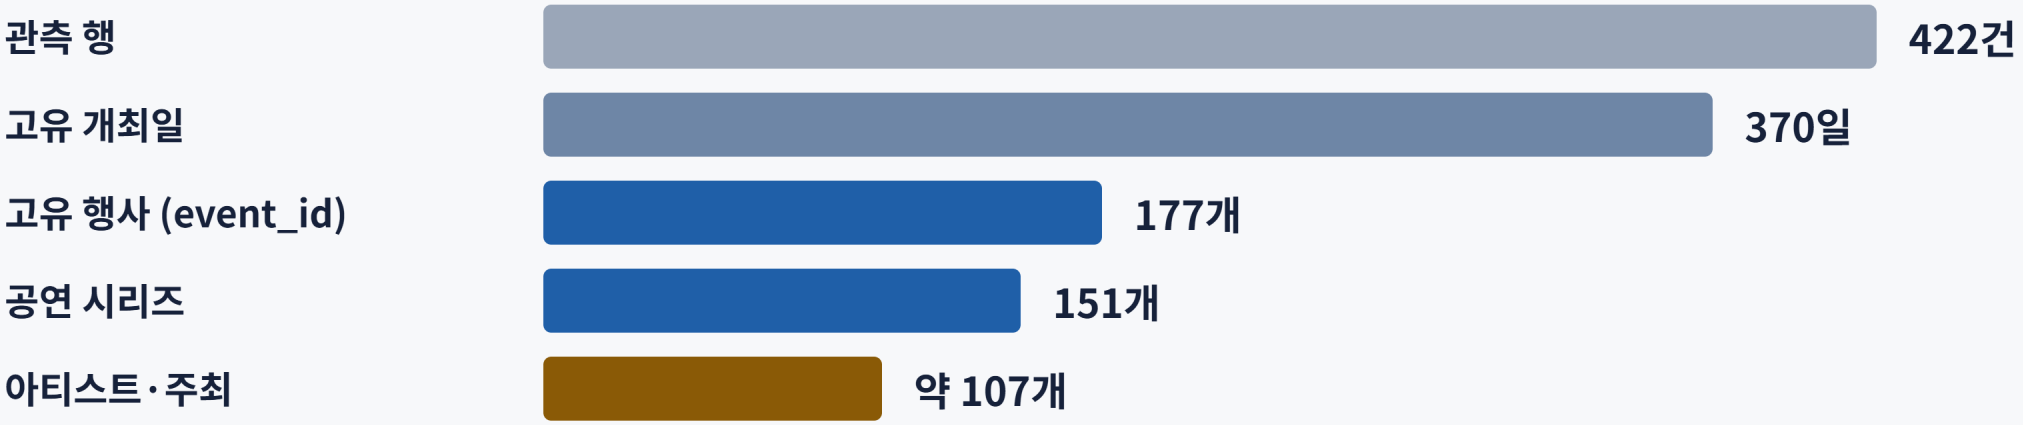
설계 단계 · 검증 남음

연구 흐름: 1단계 인과성 검증(완료) → 2단계 초과 수요 예측(완료, 이번에 보완) → **3단계 혼잡 전파(진행 중)** → 경로 재랭킹(예정)

피드백 1 · 데이터 단위

422건은 ‘독립된 행사 422개’가 아닙니다

> *피드백: “422개 행사는 정확히 무엇이며, 모두 독립 표본인가? 가수·공연 시리즈 단위로 묶어 검증해야 하지 않나?”*



관측 행 = 같은 날 공원 내 여러 시설에서 열린 행사를 시설별로 따로 센 원자료 행 · 행사 177건 중 89%가 여러 날 연속 개최, 73%가 반복 아티스트 · 막대 길이는 건수에 비례

피드백 1 · 그룹 키 수정

같은 아티스트는 한 묶음으로 검증합니다

기존 — 행사명 단위로 묶음

A 투어 1주차 → 그룹① | A 투어 2주차 → 그룹② | A 앙코르 → 그룹③

같은 가수 A가 학습 쪽과 검증 쪽에 동시에 들어갈 수 있음 → 검증 성능이 실제보다 좋게 나올 위험

학습·검증에 같은 아티스트가 동시에 등장

35건 → 0건

수정 — 아티스트(없으면 시리즈) 단위로 묶음

A 투어 1주차 · A 투어 2주차 · A 앙코르 → 그룹 '아티스트 A' 하나

아티스트 식별표(10_repeat_structure.py)로 식별 · 식별이 안 되면 '주차·앙코르' 표기를 지운 시리즈명을 사용

코드에서 쓴 그룹 키 개수

90 → 67개

실제로는 아티스트 17명이 키 40개로 갈라져 있었고, 해당 개최일이 약 92일(학습 191일의 절반) · 그룹 키 = 교차검증 때 같은 쪽에 넣을 묶음 · 'A'는 설명용 예시

피드백 1 · 실제 학습·평가 표본

370일 중 실제로 쓰인 날은 275일입니다



막대 길이 = 고유 개최일 370일 중 비율 (191 + 84 + 95 = 370) · 기존 보고서의 '학습 228일·테스트 142일' 표기는 실행 로그와 달라 정정 필요

왜 95일이 빠졌나

기준선(평소 수준)을 만들려면 같은 요일 유형의 행사 없는 날이 ±140일 안에 6일 이상 필요한데, 토요일은 거의 매주 행사가 있어 비교할 '평범한 토요일'이 부족했습니다.

제외된 95일 중 토요일

85일

토요일 행사일 133일 중 64%가 빠졌고, 2025년 Test에는 토요일이 한 번도 없습니다.

해석 주의: 현재 Test 성능은 토요일 행사에 대해서는 말해주지 못합니다.

피드백 1 · 결론

370일은 '서로 독립인 날' 약 100~150개 분량입니다

묶음 기준	그룹 수	묶음 안 닮은 정도 (ρ)	유효 표본 규모
행사 단위	158	0.65	약 185일
아티스트 단위	96	0.45	약 150일

초과 수요가 측정된 275일 기준 · 아티스트 단위로 보면 학습셋 약 104일, 평가셋 약 58일

같은 가수의 공연 날끼리는 초과 수요가 서로 비슷합니다(ρ가 1에 가까울수록 비슷). 비슷한 날이 많으면 날짜 수만큼 정보가 늘지 않아, '서로 독립인 날'로 환산하면 이 정도입니다.

그래서 이번 작업은

성능을 높이기보다, **보고하는 성능이 어떤 표본 단위와 분할 기준에 근거하는지**를 정확히 밝히는 데 집중했습니다.

그룹 키를 고치니 CV 오차가 236.48 → 238.40명(+0.8%)으로 늘어, 기존 검증이 다소 낙관적이었습니다. '튜닝은 미래 Test에서 개선되지 않는다'는 결론은 그대로이고, 현재 성능은 평일·일요일 행사 중심의 평가입니다.

다음 단계

- 보고서 일수 정정 (191·84일)
- 토요일 처리 방침 결정
- actor_freq 아티스트 기준
- 최신 코드로 재비교

피드백 2 · 문제와 수정

16시 예측에 17·18시 값이 들어가 있었습니다

afternoon_inflow_excess (오후 하차 초과량) = 16:00~18:59에 올림픽공원역에서 **평소보다 더 내린 인원의 합** · 관객이 미리 도착하는 신호

기존 코드는 이 **하루 합계**를 모든 시간대에 똑같이 넣어, 아직 오지 않은 시간대 값을 미리 본 셈이었습니다 (**Look-ahead Bias**)

예측 시각	기존에 쓰던 값	수정 후 쓰는 값
15시	16~18시 합 (미래)	없음 (0)
16시	16~18시 합 (미래 포함)	없음 (0)
17시	16~18시 합 (미래 포함)	16시 관측값
18시	16~18시 합 (미래 포함)	16~17시 관측값
19시 이후	16~18시 합	16~18시 관측값

쉽게 말하면

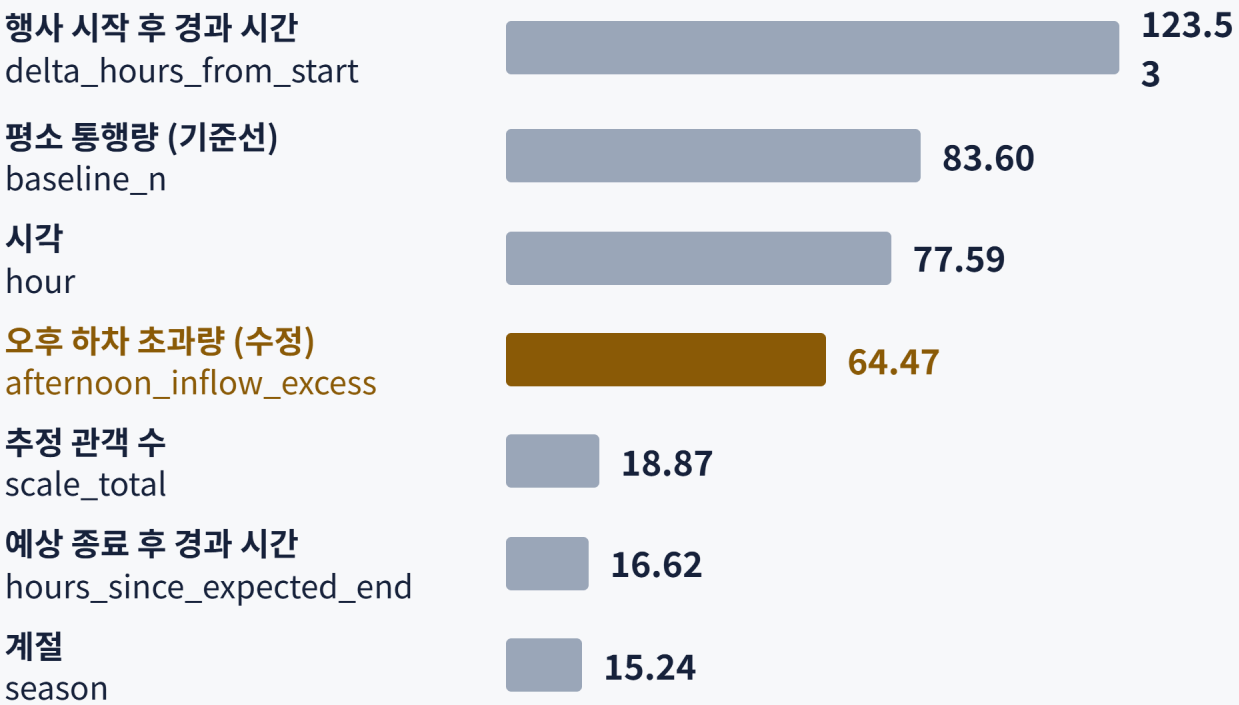
이제 17시에 예측할 때는 **16시까지 내린 사람만** 셉니다.

실제 서비스에서 그 시각에 알 수 있는 것만 쓰는 셈입니다. 시간대별로 들어간 값을 뽑아 표와 같은지 확인했습니다.

피드백 2 · 수정 후 변수 중요도

미래 정보를 빼도 오후 하차량은 4위를 유지합니다

평균 |SHAP| (각 변수가 예측을 평균 몇 명만큼 움직였는지) · 막대 길이는 값에 비례



중간발표와 비교 (상위 4개)

변수	중간발표	이번
경과 시간	137 (1위)	124 (1위)
시각	91 (2위)	78 (3위)
기준선	73 (3위)	84 (2위)
오후 하차 초과량	44 (4위)	64 (4위)

미래 값을 빼도 오후 하차 초과량은 4위 그대로, 시각과 기준선만 자리를 바꿨습니다.

값은 반올림 · 코드 버전이 함께 바뀌어 차이를 수정 효과로 보지 않음 · SHAP은 원인이 아니라 예측 기여도

피드백 2 · 수정 후 성능

수정 후에도 ‘CV는 개선, 미래 Test는 악화’

출처: outputs_1_3_fixed / tuning_final_comparison.csv · 튜닝 효과 = 튜닝 − 기본 (오차는 작을수록 좋음)

평가 항목	기본 LightGBM	튜닝 LightGBM	튜닝 효과
CV MAE (과거 데이터 검증)	234.43명	231.84명	−2.59명 (−1.1%) 개선
전체 Test MAE (2025년)	266.18명	270.14명	+3.96명 (+1.49%) 악화
귀가 피크 Test MAE (21~23시)	962.29명	984.48명	+22.19명 (+2.31%) 악화
과소예측 비율	36.57%	34.52%	−2.05%p 개선

그래서

튜닝 모델이 더 낫다고 할 수 없습니다. 재튜닝으로 MAE를 낮추기보다 모델의 타당성부터 점검합니다 (다음 장).

비교 주의

피드백 1 단계의 성능 수치는 수정 전 코드 기준이라 이 표와 직접 비교해 ‘개선됐다’고 말하지 않습니다.

피드백 2 · 연구 방향 조정

MAE를 더 낮추기보다, ‘믿을 수 있는 예측’부터

CV 개선이 미래 성능 개선으로 이어지지 않았기 때문에, 재튜닝 대신 네 가지 타당성을 먼저 점검합니다.

타당성 영역	쉽게 말하면	지금 확보한 근거	추가로 점검할 것
데이터	재료 자체가 믿을 만한가?	행사·교통량 데이터 결합, 데이터 단위 재정리 (피드백 1)	결측치, 중복, 데이터 범위
시간 ★ 이번 핵심	예측 시점에 알 수 있는 정보만 썼나?	오후 하차 초과량의 미래 참조 수정(피드백 2)	행사 종료 시각·규모 등 모든 변수의 시점별 가용성
검증	시험을 공정하게 봤나?	아티스트·시리즈 GroupKFold(피드백 1), 2025년 Hold-out	주체 중복 차단 재확인, 시간에 따른 일반화
해석	변수 설명이 흔들리지 않나?	SHAP 변수 중요도	영향 방향·부분 의존성, 특정 행사·날짜 의존 여부

점검 순서 ① 누수·예측 시점 → ② 검증 분리 → ③ SHAP 안정성 → ④ 오차 특성 분석 → ⑤ 전파·경로로 연결

3단계 · 초과 혼잡 전파 모델

전체 승객 대신, 행사로 '늘어난 승객'만 따라갑니다

기존 접근

열차에 총 몇 명이 타고 있는가?

- 올림픽공원역 이전 상류 수십 개 역의 승하차·환승을 모두 계산해야 함
- 계산 구조와 비용이 커짐
- 상류의 추정 오차가 기점역까지 누적됨

이번 설계

평소보다 몇 명이 더 타고 있는가?

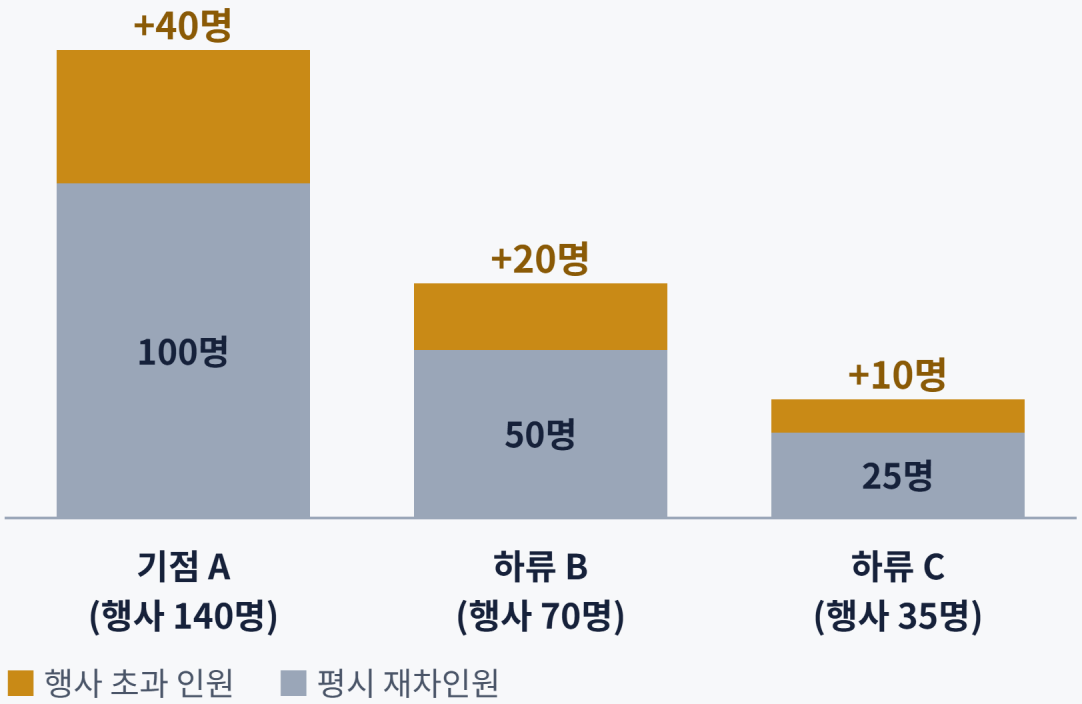
- **평시 기저 재차인원:** 평소 그 시간대 열차 안 인원
- **행사 초과 인원 (ΔL):** 행사 때문에 더 탄 인원
- **초과 혼잡 전파:** 초과 인원이 하류 역에서 내리며 줄어드는 과정

ΔL(0) = 행사 시 승차 − 평시 승차 출발점(올림픽공원역)의 초과 인원. 실제 예측에서는 2단계 모델이 내놓은 초과 승차 예측값을 넣습니다.

3단계 · 계산 방식과 예시

역마다 절반이 내리면, 초과 인원도 절반씩 줄어듭니다

가정: 매 역에서 열차 안 인원의 50% 하차 · 막대 높이는 인원에 비례



계산 방식

각 역에서 **평소 내리는 비율(하차율)만큼**, 행사로 더 탄 사람도 내린다고 봅니다.

예) 하차율 30%인 역 → 초과 40명 중 12명이 내리고 28명이 다음 역으로

핵심 가정

- **행사 관람객도 평소 승객과 같은 비율로 내림** (아직 검증 전)
- 바로 옆 역들의 행사 추가 승차는 작아서 제외
- 종점에서는 모두 내려 초과 인원 0

50%는 설명용 숫자이며, 실제 하차율은 역·시간대마다 다릅니다.

3단계 · 기준점과 가장 큰 쟁점

종점은 기준이 되지만, 환승은 아직 빈칸입니다

활용할 경계 조건

종점에서는 모두 내린다

$$L(\text{종점}) = 0$$

상류를 복원하지 않아도, 올림픽공원역에서 탄 초과 인원은 종점까지 가면서 누적 100% 내려야 합니다.

→ 하류 하차 분포를 점검하고, 감쇠 곡선이 종점에서 0이 되도록 맞추는 기준으로 사용

해결 전 쟁점

환승 승객이 데이터에 안 잡힘

승하차 데이터는 **개찰구 교통카드 태그** 기준 → 환승 통로로 갈아타는 승객은 '하차'로 집계되지 않을 수 있음

환승역 하차가 덜 잡힘 → 하차율 과소 → **초과 인원이 실제보다 오래 남은 것처럼 계산**

환승 유입·유출이 빠지면 평시 재차인원 L_base도 부정확해짐

3단계 · 환승 보완 방향

하류 환승역부터 실질 승하차량을 다시 정의합니다

노선	검토 대상 하류 환승역 (예시)
9호선	석촌 · 종합운동장 · 선정릉 · 고속터미널 · 동작 · 여의도 · 당산
5호선	천호 · 군자 · 왕십리 · 동대문역사문화공원 등

1

데이터 확인

서울교통공사·서울 열린데이터광장의 환승 통계 제공 여부와 시간·방향 단위 확인

2

실질 승하차 재정의

개찰구 승하차 + 환승 유입·유출을 합쳐 '열차 기준' 승차·하차량으로 다시 계산

3

간접 보정 (대안)

세부 데이터가 없으면 환승역별 보정 계수나 종점 전원 하차 조건으로 보정 검토

종합

한 일, 얻은 결과, 남은 과제

구분	수행 내용	현재 결과	남은 과제
피드백 1	데이터 단위 구분, 아티스트 기준 그룹 키	학습·검증 중복 35건 → 0건, 실제 정보량은 독립 단위 약 100~150개	토요일 제외 보완, 최신 코드로 재비교, actor_freq 재정의
피드백 2	오후 하차 초과량을 예측 시점별 누적으로 수정	미래 값 참조 제거, SHAP 4위 유지, 타당성 우선으로 방향 조정	다른 변수·기준선의 시점 점검, 종료 시각 민감도
전파 모델	평시와 초과 인원 분리, 하차율 기반 감쇠식	전파 구조·시뮬레이션 정리 (설계 단계)	환승 반영, 열차 단위 변환, 관람객 하차 가정 검증

검증 완료

표본 단위 재정리 · 그룹 분할 수정 · 오후 하차 초과량의 미래 참조 제거

설계·검증 진행 중

초과 혼잡 전파 모델 — 환승·열차 단위 실측 검증 전

감사합니다

질문과 의견 부탁드립니다

NEXUS · 한지원(팀장) · 정종원 · 박우찬 · 신예주 · DAT 8기