

행사 기반 대중교통 혼잡 전파 예측 및 쾌적 경로 추천 시스템 구축

DAT PROJECT · 정기세션 3주차 발표

기존 모델을 어디까지 시도했는가?

기존 규칙 기반(중앙값) 모델의 구조적 한계와 머신러닝 전환 배경


모델 구분	모델명 및 조건	Test MAE	영 모델 대비 개선율	기존 최고 대비
CASE 0	영 모델 (B0, 모든 초과=0 예측)	359.72명	0.00%	(기준선)
CASE 1	1시간 기본 모델 (요일유형 × 시각 중앙값)	277.33명	22.90%	-
CASE 1-1A	1시간 + 콘서트류 여부	275.10명	23.52%	+0.80% 개선
CASE 1-1B	1시간 + 동시개최 여부	283.94명	21.07%	-3.21% 악화
CASE 2	2시간 기본 모델 (요일유형 × 2시간대 중앙값)	290.45명	19.26%	-
CASE 2-1	2시간 + 콘서트류 여부	286.32명	20.41%	+1.42% 개선
활동 기반	활동 기반(4단계) + 콘서트류 여부	315.17명	12.39%	-

기존 요일유형 × 시각 중앙값 모델(Test MAE 277.33명)에 '동시개최 여부' 변수를 단순 세분화 그룹으로 추가했을 때, 표본 희소성 문제로 인해 Test MAE가 283.94명으로 12.1% 악화

→ 의사결정나무 기반 Gradient Boosting 머신러닝 모델과 특성 중요도 해석(SHAP)의 도입

SHAP으로 “무엇이 중요한지” 확인

shap.TreeExplainer를 통해 2025년 블라인드 테스트셋(2,100개 시점) 전체에 대해 산출한 변수별 절대 기여도(Mean |SHAP Value|) 순위입니다.




SHAP 분석을 통해 밝혀진 4대 핵심 발견

행사 시작 시각 기준 경과 시간과 당일 오후 하차 실측량이 압도적인 예측 기여를 나타냄

	압도적 1위 " 시작 시각 기준 경과 시간 "	요일별 상이한 타임라인이 시작 시각을 기점으로 동적으로 정렬(Dynamic Alignment)
	가장 강력한 선행 물리 지표 " 당일 16~18시 하차 초과 인원 "	밤 귀가 승차량을 결정하는 가장 신뢰할 수 있는 선행 신호임을 머신러닝 수준에서 검증
	추정 총 관객 규모 (18.86명) vs 단순 시설 정원 (2.14명)	단순 시설 정원(capacity)보다 실제 추정 관객수 총합(scale_total)이 약 9배 높은 설명력
	15개 노이즈 피처 제거와 모델 경량화	SHAP Top 11 변수만 남긴 정제 모델(Test MAE 273.00명)은 전체 26개 변수 모델 (272.96명)과 성능 차이가 단 0.04명에 불과

모델 성능 벤치마크 비교 결과

동일한 평가 데이터셋(2023~2024년 Train 4,775건 / 2025년 Test 2,100건)에서 기존 규칙 기반 중앙값 모델들과 제안된 머신러닝(LightGBM) 모델을 평가했습니다.



1. LightGBM 머신러닝 모델의 우수성

모든 기존 규칙 기반 모델을 능가 (MAE 272.96명)

2. SHAP 선별 정제 모델의 효율성

6개 전체 변수 중 SHAP로 선별한 11개 핵심 변수만 사용한 모델(273.00명)은 전체 변수 모델(272.96명)과 성능 차이가 단 0.04명에 불과

주체(Actor) GroupKFold 분할 무결성 검증

- 동일 아티스트 재방문율이 73%에 달해 일반적인 무작위 분할 시 심각한 정보 누수(Data Leakage)
- 연도별 요일 불균형으로 인해 고정 Val 셋을 둘 경우 검증 지표가 크게 왜곡될 위험이 있음

2023~2024년 훈련 풀 (4,775행, 191일, 고유 주체 90개) GroupKFold 검증 결과

폴드 번호	훈련 데이터 (Train)	검증 데이터 (Validation)	훈련/검증 주체(아티스트) 수	주체 정보 누수(Leakage) 건수	검증 상태
Fold 1	3,800행	975행	72개 주체 / 18개 주체	0건	완전 격리 통과
Fold 2	3,825행	950행	72개 주체 / 18개 주체	0건	완전 격리 통과
Fold 3	3,825행	950행	72개 주체 / 18개 주체	0건	완전 격리 통과
Fold 4	3,825행	950행	72개 주체 / 18개 주체	0건	완전 격리 통과
Fold 5	3,825행	950행	72개 주체 / 18개 주체	0건	완전 격리 통과

Optuna 베이지안 최적화 (50 Trials) 및 최적 파라미터

누수 없는 5-Fold CV Validation MAE를 목적 함수로 설정하고 Optuna(TPE Sampler)를 구동한 결과, 평균 MAE를 236.48명에서 **233.22명으로 1.38% 추가 감축**했습니다.

LightGBM 최적 하이퍼파라미터 튜닝 상세 (`hyperparameter\_best\_params.json`)

하이퍼파라미터	기본값 (Default)	최적 튜닝값 (Best)	학습 메커니즘 및 튜닝 의미
num_leaves	31	18	트리 복잡도 축소를 통한 과적합 방지
max_depth	-1 (무제한)	7	깊이 제약을 통해 희소 그룹에 대한 이상치 반응 억제
reg_alpha (L1)	0.0	2.3166	강력한 L1 정규화 도입 (희소 노이즈 피처 억제)
reg_lambda (L2)	0.0	0.1756	Ridge 정규화로 계수 분산 안정화
n_estimators	250	350	충분한 부스팅 이터레이션 확보
learning_rate	0.03	0.0583	손실 함수 최적 수렴 속도 달성
subsample	1.0	0.6738	행 단위 무작위 서브샘플링(배깅)으로 분산 감소
colsample_bytree	1.0	0.9271	트리별 피처 서브샘플링

2025년 미래 Test 셋(142일, 2,100건) 최종 평가 결과


2025년 블라인드 테스트셋 최종 평가 메트릭 비교

평가 지표	영 모델 (B0, ΔL=0 예측)	기본 LightGBM (Optuna 전)	튜닝된 LightGBM (Optuna 후)	영 모델 대비 개선율
전체 시간대 Test MAE	359.72명	270.34명	274.03명	24.85% 개선
귀가 피크(21~23시) Test MAE	1,337.09명	974.94명	1,001.74명	27.08% 대폭 감축
과소예측(Under-estimation) 비율	100.0%	35.19%	35.43%	-64.81%p 위험 감소
5-Fold GroupKFold CV Val MAE	-	236.48명	233.22명	1.38% 튜닝 개선

- 귀가 피크 오차 27.08% 감소 → 우회 추천 신뢰도 향상
- 과소예측 35.19%로 억제 → 안전 마진 확보
- 상황별 모델 50:50 앙상블 → 일반·대형 피크 대응력 확보

시설 수용 정원 제약 행사 관객 수 정밀 추정 모델

공연 메타데이터상의 심각한 관객 수 결측(422건 중 221건 결측, 52.4%)을 극복하기 위함



단순 1:1 비례추정(B0) 및 분담률 역산 대비
머신러닝 정원 제약 모델(M4)의 오차 41.2% 감축



M4 모델 채택



결측 221건 100% 해소

KOPIS Open API 전수 수집 및 미해결 12일 정체 100% 규명

1단계 베이스라인 검증에서 평상시 대비 지하철 승하차가 급증했으나 원인이 불명확했던 '미해결 12일'을 해결하기 위함

KOPIS 전수 매칭을 통해 정체가 규명된 미해결 12일 목록 (`kosis\_unresolved\_matched.csv`)

미해결 일자	발견 여부	공연 시설명	공연명 (KOPIS)	주요 출연진	시작 시각 및 회차 안내
2023-03-31	규명 완료	올림픽홀 / 핸드볼	권진아 단독 공연 / SG워너비 콘서트	권진아, SG워너비	금요일 20:00 동시 시작
2023-05-05	규명 완료	KSPO DOME / 올림픽홀	미스터트롯2 전국투어 / NELL'S SEASON	안성훈, 박지현, 진해성, NELL	어린이날 특별 18:00 / 19:00
2023-09-17	규명 완료	88잔디마당 (야외)	2023 조이올팍 페스티벌	BIG Naughty, 헤이즈 등 다수	일요일 13:00 시작 야간 피크
⋮ 외 9일 → KOPIS 전수 매칭 완료					

미해결 12일 규명이 가져온 핵심 도메인 인사이트

- 미해결 12일 중 8일(66.7%)이 2개 이상의 공연장이 동시에 가동된 복합 동시개최일
- 특히 2025년 12월 14일의 경우 올림픽공원 5개 공연장이 총동원된 초대형 피크일이었음이 KOPIS를 통해 입증

잔여 과제 및 3단계 우회 시스템 착수 계획

2단계 승하차 예측의 완성된 모델과 정제된 행사 DB를 기반으로,
외부 맥락 피쳐 결합 및 3단계 링크 단위 혼잡 전파 모델링에 돌입합니다.

STEP 1

시간 단위 기상 데이터 수집 및 결합

- 기상자료개방포털 시간별 강수량, 기온, 적설량 데이터를 수집
- 악천후 시 대중교통 집중도 변화를 피쳐로 결합

STEP 2

3단계 열차 링크(구간) 단위 차내 혼잡 전파 모델링

- 올림픽공원역 출발 승객의 목적지별 하차 비율 및 잔류 프로파일 , 반감 흡수를 산출
- 9호선 급행/완행 및 5호선 상·하행 열차 링크별 차내 혼잡도 계산

STEP 3

TMAP 대중교통 API 연계 우회 경로 재랭킹 시스템 구축

- 고혼잡 링크에 페널티를 부여
- 인근 대안 경로를 재랭킹하여 쾌적 경로 추천 구현

넥서스(NEXUS)

Thank you

질의응답 및 논의