

구조적 인과 모형(SCM) 기반 제조 공정 최적화를 위한 실행 가능한 반사실적 개입 추천 프레임워크

프로젝트 분야: 제조 / 공정 최적화 및 처방적
AI

참여 연구원: 정창민 · 황주희 · 오성민

보고 일자: 2026년 8월 16일

1. 프로젝트 조사 개요 및 방법

1.1 프로젝트명

구조적 인과 모형 기반 제조 공정 최적화를 위한 실행 가능한 반사실적 (개입) 추천 프레임워크

1.2 프로젝트 개요

기존 제조 AI 연구는 수집된 센서 데이터를 바탕으로 불량 발생 여부를 예측·이상 탐지하거나, 설명가능 인과 모델(XAI)을 통해 변수 중요도를 도출하는 사후 분석에 집중되어 왔습니다. 본 프로젝트는 제조 공정 데이터로부터 변수 간 실제 인과 관계를 복원하고 **구조적 인과 모형(Structural Causal Model, SCM)**을 구축한 뒤, **반사실적 추론(Counterfactual Reasoning)**을 적용하여 “불량 상태를 정상 상태로 전환하기 위해 조절 가능한 공정 변수를 최소한으로 어떻게 개입·변경해야 하는가”에 대한 실행 가능한 처방적(Prescriptive) 공정 최적화 추천 프레임워크를 수립·검증합니다.

이를 위해 Ground Truth(정답 인과 구조)가 존재하는 산업 공정 벤치마크(Tennessee Eastman Process, Ultra-processed Food)를 활용하여 인과 구조 복원 및 반사실 개입 추천 성능을 정량 채점하고, 이후 고차원·노이즈·클래스 불균형이 존재하는 실제 제조 공정 데이터로 확장 적용하여 실무적 유효성과 강건성을 입증합니다.

1.3 주제 선정 동기

- **처방적(Prescriptive) 의사결정 정보의 부재:** 현장 엔지니어와 작업자에게 실질적으로 필요한 정보는 “불량 확률이 80%이다”라는 예측값이나 단순 중요 변수 목록이 아니라, “불량을 방지하기 위해 어떤 공정 파라미터(Setpoint 등)를 얼마나 조정해야 하는가”에 대한 구체적 실행 지침입니다.
- **상관 기반 제어의 연쇄 부작용:** 단순 상관관계나 머신러닝 중요도(SHAP 등)에 기반하여 공정 변수를 조작할 경우, 공정 내 복잡한 피드백 루프와 변수 간 연쇄적 인과 파급 효과(Ripple Effect)를 반영하지 못해 원치 않는 심각한 공정 이상이나 품질 저하를 초래합니다.
- **인과 기반 최적화 통합의 필연성:** 인과 탐색, SCM 모델링, 반사실 추론, 제약 최적화를 유기적으로 결합하여 실제 제조 현장의 물리적 제약을 만족하는 최소 개입안을 도출할 필요가 있습니다.

1.4 조사 방법 및 연구 축

arXiv, IEEE, Springer, ScienceDirect 등 주요 학술 데이터베이스 및 공개 제조 벤치마크 문헌을 바탕으로 선행 연구를 다음 **4개의 핵심 축**으로 분류하여 방법론·성과·한계점을 종합 조사했습니다.

1. A. 제조 공정 인과 구조 탐색 및 진단 (Causal Discovery & Diagnosis)
2. B. SCM 기반 반사실적 추론 및 알고리즘 리코스 (Counterfactuals & Algorithmic Recourse)
3. C. 제약조건을 고려한 인과 최적화 (Constrained Causal Optimization)
4. D. 제조 결함 예측 및 처방적 의사결정 적용 사례 (Prescriptive Decision-making in Manufacturing)

2. 주요 선행 연구 및 사례 분석

2.1 선행 연구 분류 및 핵심 요약

연구 축	대표 선행 연구 / 사례	핵심 방법론 및 한계점
A. 예측·설명 중심 (기존 주류 연구)	• TEP 시계열 딥러닝 결함 탐지 • SECOM 반도체 불량 예측 • SHAP / Feature Attribution XAI	방법: 딥러닝·이상탐지로 불량 여부 예측, XAI로 기여도 산출 한계: '무엇을 어떻게 변경해야 하는가'에 대한 처방 부재 및 개입 시 연쇄 부작용 예측 불가
B. 인과 기반 탐색·진단 (제조 공정)	• CIPCaD-Bench (Menegozzo et al., 2022) • 비정상성 인과 근본원인 진단 • Causal Discovery for Manufacturing	방법: 인과 탐색 알고리즘을 통한 이상 근본 원인 규명 및 정답 벤치마크 제시 한계: 그래프 복원 및 사후 원인 진단에 편중, 반사실적 개입 추천 및 시계열/폐루프 통합 미흡
C. 반사실·개입 추천 (일반 ML/리코스)	• Algorithmic Recourse (Karimi et al., 2020, 2021) • DiCE (Mothilal et al., 2020)	방법: 분류 결과 반전을 위한 SCM 기반 최소 개입(Minimal Intervention) 도출 한계: 금융·채용 등 비제조 중심, 공정 Setpoint·조절가능성·물리적 연쇄 파급 미반영
D. 제약 최적화 및 처방 (제조 의사결정)	• cCBO (Aglietti et al., 2023) • MiCCD (Cai et al., 2025) • Double ML 재작업 결정 (Schwarz et al., 2024)	방법: 인과 모형 기반 제약 베이지안 최적화, SLSQP 비용 최소화, CATE 추정 한계: 그래프가 완벽히 주어졌다고 가정하거나, 단일 이산 결정(재작업 여부)에 국한됨

2.2 주요 선행 연구 세부 분석

1) CIPCaD-Bench: 제조 공정 인과 구조 탐색 벤치마크 (Menegozzo, Dall’Alba, Fiorini, 2022)

핵심 내용: 연속 제조 공정의 Causal Discovery 알고리즘 성능을 정량 비교하기 위해 제안된 최초의 공정 벤치마크. Tennessee Eastman Process(TEP)와 Ultra-processed Food 공정의 Ground Truth 인과 그래프를 제공함.

시사점 및 한계: 본 프로젝트의 인과 발견 성능 검증(SHD, Precision, Recall, F1)에 직접 활용됨. 그러나 연구 범위가 그래프 복원 정확도 평가에 머물러 있어, 복원된 그래프가 실제 공정 품질 개선 개입 품질로 연결되는 단계는 다루지 않음.

2) Algorithmic Recourse: 반사실적 설명에서 구조적 개입으로 (Karimi, Schölkopf, Valera, 2020/2021)

핵심 내용: 특징 공간에서 단순히 가까운 인스턴스를 찾는 반사실적 설명(Counterfactual Explanation)과 실제 인과 모형을 통해 실행 가능한 개입(Actionable Recourse) 간의 본질적 차이를 규명하고, SCM 기반 최소 개입 프레임워크를 정립함.

시사점 및 한계: "불량 상태를 정상으로 되돌리는 최소 개입"의 이론적 뼈대를 제공함. 한편 Karimi et al.(2020)은 인과 지식이 불완전할 경우 리코스 성공률이 저하됨을 입증하여, 데이터로 학습한 인과 구조의 추정 오차가 최종 추천 결과에 미치는 불확실성 평가의 필요성을 시사함.

3) Constrained Causal Bayesian Optimization (Aglietti et al., 2023)

핵심 내용: 기지의 인과 그래프에서 목적 변수를 최적화하면서 다차원 제약조건(안전 범위, 개입 비용)을 만족하는 최적 개입을 탐색하는 cCBO 알고리즘을 제안함.

시사점 및 한계: 제조 공정의 현실적 조절 범위 제약 반영에 유용하나, 인과 그래프가 사전에 완벽히 알려져 있다고 전제함. 관측 데이터로부터 인과 구조를 먼저 탐색해야 하는 실제 현장에서는 인과 발견 오차에 대한 강건성 분석이 필수적임.

4) Double ML 기반 실제 제조 재작업 의사결정 (Schwarz et al., 2024)

핵심 내용: 실제 LED 광전자 반도체 공정 데이터에서 Double/Debiased Machine Learning(DML)을 통해 재작업(Rework)의 조건부 처리 효과(CATE)를 추정하여 정책을 최적화하고 약 2~3%의 수율 개선을 달성함.

시사점 및 한계: 인과 머신러닝이 제조 현장의 실질적 수율 개선으로 이어질 수 있음을 입증함. 다만 '재작업 수행 여부'라는 이산적 단일 변수 결정에 한정되어 다변수 연속 공정 변수(온도, 압력, 유량 등)를 동시 조정하는 문제에는 확장이 필요함.

5) MiCCD: 최소비용 인과 개입 프레임워크 (Cai et al., 2025)

핵심 내용: 이상 상태를 정상으로 복구하기 위해 반사실 추론과 SLSQP 수치 최적화를 결합한 Minimum-cost Causal Decision(MiCCD) 프레임워크를 제안하여 비용 효율적 개입을 도출함.

시사점 및 한계: 반사실 추론의 처방적 의사결정 활용 가능성을 입증함. 본 프로젝트를 여기서 나아가 인과 탐색 단계의 알고리즘별 추정 오차가 최종 개입 품질에 미치는 영향까지 통합 파이프라인으로 검증한다는 점에서 차별화됨.

2.3 선행 연구 종합 한계점 및 시사점

- **예측·설명 수준의 정체:** 불량 판정이나 단순 중요도 제시에 머물러 '실제 무엇을 변경해야 하는가'에 대한 구체적 처방 정보와 부작용 분석이 부재함.
- **파이프라인의 단절:** 인과 진단 연구와 개입 최적화 연구가 분리되어 있어, 인과 탐색부터 개입 추천 및 검증까지 아우르는 End-to-End 프레임워크가 전무함.
- **제조 현장 제약 미반영:** 기존 리코스 연구는 금융·채용 데이터 위주로 연구되어, 공정의 조절 가능/불가 변수 구분, Setpoint 개입, 물리적 한계, 연쇄 파급 효과를 담지 못함.
- **평가의 순환 모순 위험:** 인과적 개입 효과를 상관 기반 예측 모델의 점수로 평가할 경우, 상관 모델이 인과 모델을 채점하는 논리적 오류가 발생함.

3. 프로젝트의 핵심 차별성 및 방법론적 강점



3.1 End-to-End 종단 통합 인과 파이프라인

개별적으로 연구되던 인과 탐색, 구조방정식 모형화, 반사실적 시뮬레이션, 실행 제약 최적화를 하나의 유기적 파이프라인으로 통합하여 제조 AI의 패러다임을 '예측'에서 '실행 가능한 처방'으로 전환합니다.

3.2 구조 복원 성능 → 개입 추천 간 '오류 전파(Error Propagation)' 정량 규명

Ground Truth가 존재하는 벤치마크 환경에서 정답 그래프 기반 추천을 기준선(Baseline)으로 설정하고, 다양한 인과 발견 알고리즘(PC, FCI, FGES, DirectLiNGAM)으로 추정된 그래프 기반 추천을 비교합니다. 이를 통해 그래프 복원 정확도(SHD, F1-score)가 최종 의사결정의 유효성·근접성에 미치는 오차 전파 메커니즘을 규명합니다.

3.3 비인과 반사실 기법(DiCE) 대비 결정적 비교 실험 및 평가 순환 회피

Tennessee Eastman 공정 시뮬레이터 환경에서 비인과적 특징 반전 기법(DiCE 등)과 본 프레임워크의 인과 추천을 실제로 적용·실행하여 물리적 거동과 품질 개선율을 직접 비교합니다. 이를 통해 상관 기반 개입이 초래하는 공정 연쇄 부작용을 수치적으로 입증하며, 머신러닝 예측기에 채점을 의존하는 평가 순환 오류를 원천 차단합니다.

3.4 제조 특화 현실적 제약 반영 및 5대 평가 지표 체계

조절 가능 변수(Actionable, Setpoint 등)와 불가 변수(Non-actionable, 외기 환경 등)를 엄격히 구분하고, 제어 허용 범위, 변경량, 변경 변수 개수 제약을 반영하여 다음 **5대 핵심 지표**로 다각도 평가합니다.

- 1. 유효성 (Validity)** 개입 후 불량이 정상 상태로 전환되는 실제 성공 비율
- 2. 근접성 (Proximity)** 현재 상태 대비 제어 변수의 총 변경량(비용) 최소화 수준
- 3. 희소성 (Sparsity)** 현장 작업 부하 경감을 위한 변경 대상 공정 변수 개수의 최소화
- 4. 현실 개연성 (Plausibility)** 도출된 개입 상태가 장비 운전 한계 및 정상 공정 분포 내에 존재할 확률
- 5. 인과적 타당성 (Causal Validity)** 공정 내 연쇄 파급 효과를 수용하고 잠재적 안전/품질 부작용을 억제한 정도

3.5 공정 동역학을 고려한 방법론 강건화

- **시계열 및 페루프 제어 대응:** 공정의 시간 지연(Time Lag)과 피드백 제어 루프를 반영하기 위해 시간축을 확장한 시계열 인과 탐색(PCMCI 등)을 적용합니다.
- **잠재 교란변수 편향 제거:** 예측 중심 변수 선택 대신 Markov Blanket 및 잠재 요인을 다루는 FCI 계열 알고리즘을 도입하여 교란 편향을 제어합니다.
- **데이터 불균형 및 노이즈 극복:** 제조 공정의 희소 불량 데이터 및 센서 노이즈에 강건한 데이터 전처리 및 통계적 검증 프로토콜을 구현합니다.

3.6 단계적 실증 검증 전략

1단계로 Ground Truth 인과 구조가 있는 Tennessee Eastman Process 및 Ultra-processed Food 데이터에서 알고리즘의 정밀성 및 오차 전파를 검증하고, 2단계로 고차원·노이즈가 존재하는 실제 제조 공정 데이터로 확장하여 산업 현장 적용성을 입증합니다.

4. 참고문헌 (References)

1. Aglietti, V., Malek, A., Ktena, I., & Chiappa, S. (2023). Constrained Causal Bayesian Optimization. International Conference on Machine Learning (ICML 2023).
2. Cai, R., et al. (2025). An Identifiable Cost-Aware Causal Decision-Making Framework Using Counterfactual Reasoning. arXiv: 2505.08343.
3. Karimi, A. H., Schölkopf, B., & Valera, I. (2021). Algorithmic Recourse: From Counterfactual Explanations to Interventions. ACM Conference on Fairness, Accountability, and Transparency (ACM FAccT 2021).
4. Karimi, A. H., von Kügelgen, J., Schölkopf, B., & Valera, I. (2020). Algorithmic Recourse under Imperfect Causal Knowledge: A Probabilistic Approach. Advances in Neural Information Processing Systems (NeurIPS 2020).
5. Menegozzo, G., Dall'Alba, D., & Fiorini, P. (2022). CIPCaD-Bench: Continuous Industrial Process datasets for benchmarking Causal Discovery methods. arXiv:2208.01529 (IEEE CASE 2022).
6. Mothilal, R. K., Sharma, A., & Tan, C. (2020). Explaining Machine Learning Classifiers through Diverse Counterfactual Explanations (DiCE). ACM FAT* 2020.
7. Schwarz, P., et al. (2024). Management Decisions in Manufacturing using Causal Machine Learning – To Rework, or not to Rework? arXiv:2406.11308.
8. Causal Discovery for Manufacturing Domains. arXiv:1605.04056.
9. A systematic nonstationary causality analysis framework for root cause diagnosis of faults in manufacturing processes. Control Engineering Practice, 2022.
10. Combining SHAP and Causal Analysis for Interpretable Fault Detection in Industrial Processes. arXiv:2510.23817.

11. Fault detection in Tennessee Eastman process with temporal deep learning models. *Control Engineering Practice*, 2021.
12. Machine learning-based techniques for fault diagnosis in the semiconductor manufacturing process: a comparative study (SECOM). *Journal of Supercomputing*, 2022.
13. *Machine Learning for Predictive and Prescriptive Analytics of Operational Data in Smart Manufacturing*. Springer, 2020.
14. Multi-stage Continuous Flow Manufacturing Process dataset. Kaggle.