

데이터 분석 학회 · 논문리뷰 발표

The Seven Tools of Causal Inference

with Reflections on Machine Learning

Judea Pearl (2019)

Communications of the ACM, Vol. 62, No. 3, March 2019, pp. 54–60 · DOI 10.1145/3241036

UCLA Technical Report R-481, February 2019

리뷰 팀 막시무 | 대상 팀 닭고조이고기름치자 | 0000. 00. 00

로고

목차

약 10분 — 개념 논문을 처음부터 끝까지

1	문제와 세 가지 장벽	2분
2	인과의 3단계 위계 — 핵심 아이디어	3분
3	SCM 엔진과 7가지 도구	3분
4	이 논문의 기여와 핵심 정리	2분

핵심 메시지

머신러닝이 못 푸는 문제는 데이터가 부족해서가 아니라, 애초에 통계만으로는 답할 수 없는 질문이기 때문이다.

이 논문이 푸는 문제

인간 수준의 기계지능 — 그 전엔 뭐가 안 됐나

그 전 — 순수 통계 기반 머신러닝

- 상관관계(association)만 학습 — $P(y|x)$
- 환경이 바뀌면 무너짐 — 전이학습 · 도메인 적응 · 평생학습으로 우회 시도 중
- 예측은 잘해도 "왜"를 설명 못함 — "모델은 대부분 블랙박스"로 남아 있다"
- "담배를 금지하면?" 같은 개입(intervention) 질문에 답 불가
- "아스피린이 두통을 멈췄나?" 같은 반사실(counterfactual) 질문은 원천적으로 불가



이 논문 — 인과 모델링(SCM)

- 그래픽 모델 + 구조 방정식 + 반사실·개입 논리를 결합
- 인과 질문을 수학적으로 명확히 정의 — 대수 방정식 풀듯 다룸
- 지식이나 데이터가 부족해 답할 수 없을 때는 미리 경고까지 해줌
- 사회과학 · 의학에서 이미 "제2의 언어"가 된 도구를 머신러닝에 이식

한 줄 요약 — 순수 통계 학습으로는 답할 수 없던 인과 질문들을, 인과 다이어그램과 do-calculus로 답할 수 있게 만들었다.

인과의 3단계 위계 — Ladder of Causation

Figure 1 재현 — 이 논문을 논문이게 하는 것은 수식 하나가 아니라 이 구조 자체

단계 (기호)	대표 활동	대표 질문	논문의 예시
1. 연관 Association $P(y x)$	보기 Seeing	무엇인가? X를 보면 Y에 대한 나의 믿음이 어떻게 바뀌는가?	증상이 질병에 대해 무엇을 말해주는가? 설문이 선거 결과에 대해 무엇을 말해주는가?
2. 개입 Intervention $P(y do(x), z)$	하기 · 개입 Doing, Intervening	만약 X를 하면 어떻게 되는가?	아스피린을 먹으면 두통이 나올까? 담배를 금지하면 어떻게 될까?
3. 반사실 Counterfactuals $P(y_x x', y')$	상상 · 회고 Imagining, Retrospection	왜? Y를 일으킨 것이 X였나? 내가 다르게 행동했다면?	아스피린이 내 두통을 멈췄나? 오스왈드가 쏘지 않았다면 케네디는 살아 있을까?

level i의 질문은 level j (j > i) 의 정보가 있어야 답할 수 있다 — 위계는 방향이 있고, 최상단이 가장 강력하다.

기호 읽는 법

각 층은 고유한 문장 형태(syntactic signature)를 가진다 — 기호가 곧 그 층의 한계선

1

$P(y|x) = p$ · 연관

" $X = x$ 를 관찰했을 때 $Y = y$ 일 확률이 p 이다" — 베이지안 네트워크나 대부분의 머신러닝 기법으로 효율적으로 계산 가능한 층.

2

$P(y|\text{do}(x), z)$ · 개입

" X 를 x 로 **강제로 설정**하고, 이후 $Z = z$ 를 관찰했을 때 $Y = y$ 일 확률" — 자연스럽게 관찰된 $X = x$ 와는 전혀 다른 개념. 무작위 실험으로 추정하거나 인과 베이지안 네트워크로 해석적으로 구한다.

3

$P(y_x|x', y')$ · 반사실

"실제로는 $X = x'$, $Y = y'$ 를 관찰했지만, 만약 X 가 x 였다면 $Y = y$ 였을 확률" — 실제 세계와 대안 세계를 **동시에 참조**하는 표기. 구조 방정식(함수 관계)에 기반한 모델에서만 계산할 수 있다.

왜 "위계"인가 — 방향이 있다

상위는 하위를 포함한다. 그러나 역방향은 원리적으로 불가능하다

위 → 아래 : 된다

반사실 질문에 답할 수 있는 모델이면 개입 · 관찰 질문에도 답할 수 있다. "가격을 두 배로 올리면?"은 "가격이 두 배였다면?"으로 물어 답할 수 있고, 연관 질문은 개입 부분을 지우고 관찰만 남기면 된다.

아래 → 위 : 안 된다

개입 질문은 순수 관찰 데이터만으로는 답할 수 없다 — 데이터가 아무리 커도 마찬가지다. 회고가 필요한 반사실 질문은 통제 실험 정보만으로도 답할 수 없다. 약을 복용한 피험자에게 "복용하지 않았다면"을 다시 실험할 수는 없기 때문이다.

논문의 가격 인상 예시

과거에 가격이 올랐던 시기의 판매 데이터를 아무리 모아도, "지금 우리가 가격을 두 배로 올리면 어떻게 될까"에는 답할 수 없다. 당시의 시장 조건을 정확히 복제하지 않는 한, 그때의 행동과 지금의 개입은 같은 것이 아니다.

이 방향성이 이 논문 전체의 핵심 통찰이다. 연관만 학습하는 머신러닝 시스템이 새로운 행동 · 실험 · 인과적 설명에 대해 추론할 수 없는 이유가 바로 여기서 나온다.

각주 b — 관찰 데이터의 어떤 속성을 최적화하든, 데이터 밖의 세계를 참조하지 않는 한 우리는 위계의 1층에 머문다.

SCM 추론 엔진 — 입력 3개, 출력 3개

Figure 2 · 3 — 그래픽 모델 + 구조 방정식 + 반사실 논리를 하나의 기계로




Figure 3 예시로 구체화

X = 약 복용, Y = 회복, Z = 성별. Z 가 X 와 Y 둘 다에 영향을 준다(교란).

Query : $Q = P(Y|do(X))$

엔진이 Tool 2로 자동 도출한 Estimand

$$ES = \sum_z P(Y|X, Z) P(Z)$$

성별별 조건부 분포를 추정하고, 각 성별의 비율로 가중 평균한다. 희소 데이터에서의 추정은 딥러닝이 잘하는 영역이다.

이 예시의 Fit Index 는 NULL — 그래프가 완전 (complete)해서 검증 가능한 함의가 없다.

7가지 도구 — 한 장에 압축

SCM 프레임워크로 수행되는 일곱 가지 인지 과제 — 이 중 Tool 2 만 조금 더 자세히

- 1 인과 가정의 인코딩 — 투명성과 검증가능성
- 2 do-calculus 와 교란의 통제
- 3 반사실의 알고리즘화
- 4 매개 분석 — 직접효과 · 간접효과의 분리
- 5 적응력 · 외적 타당성 · 표본 선택 편향
- 6 결측 데이터로부터의 복구
- 7 인과 발견 — 데이터로부터 인과 구조 추론

Tool 1 은 d-separation 으로 "이 가정이 데이터와 맞는지"를 검증 가능하게 만들었고, Tool 6 은 결측 데이터에서 관계를 복구할 수 있는 조건을 공식화했다.

TOOL 2

교란을 "길 막기 퍼즐"로 바꾼 backdoor

교란(confounding) — 둘 이상의 변수에 공통 원인이 숨어 있는 상태 — 은 데이터로부터 인과를 끌어내는 가장 큰 장애물로 오래 여겨졌다.

"backdoor" 라는 그래프 기준이 이것을 탈신비화했다. 어떤 공변량을 통제해야 하는가라는 문제가, 그래프에서 뒷문 경로를 막는 단순한 "길 막기(roadblocks)" 퍼즐로 환원되어 알고리즘으로 풀린다.

backdoor 기준이 성립하지 않는 모델에는 do-calculus 라는 기호 엔진이 있다. 정책 개입의 효과를 가능한 경우엔 예측하고, 주어진 가정으로 확정할 수 없으면 실패로 종료한다.

이 논문에는 성능 숫자가 없다

벤치마크 실험 논문이 아니라, 인과 추론을 가능하게 하는 수학적 도구 체계를 제시한 개념 · 이론 논문

그래서 BLEU 같은 정량 지표 대신, **각 도구가 이미 해결한 문제 유형**을 결과로 읽는 것이 정직한 리뷰가 된다.

Tool 1 — 검증가능성

d-separation 으로 "이 가정이면 데이터에 어떤 의존 패턴이 보여야 한다"를 도출 — 가정 자체를 반증 가능하게 만들었다.

Tool 2 — 교란의 해소

공변량 선택 문제를 단순 알고리즘으로 환원. do-calculus 는 식별 가능 여부를 스스로 판정한다.

Tool 3 · 4 — 설명의 생성

반사실 문장의 추정 가능 여부를 알고리즘이 판정. "X의 효과 중 Z가 매개한 비율"을 계산할 수 있게 되었다.

Tool 5 — 강건성

환경 변화로 인한 편향을 극복하는 완결된 방법론. 강화학습에서 학습 때 쓰지 않은 새 행동의 정책 평가에도 쓰인다.

Tool 6 — 결측 데이터

기존 문헌이 "무작위 결측"에만 갇혀 있던 문제를, 결측 과정 자체를 인과 모델링해 복구 조건을 공식화했다.

Tool 7 — 인과 발견

데이터와 양립하는 모델 집합을 압축 표현하고, 경우에 따라 그 집합에서 직접 인과 질의를 추정한다.

저자의 단서 — 이 모델들은 구조적 · 개념적이며 분포 형태를 가정하지 않는다. 다만 모든 추론의 타당성은 가정한 구조가 참인지에 결정적으로 의존한다.

핵심 정리 — 이 장만 읽어도 되게

문제 ① · 핵심 아이디어 ② · 결과 ③ · 그 이후

① 문제

통계 기반 머신러닝은 개입 · 반사실 질문에 답하지 못한다 — 적응력(강건성), 설명가능성, 인과 이해의 세 장벽.

② 핵심 아이디어

인과의 3단계 위계 — 연관 → 개입 → 반사실. 상위는 하위를 포함하되 역방향은 불가능하고, 2 · 3층 추론에는 환경의 인과 모델이 반드시 필요하다.

③ 결과(기여)

SCM 프레임워크와 7가지 도구로, 가정의 검증 · 교란 통제 · 반사실 추론을 알고리즘화했다. 정량 벤치마크가 아닌 도구 체계의 제시가 결과다.

그 이후

저자는 인과 추론이 차세대 AI의 지배적 패러다임이 될 것으로 전망한다 — 사용자와 원인 · 결과의 언어로 대화하는 시스템.

단, 예측 · 진단 · 인식 과제에는 모델 없는 머신러닝의 이론적 한계가 적용되지 않는다는 점도 저자가 함께 명시한다.

감사합니다

리뷰 팀 막시무스 | 대상 팀 닭고조이고기름치자 | DAT