

데이터 분석 학회 · 논문리뷰 발표

The Seven Tools of Causal Inference

with Reflections on Machine Learning

Judea Pearl (2019)

Communications of the ACM, Vol. 62, No. 3, March 2019, pp. 54–60 · DOI 10.1145/3241036

UCLA Technical Report R-481, February 2019

리뷰 팀 막시무스 | 대상 팀 닭고조이고기름치자

목차

index

- 1 문제와 세 가지 장벽
- 2 인과의 3단계 위계 — 핵심 아이디어
- 3 SCM 엔진과 7가지 도구
- 4 이 논문의 기여와 핵심 정리

핵심 메시지

머신러닝이 못 푸는 문제는 데이터가 부족해서가 아니라, 애초에 통계만으로는 답할 수 없는 질문이기 때문이다.

이 논문이 푸는 문제

인간 수준의 기계지능 — 그 전엔 뭐가 안 됐나

그 전 — 순수 통계 기반 머신러닝

- 상관관계(association)만 학습 — $P(y|x)$
- 환경이 바뀌면 무너짐 — 전이학습 · 도메인 적응 · 평생학습으로 우회 시도 중
- 예측은 잘해도 "왜"를 설명 못함 — "모델은 대부분 블랙박스"로 남아 있다"
- "담배를 금지하면?" 같은 개입(intervention) 질문에 답 불가
- "아스피린이 두통을 멈췄나?" 같은 반사실(counterfactual) 질문은 원천적으로 불가



이 논문 — 인과 모델링(SCM)

- 그래픽 모델 + 구조 방정식 + 반사실·개입 논리를 결합
- 인과 질문을 수학적으로 명확히 정의 — 대수 방정식 풀듯 다룸
- 지식이나 데이터가 부족해 답할 수 없을 때는 미리 경고까지 해줌
- 사회과학 · 의학에서 이미 "제2의 언어"가 된 도구를 머신러닝에 이식

한 줄 요약 — 순수 통계 학습으로는 답할 수 없던 인과 질문들을, 인과 다이어그램과 do-calculus로 답할 수 있게 만들었다.

인과의 3단계 위계 — Ladder of Causation

Figure 1 재현 — 이 논문을 논문이게 하는 것은 수식 하나가 아니라 이 구조 자체

단계 (기호)	대표 활동	대표 질문	논문의 예시
1. 연관 Association $P(y x)$	보기 Seeing	무엇인가? X를 보면 Y에 대한 나의 믿음이 어떻게 바뀌는가?	증상이 질병에 대해 무엇을 말해주는가? 설문이 선거 결과에 대해 무엇을 말해주는가?
2. 개입 Intervention $P(y do(x), z)$	하기 · 개입 Doing, Intervening	만약 X를 하면 어떻게 되는가?	아스피린을 먹으면 두통이 나올까? 담배를 금지하면 어떻게 될까?
3. 반사실 Counterfactuals $P(y_x x', y')$	상상 · 회고 Imagining, Retrospection	왜? Y를 일으킨 것이 X였나? 내가 다르게 행동했다면?	아스피린이 내 두통을 멈췄나? 오스왈드가 쏘지 않았다면 케네디는 살아 있을까?

level i의 질문은 level j ($j \geq i$)의 정보가 있어야 답할 수 있다 — 위계는 방향이 있고, 최상단이 가장 강력하다.

기호 읽는 법

각 층은 고유한 문장 형태(syntactic signature)를 가진다 — 기호가 곧 그 층의 한계선

1

$P(y|x) = p$ · 연관

" $X = x$ 를 관찰했을 때 $Y = y$ 일 확률이 p 이다" — 베이지안 네트워크나 대부분의 머신러닝 기법으로 효율적으로 계산 가능한 층.

2

$P(y|\text{do}(x), z)$ · 개입

" X 를 x 로 **강제로 설정**하고, 이후 $Z = z$ 를 관찰했을 때 $Y = y$ 일 확률" — 자연스럽게 관찰된 $X = x$ 와는 전혀 다른 개념. 무작위 실험으로 추정하거나 인과 베이지안 네트워크로 해석적으로 구한다.

3

$P(y_x|x', y')$ · 반사실

"실제로는 $X = x'$, $Y = y'$ 를 관찰했지만, 만약 X 가 x 였다면 $Y = y$ 였을 확률" — 실제 세계와 대안 세계를 **동시에 참조**하는 표기. 구조 방정식(함수 관계)에 기반한 모델에서만 계산할 수 있다.

왜 "위계"인가 — 방향이 있다

상위는 하위를 포함한다. 그러나 역방향은 원리적으로 불가능하다

위 → 아래 : 된다

반사실 질문에 답할 수 있는 모델이면 개입 · 관찰 질문에도 답할 수 있다. "가격을 두 배로 올리면?"은 "가격이 두 배였다면?"으로 물어 답할 수 있고, 연관 질문은 개입 부분을 지우고 관찰만 남기면 된다.

아래 → 위 : 안 된다

개입 질문은 순수 관찰 데이터만으로는 답할 수 없다 — 데이터가 아무리 커도 마찬가지다. 회고가 필요한 반사실 질문은 통제 실험 정보만으로도 답할 수 없다. 약을 복용한 피험자에게 "복용하지 않았다면"을 다시 실험할 수는 없기 때문이다.

논문의 가격 인상 예시

과거에 가격이 올랐던 시기의 판매 데이터를 아무리 모아도, "지금 우리가 가격을 두 배로 올리면 어떻게 될까"에는 답할 수 없다. 당시의 시장 조건을 정확히 복제하지 않는 한, 그때의 행동과 지금의 개입은 같은 것이 아니다.

이 방향성이 이 논문 전체의 핵심 통찰이다. 연관만 학습하는 머신러닝 시스템이 새로운 행동 · 실험 · 인과적 설명에 대해 추론할 수 없는 이유가 바로 여기서 나온다.

각주 b — 관찰 데이터의 어떤 속성을 최적화하든, 데이터 밖의 세계를 참조하지 않는 한 우리는 위계의 1층에 머문다.

SCM 추론 엔진 — 입력 3개, 출력 3개

Figure 2 · 3 — 그래픽 모델 + 구조 방정식 + 반사실 논리를 하나의 기계로




Figure 3 예시로 구체화

X = 약 복용, Y = 회복, Z = 성별. Z 가 X 와 Y 둘 다에 영향을 준다(교란).

Query : $Q = P(Y|do(X))$

엔진이 Tool 2로 자동 도출한 Estimand

$$ES = \sum_z P(Y|X, Z) P(Z)$$

성별별 조건부 분포를 추정하고, 각 성별의 비율로 가중 평균한다. 희소 데이터에서의 추정은 딥러닝이 잘하는 영역이다.

이 예시의 Fit Index 는 NULL — 그래프가 완전 (complete)해서 검증 가능한 함의가 없다.

7가지 도구 — 한 장에 압축

SCM 프레임워크로 수행되는 일곱 가지 인지 과제 — 이 중 Tool 2 만 조금 더 자세히

- 1 인과 가정의 인코딩 — 투명성과 검증가능성
- 2 do-calculus 와 교란의 통제
- 3 반사실의 알고리즘화
- 4 매개 분석 — 직접효과 · 간접효과의 분리
- 5 적응력 · 외적 타당성 · 표본 선택 편향
- 6 결측 데이터로부터의 복구
- 7 인과 발견 — 데이터로부터 인과 구조 추론

Tool 1 은 d-separation 으로 "이 가정이 데이터와 맞는지"를 검증 가능하게 만들었고, Tool 6 은 결측 데이터에서 관계를 복구할 수 있는 조건을 공식화했다.

TOOL 2

교란을 "길 막기 퍼즐"로 바꾼 backdoor

교란(confounding) — 둘 이상의 변수에 공통 원인이 숨어 있는 상태 — 은 데이터로부터 인과를 끌어내는 가장 큰 장애물로 오래 여겨졌다.

"backdoor" 라는 그래프 기준이 이것을 탈신비화했다. 어떤 공변량을 통제해야 하는가라는 문제가, 그래프에서 뒷문 경로를 막는 단순한 "길 막기(roadblocks)" 퍼즐로 환원되어 알고리즘으로 풀린다.

backdoor 기준이 성립하지 않는 모델에는 **do-calculus** 라는 기호 엔진이 있다. 정책 개입의 효과를 가능한 경우엔 예측하고, 주어진 가정으로 확정할 수 없으면 실패로 종료한다.

성능 숫자의 부재

벤치마크 실험 논문이 아니라, 인과 추론을 가능하게 하는 수학적 도구 체계를 제시한 개념 · 이론 논문

그래서 BLEU 같은 정량 지표 대신, **각 도구가 이미 해결한 문제 유형**을 결과로 읽는 것이 정직한 리뷰가 된다.

Tool 1 — 검증가능성

d-separation 으로 "이 가정이면 데이터에 어떤 의존 패턴이 보여야 한다"를 도출 — 가정 자체를 반증 가능하게 만들었다.

Tool 2 — 교란의 해소

공변량 선택 문제를 단순 알고리즘으로 환원. do-calculus 는 식별 가능 여부를 스스로 판정한다.

Tool 3 · 4 — 설명의 생성

반사실 문장의 추정 가능 여부를 알고리즘이 판정. "X의 효과 중 Z가 매개한 비율"을 계산할 수 있게 되었다.

Tool 5 — 강건성

환경 변화로 인한 편향을 극복하는 완결된 방법론. 강화학습에서 학습 때 쓰지 않은 새 행동의 정책 평가에도 쓰인다.

Tool 6 — 결측 데이터

기존 문헌이 "무작위 결측"에만 갇혀 있던 문제를, 결측 과정 자체를 인과 모델링해 복구 조건을 공식화했다.

Tool 7 — 인과 발견

데이터와 양립하는 모델 집합을 압축 표현하고, 경우에 따라 그 집합에서 직접 인과 질의를 추정한다.

저자의 단서 — 이 모델들은 구조적 · 개념적이며 분포 형태를 가정하지 않는다. 다만 모든 추론의 타당성은 가정한 구조가 참인지에 결정적으로 의존한다.

핵심 정리

문제 ① · 핵심 아이디어 ② · 결과 ③ · 그 이후

① 문제

통계 기반 머신러닝은 개입 · 반사실 질문에 답하지 못한다 — 적용력(강건성), 설명가능성, 인과 이해의 세 장벽.

② 핵심 아이디어

인과의 3단계 위계 — 연관 → 개입 → 반사실. 상위는 하위를 포함하되 역방향은 불가능하고, 2 · 3층 추론에는 환경의 인과 모델이 반드시 필요하다.

③ 결과(기여)

SCM 프레임워크와 7가지 도구로, 가정의 검증 · 교란 통제 · 반사실 추론을 알고리즘화했다. 정량 벤치마크가 아닌 도구 체계의 제시가 결과다.

그 이후

저자는 인과 추론이 차세대 AI의 지배적 패러다임이 될 것으로 전망한다 — 사용자와 원인 · 결과의 언어로 대화하는 시스템.

단, 예측 · 진단 · 인식 과제에는 모델 없는 머신러닝의 이론적 한계가 적용되지 않는다는 점도 저자가 함께 명시한다.

감사합니다

리뷰 팀 막시무스 | 대상 팀 닭고조이고기름치자 | DAT